

Étude complète — Prédiction de la catégorie NPS des clients silencieux

Annexe au write-up. Un document par phase CRISP-DM, généré par `python -m src.rapports`.

Synthèse — Prédire la catégorie NPS des clients silencieux

Pour un lecteur non technique. Chaque chiffre est calculé et retrouvable dans les six documents de l'étude.

Ce qu'on a construit

Un modèle qui, pour chacun des clients n'ayant pas répondu à l'enquête NPS, estime s'il est Détracteur, Passif ou Promoteur ; une application qui en tire une **liste d'appels priorisée** avec, pour chaque client, les raisons de la prédiction et le levier à proposer ; une estimation du **NPS des 85 % silencieux** ; et un dispositif de suivi.

Les cinq chiffres

NPS réel de la base sous la grille retenue	+21 — connu ici parce que la satisfaction des 7 043 clients est dans le jeu de données ; ce n'est pas une sortie du modèle. Avec la grille de l'énoncé prise au pied de la lettre : -42
NPS des silencieux, estimé par le modèle	+4 (intervalle +2 à +5). La vérité, connue ici seulement, est +20 : l'estimateur sous-estime de 17 points et l'intervalle ne couvre pas ce biais. Les répondants seuls donneraient +27. Ce chiffre se lit en relatif — classement des segments — pas en absolu
Sur 500 appels, part de vrais détracteurs	51% contre 18% au hasard — ×2.8
Gain net supplémentaire par campagne	18 585 € à hypothèses de coût constantes (à valider)
Détracteurs retrouvés	63% — mais 47% seulement chez les moins de 30 ans

Les trois résultats à retenir

- 1. La grille NPS proposée dans l'énoncé fabrique un résultat faux.** Appliquée telle quelle, elle donne un NPS de **-42**, à 60–75 points des benchmarks télécom, parce qu'elle classe en détracteurs 2665 clients « moyennement satisfaits » (38% de la base) dont 84 % sont restés fidèles. En demandant aux données à qui ces clients ressemblent, on trouve qu'ils penchent à **72% du côté des promoteurs**. Le NPS corrigé est de **+21**, dans la fourchette du secteur.
- 2. Le modèle multiplie par 2.8 l'efficacité des appels**, et il a été choisi honnêtement. Quinze modèles de sept familles ont été comparés ; le choix s'est fait **sans regarder les clients sur lesquels il est évalué**, avec une règle qui préfère le plus simple quand les écarts sont dans le bruit. Retenu : logistique ordinale. Évalué dans les conditions réelles : entraîné sur 15 % de répondants dont la composition est biaisée (les mécontents et les enthousiastes répondent plus), testé sur les 85 % restants.
- 3. Il rate davantage les jeunes détracteurs** : 47% de rappel chez les moins de 30 ans contre 73% chez les 60 ans et plus — alors qu'aucune variable d'âge n'entre dans le modèle. On a mesuré pourquoi : les variables contractuelles **reconstruisent** l'âge. Une correction est chiffrée ; la décision de l'appliquer appartient au métier et au juridique, pas au modèle.

Ce qu'il faut savoir sur la fiabilité

- Aucune variable liée au départ des clients n'est utilisée.** Le dataset en contient plusieurs qui auraient donné un score presque parfait et un modèle inutilisable. Identifiées, mesurées, exclues.
- Les probabilités servent à classer les clients entre eux, pas à lire une fréquence** : ajustées sur des répondants biaisés, elles sont surestimées. L'application le dit à chaque écran.
- Ce que le modèle appelle « drivers » sont des associations**, pas des causes. Contrat sans engagement, faible ancienneté, absence de parrainage et facture élevée vont avec la détraction ; l'offre commerciale E « crédit » le départ parce qu'elle a été proposée à des clients déjà fragiles.

La décision demandée

Appeler les clients les plus à risque n'est pas la stratégie la plus rentable : la recherche établit qu'il faut cibler ceux **dont le comportement change le plus quand on les appelle**. Mesurer cela ne demande qu'une chose, gratuite : **ne pas contacter 10 à 20 % des clients ciblés à la prochaine campagne, tirés au hasard**. Sans ce groupe de contrôle, on ne saura jamais si la campagne a servi — et le modèle se dégradera en réapprenant ses propres effets.

Ce que cette étude ne fait pas

Elle n'estime pas l'effet d'un appel (aucune campagne dans les données). Ses verbatims clients sont synthétiques et le signal texte, démontré techniquement, n'est pas déployable sur cette base. Ses hypothèses économiques sont des paramètres à valider avec l'équipe rétention. TabPFN 2.5 n'a pas pu être évalué — sa licence PriorLabs demande un compte et une clé API — mais TabICL et TabPFN v2 l'ont été, sur des poids publics.

Lire la suite

[Phase 1 — métier](#) · [Phase 2 — données](#) · [Phase 3 — préparation](#) · [Phase 4 — modélisation](#) · [Phase 5 — évaluation](#) · [Phase 6 — déploiement](#) · [Conformité à l'énoncé](#)

Phase 1 — Compréhension métier

En bref. Un opérateur télécom ne connaît le NPS que de ~15 % de ses clients. On construit un modèle qui estime la catégorie NPS des 85 % silencieux, une liste d'appels priorisée pour l'équipe rétention, et une lecture des drivers de détraction. La cible est **ordonnée** (Détracteur < Passif < Promoteur) et **déséquilibrée** ; les critères de succès sont chiffrés avant toute ligne de code.

1. Le problème et ses trois usages

Usage demandé (énoncé § 2)	Ce que le livrable fournit	Où
Prioriser les appels vers les détracteurs prédicts	liste classée par P(Détracteur) calibrée, capacité K réglable, export CSV	application, page <i>Prioriser les appels</i>
Identifier les drivers de détraction, au niveau individuel et par segment	contributions par client ; drivers par segment (contrat, ancienneté, type d'accès) ; leviers actionnables	phase 5 § 6, application
Simuler le NPS attendu des 85 % silencieux	NPS prédit des silencieux avec intervalle bootstrap, comparé au NPS observé des répondants et, ici seulement, à la vérité	phase 5 § 4

2. Critères de succès, fixés a priori

Les seuils ci-dessous sont écrits dans `config.yaml` (section `criteres_succes`), vérifiés par le pipeline (clé `criteres_succes` de `resultats.json`) et verrouillés par un test automatisé. Un critère qu'on ne peut pas rater n'est pas un critère : chacun a donc une valeur numérique décidée avant la modélisation, et le tableau affiche le résultat obtenu à côté.

Niveau	Critère	Cible chiffrée a priori	Résultat (phase 5)	
Métier	Précision@K sur les détracteurs, K = 500 appels/mois	$\geq 35\%$, et lift ≥ 2	51% vs 18% de base ($\times 2.8$)	✓
Métier	Gain net d'une campagne ciblée vs ciblage aléatoire	> 0 €	18 585 € apportés par le modèle	✓
Data science	Kappa quadratique pondéré, modèle retenu vs baseline logistique	au niveau de la baseline ou au-dessus	0.384 contre 0.371	✓
Data science	Rappel Détracteur, modèle retenu vs baseline logistique	au niveau de la baseline ou au-dessus	0.629 contre 0.805	⚠ non atteint — voir ci-dessous
Data science	Aucune classe abandonnée	rappel $\geq 5\%$ sur les trois classes	minimum 42%	✓
Éthique	Écart de rappel Détracteur entre sous-groupes	mesuré, signalé au-delà de 10%	26 pts sur l'âge	⚠ signalé (phase 5 § 7)

Le critère de rappel Détracteur n'est pas atteint, et ce n'est pas un oubli. La baseline logistique capte 81% des détracteurs contre 63% pour le modèle retenu. Elle y parvient en prédisant « Détracteur » beaucoup plus souvent : sa précision est plus faible, et surtout elle écrase la classe Passif. Le critère métier — qui décide réellement de l'usage — départage dans l'autre sens : à capacité d'appel égale, c'est la précision@K qui compte, et elle vaut 51%. Le rappel brut d'un classifieur qui sur-prédit une classe n'est pas une performance ; on le publie en défaveur du modèle retenu, avec la raison de ne pas le suivre. Détail en phase 4 § 6.

3. Formulation du problème d'apprentissage

L'énoncé demande d'arbitrer entre classification nominale, classification ordinale et régression avec seuillage, et de **justifier**. On ne tranche pas a priori : les trois formulations sont instanciées dans le catalogue de modèles (phase 4 § 3) et comparées par la même mesure — le kappa quadratique pondéré, qui pénalise une erreur de deux crans plus qu'une erreur d'un cran, ce qui est le comportement métier correct sur une cible ordonnée.

4. Hypothèses déclarées

- Satisfaction Score (1–5) est un proxy acceptable d'une note NPS (0–10). C'est une hypothèse, pas une identité : le NPS mesure une intention de recommandation, la satisfaction une expérience. Elero et al. (2026) font la même approximation et la discutent.
- Le biais de non-réponse simulé (les mécontents et les enthousiastes répondent plus) ressemble au biais réel. Sa forme est plausible, pas observée.
- Les patterns d'un opérateur californien fictif se transposent au cadrage panafricain de l'énoncé.

5. Contraintes et ce qu'elles interdisent

5.1 Contraintes de données

Dataset fictif (IBM), une seule photographie, aucun historique, aucune campagne de rétention enregistrée. Conséquence directe : **aucune estimation d'effet causal n'est possible** — le modèle classe par risque, pas par sensibilité à l'appel (phase 5 § 8, phase 6 § 5).

5.2 Contraintes de projet : deux semaines, et la gestion du périmètre

L'énoncé fixe une limite de deux semaines et annonce valoriser « *thoughtful scope management more than over-engineering* » (§ 1). Le périmètre a donc été arbitré explicitement, et les refus sont documentés au même titre que les ajouts.

Décision	Sens	Raison
Quinze modèles, sept familles	dans le périmètre	l'exigence minimale est « au moins deux familles ». La grille sert à mesurer le plafond de signal des données, pas à chercher un meilleur score : quand quinze modèles très différents plafonnent au même endroit, la limite vient des données, et c'est cette conclusion qui est utile au métier. Coût réel : 35 minutes d'exécution, une seule fois.
CORAL / CORN (réseaux ordinaux)	hors périmètre	environ 1 000 lignes d'entraînement : un réseau profond n'a aucune chance de battre un modèle linéaire régularisé. Cités et écartés avec l'argument (phase 4 § 3).
Enrichissement Censur par code postal	hors périmètre	voir phase 2 § 6 : l'affectation des clients aux codes postaux est produite par le générateur d'IBM.
MLflow	hors périmètre	une seule exécution déterministe, tracée par <code>resultats.json</code> et le seed : un serveur de suivi n'ajouterait rien ici.
TabPFN 2.5	partiellement hors périmètre	bloqué par une acceptation de licence externe ; TabICL et TabPFN v2 sont évalués à sa place (phase 4 § 8).
Appels d'API payants pour les verbatims	hors périmètre	le bonus texte est traité avec des textes rédigés hors ligne et assemblés localement, de façon reproductible (phase 4 § 9).

Ce que cette contrainte **n'a pas** permis : entraîner un modèle par segment, tester l'enrichissement externe, et mener une véritable campagne avec groupe de contrôle — la seule façon de passer du risque à la sensibilité (phase 6 § 5).

6. Registre de risques

Risque	Parade dans l'étude
Fuite de données → score irréal, modèle inutilisable	registre de fuites quantifié (phase 2 § 4) + double diagnostic (phase 4 § 5)
Cible mal construite → tout le reste invalide	arbitrage empirique des « 3 » + sensibilité au mapping + bruit d'étiquettes (phases 3, 5)
Sélection de modèle sur le jeu de test	sélection par validation croisée sur les répondants ; les silencieux ne servent qu'au test (phase 4 § 6)
Modèle inéquitable non détecté	audit par sous-groupe, audit des proxies, mitigation chiffrée (phase 5 § 7)
Livrable non reproductible	seed unique, <code>python -m src.run</code> , test à blanc depuis copie vierge, tests automatisés

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Cible traitée comme ordonnée et déséquilibrée	trois classes ordonnées par construction ; Passif = 38% de la base, Détracteur = 20%	phase 3 § 4
Métrique principale = kappa quadratique pondéré	seule métrique usuelle qui distingue une erreur d'un cran d'une erreur de deux crans	phase 5 § 1
Critères de succès chiffrés avant modélisation	exigence CRISP-DM ; évite de choisir la métrique qui arrange	ce document § 2

Phase 2 — Compréhension des données

En bref. Cinq tables IBM Telco 11.1.3+ jointes sans perte (7043 clients × 51 colonnes). Trois faits structurent tout le projet : (1) la note **3** pèse 38% de la base et 84% de ces clients sont restés ; (2) le dataset **contient sa propre réponse** — satisfaction 1–2 → 100 % de départs, 4–5 → 0 % — donc toute colonne liée au churn est une fuite ; (3) les offres commerciales ont été **ciblées** sur des clients fragiles, ce qui interdit toute lecture causale.

1. Sources et jointure

Table	Lignes × colonnes	Clé	Contenu
demographics	7 043 × 9	Customer ID	genre, âge, situation familiale
location	7 043 × 9	Customer ID	ville, code postal, coordonnées
population	1 671 × 3	Zip Code	population du code postal
services	7 043 × 30	Customer ID	contrat, services, facturation, parrainage
status	7 043 × 11	Customer ID	Satisfaction Score , statut client, churn (label, valeur, score, catégorie, raison), CLTV

Jointure **gauche** à partir de `demographics`, `population` rattachée par `Zip Code`. Deux portes de contrôle, pas une : **7043 lignes** après jointure et 0 doublon d'identifiant (aucune ligne perdue ni dupliquée), puis une vérification qu'aucun client n'arrive sans ligne de services, de statut ou de localisation. Une jointure interne masquerait ce second cas en supprimant silencieusement les clients incomplets ; ici, un client incomplet fait échouer le pipeline.

⚠ **La variable cible vit dans la même table que le churn.** `Satisfaction Score` est livré par IBM dans `status`, aux côtés de `Churn Label`, `Churn Value`, `Churn Score`, `Customer Status` et `CLTV`, et pour le même trimestre. Ce n'est pas un détail d'intendance : c'est le premier argument du registre de fuites (§ 4). Toutes les colonnes qui accompagnent la cible dans cette table ont été construites en même temps qu'elle, et aucune n'est disponible au moment où l'on voudrait prédire.

2. Dictionnaire des données

Statut de chaque colonne, décidé au registre de fuites (§ 4) : `feature` = variable explicative candidate (27) · `audit_seulement` = exclue du modèle, utilisée pour l'audit d'équité (12) · `fuite_*` = interdite (7) · `techniques` = identifiant ou constante (4) · `cible` (1).

Colonne	Type	Manquants	Modalités	Exemple	Statut
Customer ID	object	0.0%	7043	8779-QRDMV	techniques
Gender	object	0.0%	2	Male	audit_seulement
Age	int64	0.0%	62	78	audit_seulement
Under 30	object	0.0%	2	No	audit_seulement
Senior Citizen	object	0.0%	2	Yes	audit_seulement
Married	object	0.0%	2	No	audit_seulement
Dependents	object	0.0%	2	No	audit_seulement
Number of Dependents	int64	0.0%	10	0	audit_seulement
Country	object	0.0%	1	United States	techniques
State	object	0.0%	1	California	techniques
City	object	0.0%	1106	Los Angeles	audit_seulement
Zip Code	int64	0.0%	1626	90022	audit_seulement
Lat Long	object	0.0%	1679	34.02381, -118.156582	techniques
Latitude	float64	0.0%	1626	34.02381	audit_seulement
Longitude	float64	0.0%	1625	-118.156582	audit_seulement
Referred a Friend	object	0.0%	2	No	feature
Number of Referrals	int64	0.0%	12	0	feature
Tenure in Months	int64	0.0%	72	1	feature
Offer	object	55.0%	5	Offer E	feature
Phone Service	object	0.0%	2	No	feature
Avg Monthly Long Distance Charges	float64	0.0%	3584	0.0	feature
Multiple Lines	object	0.0%	2	No	feature
Internet Service	object	0.0%	2	Yes	feature
Internet Type	object	21.7%	3	DSL	feature
Avg Monthly GB Download	int64	0.0%	50	8	feature
Online Security	object	0.0%	2	No	feature
Online Backup	object	0.0%	2	No	feature
Device Protection Plan	object	0.0%	2	Yes	feature
Premium Tech Support	object	0.0%	2	No	feature
Streaming TV	object	0.0%	2	No	feature
Streaming Movies	object	0.0%	2	Yes	feature
Streaming Music	object	0.0%	2	No	feature
Unlimited Data	object	0.0%	2	No	feature
Contract	object	0.0%	3	Month-to-Month	feature
Paperless Billing	object	0.0%	2	Yes	feature
Payment Method	object	0.0%	3	Bank Withdrawal	feature
Monthly Charge	float64	0.0%	1585	39.65	feature
Total Charges	float64	0.0%	6540	39.65	feature
Total Refunds	float64	0.0%	500	0.0	feature
Total Extra Data Charges	int64	0.0%	16	20	feature
Total Long Distance Charges	float64	0.0%	6110	0.0	feature
Total Revenue	float64	0.0%	6996	59.65	feature
Satisfaction Score	int64	0.0%	5	3	cible
Customer Status	object	0.0%	3	Churned	fuite_consequence
Churn Label	object	0.0%	2	Yes	fuite_consequence
Churn Value	int64	0.0%	2	1	fuite_consequence
Churn Score	int64	0.0%	81	91	fuite_modele_amont
CLTV	int64	0.0%	3438	5433	fuite_modele_amont
Churn Category	object	73.5%	5	Competitor	fuite_disponibilite
Churn Reason	object	73.5%	20	Competitor offered mor	fuite_disponibilite
Population	int64	0.0%	1569	68701	audit_seulement


3. Qualité des données — cinq contrôles

3.1 Valeurs manquantes. Quatre colonnes, toutes à manquants **structurels** (le vide a un sens), aucune imputation :

Colonne	Manquants	Part	Nature	Traitement
Churn Category	5174	73.5%	structurel	colonne exclue (fuite de disponibilité)
Churn Reason	5174	73.5%	structurel	colonne exclue (fuite de disponibilité)
Offer	3877	55.0%	structurel	catégorie « Aucune offre »
Internet Type	1526	21.7%	structurel	catégorie « Pas d'internet »

3.2 Doublons. 0 sur l'identifiant, 0 sur l'ensemble des colonnes hors identifiant.

3.3 Valeurs aberrantes (règle IQR $\times 1,5$) — **conservées** : un client à 100 Go/mois ou à 120 \$/mois est un client réel, précisément le profil qu'un modèle de détraction doit voir ; les modèles retenus (standardisation + régularisation, arbres) y sont robustes.



Variable	Hors IQR $\times 1,5$
Tenure in Months	0
Monthly Charge	0
Total Charges	0
Total Revenue	21
Avg Monthly GB Download	362

3.4 Cohérence interne. Ancienneté nulle : 0 client. Écart $> 50\%$ entre Total Charges et Monthly Charge $\times$ Tenure : 2 lignes — attendu (tarif variable sur la durée de vie), non corrigé, documenté.

3.5 Colonnes constantes. Country, State — base 100 % Californie. Supprimées.

4. Registre de fuites — l'étape la plus discriminante

Le fait fondateur.

Satisfaction	Restés	Partis	% départ
1.0	0.0	922.0	100.0
2.0	0.0	518.0	100.0
3.0	2236.0	429.0	16.1
4.0	1789.0	0.0	0.0
5.0	1149.0	0.0	0.0

Satisfaction 1–2 $\rightarrow$ **100 % de départs** ; 4–5 $\rightarrow$ **0 %**. Connaître le churn, c'est connaître la cible. Or au moment où l'on veut détecter un détracteur, il n'est pas encore parti : l'information n'existe pas. Toute colonne liée au churn est donc une fuite — et une fuite de trois natures :

Ce que cette séparation parfaite dit vraiment. L'énoncé présente la satisfaction comme « *a real human-provided signal inside the dataset, not a fabricated label* ». Une relation déterministe parfaite entre une note d'enquête et un départ — aucun client noté 4–5 parti, aucun client noté 1–2 resté — **n'existe dans aucune enquête réelle** : il y a toujours des clients satisfaits qui partent pour un déménagement ou un prix, et des mécontents qui restent par inertie. Le plus probable est donc que, dans cet échantillon IBM, la note ait été rendue cohérente avec le statut de churn au moment de la génération. Nous ne pouvons pas le prouver, et c'est précisément pour cela qu'il faut l'écrire. Deux conséquences, toutes deux tenues dans la suite de l'étude : **(a)** l'exclusion des colonnes de churn n'est pas une précaution parmi d'autres, c'est la condition pour que le travail ait un sens ; **(b)** les performances mesurées ici sont une **borne haute** — sur de vraies réponses, plus bruitées, il faut s'attendre à une dégradation de l'ordre de celle que mesure le test de bruit d'étiquettes (phase 5 § 5.2). La discussion complète de cette limite est en phase 3 § 1.6.


Nature	Définition	Colonnes	Décision
Conséquence	la colonne est un effet de la cible	Churn Label, Churn Value, Customer Status	exclues
Disponibilité	la colonne n'existe que pour une partie de la population — sa présence trahit la réponse	Churn Category, Churn Reason (5 174 vides = clients restés)	exclues
Modèle amont	la colonne est la sortie d'un autre modèle (IBM SPSS)	Churn Score, CLTV	exclues des features ; CLTV admise en couche de décision (phase 5 § 3)

Churn Score et CLTV par niveau de satisfaction :

Satisfaction	Churn Score moyen	CLTV moyenne
1.0	82.0	4158.0
2.0	82.0	4104.0
3.0	55.0	4473.0
4.0	50.0	4514.0
5.0	50.0	4381.0

Churn Score passe de ~82 à ~50 : une prédiction déguisée en donnée. CLTV est plate — peu informative comme feature, mais légitime pour pondérer *qui appeler* parmi les détracteurs prédits.

Quantifier au lieu d'affirmer. Information mutuelle de chaque colonne avec la cible :



Colonne	Information mutuelle	Statut
Customer Status	0.421	fuite_consequence
Churn Value	0.416	fuite_consequence
Churn Score	0.281	fuite_modele_amont
Contract	0.092	feature
Number of Referrals	0.058	feature
Internet Type	0.052	feature
Tenure in Months	0.046	feature
Monthly Charge	0.045	feature
Offer	0.033	feature
CLTV	0.016	fuite_modele_amont


Les colonnes exclues portent une information sans commune mesure avec les features légitimes. C'est la mesure qui justifie l'exclusion, pas l'intuition.

Contre-exemple publié. Mustafa et al. (2021) annoncent 98 % d'exactitude en prédisant le churn avec la note NPS et la catégorie NPS parmi les features, alors que leur cible en dérive. Leurs modèles linéaires font 41 %, leurs arbres 98 % : cet écart est la **signature** d'une variable qui fuit. On applique ce test en phase 4 § 5.

Démographie et géographie : exclues du modèle, gardées pour l'audit. Gender, Age, Under 30, Senior Citizen, Married, Dependents, Number of Dependents, City, Zip Code, Latitude, Longitude, Population. Précédent : Elero et al. (2026) excluent délibérément les démographiques. Position cohérente avec le métier (les leviers actionnables sont contractuels) et avec l'énoncé § 4.7 (le code postal est un proxy socio-économique). Le coût de cette exclusion est **chiffré** en phase 5 § 5, et la mesure de ce que les features retenues révèlent malgré tout de ces attributs en phase 5 § 7.

5. Analyse exploratoire


5.1 La cible.




Note	Clients	Part
1	922	13.1%
2	518	7.4%
3	2665	37.8%
4	1789	25.4%
5	1149	16.3%

La note 3 pèse **2665 clients, 37.8% de la base**, et 2236 d'entre eux (84%) sont toujours clients. Où les placer dans la grille NPS décide de tout le reste (phase 3 § 1).


5.2 Numériques par niveau de satisfaction. Écarts de médiane entre les notes basses (1–2) et hautes (4–5) : **Tenure in Months** passe d'une médiane de 10 chez les notes 1–2 à 35 chez les 4–5 ; **Avg Monthly GB Download** passe d'une médiane de 19 chez les notes 1–2 à 14 chez les 4–5 ; **Monthly Charge** passe d'une médiane de 80 chez les notes 1–2 à 59 chez les 4–5. Les variables de relation — ancienneté, parrainage — séparent bien mieux les extrêmes que les variables de consommation, ce qui oriente la sélection de features (phase 3 § 3).




5.3 Catégorielles : force d'association. Le type de contrat et l'offre reçue dominent ; les variables démographiques (gris) sont faiblement associées à la satisfaction — leur exclusion devrait donc coûter peu (vérifié en phase 5).



5.4 Corrélations entre numériques. Total Charges, Total Revenue et Tenure in Months sont mécaniquement liés (le total cumule le mensuel sur la durée). Traité en phase 3 § 3 (colinéarité).



5.5 La quasi-expérience du dataset : Offer.



Offre	Clients	Taux de départ	Satisfaction moy.
Offer A	520	6.7%	3.55
Offer B	824	12.3%	3.48
Offer C	415	22.9%	3.32
Offer D	602	26.7%	3.25
Aucune offre	3877	27.1%	3.24
Offer E	805	52.9%	2.81

Les clients ayant reçu l'**offre E partent deux fois plus** que ceux qui n'ont rien reçu. Lire « l'offre E fait fuir » serait une erreur : c'est un **biais d'indication** — l'offre a été proposée à des clients déjà en difficulté, comme un médicament à des patients déjà malades. On ne lit pas un effet causal dans des données observationnelles ; ce constat fonde les limites du ciblage (phase 5 § 8).

6. Enrichissement externe : décision

L'énoncé autorise des sources externes (recensement par code postal, benchmarks télécom) à condition d'en justifier la pertinence métier. **Décision : aucune.** Deux raisons, et la seconde a été reformulée parce que la première version était fausse.

(1) Le proxy qu'on vient d'exclure reviendrait par la fenêtre. Le dataset contient déjà une variable de contexte socio-démographique externe, jointe à la maille du **code postal** et non du client (`Population`), et elle est exclue du modèle au titre de l'équité. Ajouter des revenus médians par code postal reviendrait à réintroduire le proxy socio-économique qu'on a sorti par la porte (énoncé § 4.7).

(2) La géographie est réelle, mais l'affectation des clients ne l'est pas. Les codes postaux, les villes et les populations sont d'authentiques données californiennes (90022 Los Angeles, 94112 San Francisco, 95405 Santa Rosa), et l'énoncé suggère précisément un enrichissement Census sur ces codes postaux : techniquement, c'est faisable. Ce qui est fabriqué, c'est l'**attribution de chaque client fictif à un code postal**, produite par le générateur d'IBM. Un modèle qui apprendrait sur un revenu médian par code postal apprendrait donc ce générateur, pas un comportement de marché — et ne se transposerait pas à l'opérateur panafricain du cadrage. *(La rédaction précédente disait « coordonnées californiennes fictives » : c'était inexact, la géographie est réelle et cette imprécision affaiblissait un argument qui tient sans elle.)*

Les **benchmarks NPS télécom** publiés sont en revanche utilisés comme corroboration externe de la construction de la cible, avec leurs sources et leurs réserves (phase 3 § 1.1).

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Jointure interne, porte de contrôle à 7 043 lignes	aucune perte tolérée ; un client sans ligne de services est une erreur, pas un cas	test <code>test_jointure_sans_perte</code>
Manquants structurels → catégorie explicite, jamais imputés	le vide a un sens métier (pas d'offre, pas d'internet) ; imputer fabriquerait de l'information	§ 3.1
Aberrantes conservées	profils réels ; robustesse des modèles retenus	§ 3.3
Toute colonne liée au churn exclue, en trois natures nommées	fait fondateur : satisfaction ↔ churn ; information mutuelle mesurée	§ 4, test <code>test_aucune_colonne_churn_dans_les_features</code>
Démographie et géographie hors modèle, audit seulement	leviers non actionnables ; proxies d'attributs protégés (énoncé § 4.7)	§ 4, phase 5 § 7
Aucun enrichissement externe	réintroduirait un proxy socio-économique ; dataset fictif	§ 6


Phase 3 — Préparation des données

En bref. La cible NPS est construite à partir de la satisfaction 1–5 par trois mappings ; le mapping de l'énoncé donne un NPS de **-42**, hors de toute plausibilité sectorielle, parce qu'il envoie les 2665 clients « 3 » chez les détracteurs. Un arbitrage **empirique** (modèle entraîné sur les seuls extrêmes) montre qu'ils penchent à 72% côté promoteur ; le bloc rejoint les Passifs (NPS **+21**). 18 variables numériques et 17 catégorielles sont retenues, chacune avec l'hypothèse qui la justifie ; le déséquilibre est traité par pondération de classes, choix comparé à quatre alternatives ; tout le préprocessing vit dans un `Pipeline` scikit-learn.

1. Construction de la cible NPS

Le dataset donne une satisfaction de 1 à 5. Le NPS a trois classes. Personne ne fournit la traduction : c'est à nous de la construire et de la défendre.

	Détracteur	Passif	Promoteur	NPS	Logique
M1	1, 2, 3	4	5	-42.0	mapping baseline de l'énoncé (fidèle à l'échelle : 3/5 = 5/10 = détracteur)
M2	1, 2	3, 4	5	-4.1	recentré : le 3 est le milieu, donc passif
M3	1, 2	3	4, 5	+21.3	retenu — le « 3 » arbitré par les données (§ 1.2), le « 4 » reclassé par hypothèse d'échelle (§ 1.3)




1.1 Pourquoi M1 pose problème. M1 est le mapping *fidèle à l'échelle* — et c'est précisément pour ça qu'il est faux : une échelle à 5 points compressée dans les bandes NPS envoie 58% de la base chez les détracteurs, dont 2 665 clients à « 3 » qui, à 84%, sont restés. Un NPS de -42 est à 60–75 points des benchmarks télécom publiés (+19 à +34 ; voir la note de sources ci-dessous). Ce n'est pas un résultat, c'est un signal d'alerte sur la construction.

D'où vient le « +19 à +34 », et ce qu'il vaut. Trois compilations commerciales de NPS télécom, consultées en septembre 2026 : [CustomerGauge](#), [QuestionPro](#) et [Survicate](#). **Pertinence métier** : marché américain, le même que celui du dataset, et NPS relationnel — la même mesure que celle qu'on reconstruit. **Réserves, qui comptent autant que le chiffre** : ce sont des sources d'éditeurs, pas de la littérature relue ; leur dispersion est large (19, 31, 34, voire 54 selon l'éditeur et l'année) ; et notre NPS est calculé sur une satisfaction de 1 à 5, pas sur une intention de recommandation de 0 à 10 (hypothèse 1 de la phase 1). Ce repère sert donc à qualifier M1 d'**implausible**, à l'ordre de grandeur près — jamais à valider un mapping ni à servir de cible.

1.2 L'arbitrage empirique des « 3 » (méthode d'Elero et al., 2026, qui l'appliquent aux notes 7 et 8). Plutôt que de décider où vont les 2665 clients ambigus, on demande aux données :

- entraîner un modèle **uniquement sur les extrêmes non ambigus** — satisfaction 1–2 contre 4–5 (4378 clients), avec les seules features légitimes ;
- contrôler qu'il sépare ces extrêmes : **80.1%** d'exactitude en validation croisée, contre **67.1%** pour la classe majoritaire. Le modèle apprend donc quelque chose sans être parfait, ce qui est exactement le comportement attendu. *(Ce n'est pas une preuve d'absence de fuite, et l'ancienne rédaction le laissait croire en comparant ce chiffre à des exactitudes 3 classes de la littérature, qui ne sont pas comparables à un problème binaire. Le test formel de fuite est en phase 4 § 5.)* ;
- faire passer les 2665 clients à « 3 », jamais vus, à travers ce modèle.

Arbitrage empirique : 27.9% penchent détracteur, 72.1% promoteur



Résultat : 27.9% des « 3 » ressemblent à des détracteurs, contre 72.1% qui ressemblent aux 4–5. Le bloc rejoint les **Passifs**.

La règle de décision, et son asymétrie assumée. La seule question posée au modèle d'arbitrage est : *les clients à 3 sont-ils majoritairement des détracteurs* ? Si la part dépasse 50%, le bloc rejoint les Détracteurs ; sinon il reste **Passif**. Promoteur n'est volontairement **pas** une issue possible, et il faut le dire plutôt que de le laisser deviner : une note de 3 sur 5 est le milieu exact de l'échelle, et rien dans le NPS ne permet de promouvoir un milieu d'échelle au rang de promoteur. La mesure sert donc à **écarter l'hypothèse de l'énoncé** (« ces clients sont des détracteurs »), pas à choisir librement parmi les trois classes ; le complément de 72.1% dit que ces clients ressemblent aux 4–5, pas qu'ils en sont.

La décision n'est pas sur le fil : il manque 22.1% de part détractrice pour que le bloc bascule. Un test automatisé verrouille cette valeur, parce qu'un glissement silencieux de ce seul chiffre changerait le NPS de référence de plus de 60 points.

1.3 L'autre décision, celle du « 4 » — et d'où viennent vraiment les +63 points. L'arbitrage des « 3 » ne fait pas tout le chemin, et présenter M3 comme « arbitré par les données » sans plus de précision laisserait croire le contraire. Le passage de -42.0 à +21.3 se décompose en **deux décisions distinctes**, dont une seule est empirique :

Étape	Décision	Nature	NPS
Départ	grille de l'énoncé : 1–2–3 Détracteur, 4 Passif, 5 Promoteur	hypothèse de l'énoncé	-42.0
1	les 2 665 clients à « 3 » quittent les Détracteurs pour les Passifs	mesurée (§ 1.2)	-4.1
2	les clients à « 4 » passent de Passif à Promoteur	hypothèse d'échelle , assumée ici	+21.3

La décision 2 n'est pas mesurée, et voici l'argument qui la porte. Sur une échelle à 5 points, la note 4 correspond à « satisfait » et se projette vers 8–9 sur une échelle en 10 points, donc dans la bande Promoteur du NPS (9–10) ou à sa frontière immédiate (8 = Passif). Deux éléments font pencher vers Promoteur : **aucun** client noté 4 n'a quitté l'opérateur, exactement comme les 5 ; et Elero et al. (2026) traitent de la même façon la borne haute de leur échelle. Deux réserves, qui restent entières : une échelle à 5 points n'a pas de position pour le « 8 » qui sépare Passif de Promoteur, et la note 4 concerne 25% de la base — c'est donc la décision la plus lourde de l'étude après celle du « 3 ». La variante prudente, qui laisse le « 4 » chez les Passifs, est **M2** (-4.1) : elle est calculée, publiée et incluse dans l'étude de sensibilité (phase 5 § 5.1), précisément pour qu'un lecteur qui refuse cette hypothèse puisse lire le travail avec son propre mapping.

1.4 Le piège évité — la circularité. Il était tentant d'étiqueter *chaque* « 3 » par la prédiction du modèle. Ce serait une faute : la cible deviendrait une fonction des features, et le modèle aval réapprendrait sa propre sortie — une circularité cousine de la fuite *Churn Score*. On tranche donc **le bloc** par la mesure agrégée, et on conserve la probabilité individuelle comme simple **indicateur métier** (« ce passif a un profil de détracteur à X % »), affiché dans l'application, jamais utilisé à l'entraînement.

1.5 Ce que l'énoncé suggérerait et qu'on a refusé. Enrichir la cible par Churn Value ou CLTV transformerait le projet en modèle de churn déguisé (phase 2 § 4). Enrichir par l'ancienneté rendrait la cible fonction d'une feature (même circularité qu'en 1.4). Le **bruit réaliste** suggéré par l'énoncé est traité en phase 5 § 5.2 comme test de robustesse. Ce bruit est **ordinal**, et ce choix est le point de la section : dans une vraie enquête, un promoteur mal mesuré devient passif bien plus souvent que détracteur, et ce sont les notes du milieu qui sont les plus fragiles. On bascule donc vers une classe adjacente dans 80 % des cas et vers la classe opposée dans 20 %, avec une exposition trois fois plus forte pour les clients notés 3. Un bruit uniforme — toutes les erreurs équiprobables, y compris promoteur → détracteur — est le moins réaliste possible sur une cible ordonnée ; il est conservé en second, comme borne pessimiste.

1.6 Limites du label construit. L'énoncé demande explicitement de discuter les limites de la cible qu'on fabrique (§ 4.5). Trois, par ordre de gravité.

- 1. La satisfaction n'est pas une intention de recommander.** Le NPS mesure la propension à recommander à un tiers, la satisfaction une expérience vécue. Les deux corrélient, ils ne s'identifient pas. C'est l'hypothèse 1 de la phase 1, et elle est indépasseable avec ce dataset.
- 2. La note a probablement été rendue cohérente avec le churn par le producteur du dataset.** Le fait fondateur — 100 % de départs chez les 1–2, 0 % chez les 4–5 — ne s'observe dans aucune enquête réelle. L'interprétation retenue ailleurs dans l'étude (« le churn est une conséquence de l'insatisfaction ») n'est pas la seule compatible : l'hypothèse inverse, une note dérivée du statut de churn, l'est tout autant et nous ne pouvons pas les départager. Conséquence à assumer : notre modèle NPS et un modèle de churn partagent largement leurs drivers, et les performances mesurées ici sont une **borne haute**. Sur de vraies réponses, plus bruitées, il faut s'attendre à une dégradation de l'ordre de celle que mesure le test de bruit d'étiquettes (phase 5 § 5.2).
- 3. Seule la note 3 apporte une information non réductible au churn.** Parmi les 2665 clients à « 3 », 2236 sont restés et les autres sont partis : c'est le seul endroit du jeu où la note et le statut de départ ne se déduisent pas l'un de l'autre. C'est aussi pourquoi l'arbitrage de ce bloc a reçu autant d'attention, et pourquoi la classe Passif est la plus difficile à prédire (phase 5 § 2).

2. Nettoyage

- Manquants structurels (`Offer`, `Internet Type`) → catégorie explicite (phase 2 § 3).
- Manquants accidentels (aucun dans ce dataset, mais l'application en produira) → imputation **dans le pipeline** (médiane / modalité la plus fréquente), jamais en amont, pour qu'aucune statistique calculée sur tout le jeu ne fuie vers l'évaluation.
- Aberrantes conservées ; colonnes constantes supprimées.

3. Feature engineering — chaque variable adossée à une hypothèse

3.1 Variables brutes retenues et pourquoi.

Variable(s)	Pourquoi elle devrait aider à prédire le NPS
Contract	l'engagement contractuel est le premier marqueur de la relation ; un client mensuel peut partir demain
Tenure in Months	l'ancienneté cumule l'expérience vécue ; les premiers mois concentrent les déceptions
Offer	un geste commercial reçu signale à la fois une politique de l'opérateur et un client jugé fragile
Number of Referrals	recommander est le comportement que le NPS mesure : proxy comportemental direct, observable, antérieur
Monthly Charge	le prix payé chaque mois ; la perception du rapport qualité-prix passe par lui
Total Charges / Total Revenue	l'intensité économique cumulée de la relation
Total Refunds / Total Extra Data Charges / Total Long Distance Charges	traces d'incidents de facturation et d'usages hors forfait — sources classiques de friction
Avg Monthly GB Download / Avg Monthly Long Distance Charges	intensité d'usage : un gros consommateur subit davantage les défauts de qualité
Internet Service / Internet Type	la fibre et le DSL n'ont ni la même qualité ni la même clientèle (Elero : vitesse et stabilité = premiers drivers)
Services optionnels (sécurité, sauvegarde, protection, support premium, streaming, données illimitées)	la composition du bouquet dit ce que le client attend et ce qu'il a accepté de payer
Phone Service / Multiple Lines	périmètre du service souscrit
Paperless Billing	proxy d'engagement numérique cité par l'énoncé
Payment Method	le mode de paiement révèle l'automatisation de la relation (auto-pay) et le canal préféré

3.2 Variables dérivées.

Variable dérivée	Hypothèse métier
<code>nb_services</code>	intensité de la relation commerciale : plus de services, plus de raisons de rester — ou de se plaindre
<code>charge_par_service</code>	perception du rapport qualité-prix : ce que coûte chaque service souscrit
<code>tranche_anciennete</code>	l'insatisfaction d'un nouveau client (attentes déçues) n'a pas la même nature que celle d'un ancien (usure)
<code>a_recu_offre</code>	un geste commercial a-t-il été fait ? (indicateur binaire, complémentaire du type d'offre)
<code>a_eu_remboursement</code>	trace d'un incident de facturation reconnu par l'opérateur
<code>a_frais_supplementaires</code>	trace d'un dépassement de forfait — friction tarifaire
<code>revenu_par_mois</code>	intensité économique moyenne de la relation, indépendante de l'ancienneté
<code>a_parraine</code>	proxy comportemental direct de la recommandation, donc du NPS lui-même ; comportement passé observable, pas une conséquence de la note
<code>paiement_automatique</code>	auto-pay (énoncé § 4.3) : un paiement automatisé signale une relation installée et sans friction

3.3 Variables retenues. 18 numériques : `Number of Referrals`, `Tenure in Months`, `Avg Monthly Long Distance Charges`, `Avg Monthly GB Download`, `Monthly Charge`, `Total Charges`, `Total Refunds`, `Total Extra Data Charges`, `Total Long Distance Charges`, `Total Revenue`, `nb_services`, `charge_par_service`, `a_recu_offre`, `a_eu_remboursement`, `a_frais_supplementaires`, `revenu_par_mois`, `a_parraine`, `paiement_automatique`. **17 catégorielles :** `Offer`, `Phone Service`, `Multiple Lines`, `Internet Service`, `Internet Type`, `Online Security`, `Online Backup`, `Device Protection Plan`, `Premium Tech Support`, `Streaming TV`, `Streaming Movies`, `Streaming Music`, `Unlimited Data`, `Contract`, `Paperless Billing`, `Payment Method`, `tranche_anciennete`.


3.4 Variables écartées et pourquoi. Démographie (`Gender`, `Age`, `Senior Citizen`, `Married`, `Dependents...`) et géographie (`Zip Code`, `Latitude`, `Longitude`, `Population`, `City`) : hors modèle par décision d'équité (phase 2 § 4), **coût chiffré** en phase 5 § 5 ; `Referred a Friend` : redondant avec `Number of Referrals` (recodé en `a_parraine`) ; identifiants et constantes.

3.5 Colinéarité (VIF).

Variable	VIF
Total Revenue	> 1 000 (identité comptable)
Total Charges	> 1 000 (identité comptable)
Total Refunds	> 1 000 (identité comptable)
Total Extra Data Charges	> 1 000 (identité comptable)
Total Long Distance Charges	> 1 000 (identité comptable)
revenu_par_mois	86.5
Monthly Charge	68.2
nb_services	19.4
Avg Monthly Long Distance Charges	18.7
Tenure in Months	7.7
charge_par_service	4.9
a_eu_remboursement	4.3
a_frais_supplementaires	3.1
a_parraine	2.1
Number of Referrals	2.1
Avg Monthly GB Download	1.3
paiement_automatique	1.0
a_recu_offre	1.0

Total Charges, Total Revenue, Total Refunds, Total Extra Data Charges et Total Long Distance Charges sont liés par une **identité comptable** (le revenu total est la somme des autres) : VIF infini par construction. **Décision : conservées.** Les modèles linéaires du catalogue sont régularisés (L2), ce qui absorbe la colinéarité ; les arbres y sont insensibles. La colinéarité brouillerait l'interprétation coefficient par coefficient : l'interprétabilité (phase 5 § 6) lit donc les variables corrélées comme un bloc.

4. Déséquilibre des classes



Deux déséquilibres se superposent. Dans la base, le Passif domine (38%) et le Détracteur est minoritaire (20%). Mais le modèle apprend sur les **répondants**, où le biais de réponse (phase 4 § 2) inverse la structure : 33% de Détracteurs, 7% de Passifs seulement. Le Passif est donc à la fois la classe la plus fréquente à l'évaluation et la plus rare à l'entraînement — c'est **elle** qu'un modèle abandonne en premier, et c'est ce que le rappel par classe surveille (phase 5 § 1).

Stratégies comparées (baseline logistique, S3/M3, évaluées sur les silencieux) :

Stratégie	Kappa	Macro-F1	Rappel Dét.	Rappel Passif	Rappel Prom.	Précision Dét.
aucune (logistique non pondérée)	0.365	0.380	0.764	0.012	0.793	0.399
pondération de classes 'balanced' (retenue)	0.370	0.497	0.785	0.323	0.559	0.395
sur-échantillonnage aléatoire	0.372	0.498	0.776	0.329	0.560	0.396
SMOTE (k=5)	0.357	0.489	0.737	0.323	0.565	0.388
sous-échantillonnage aléatoire	0.323	0.479	0.691	0.418	0.446	0.372

Décision : pondération de classes balanced. Elle est appliquée à tous les modèles du catalogue qui l'acceptent (ou par `sample_weight` équivalent). Le rééchantillonnage (SMOTE, sur/sous-échantillonnage) n'apporte pas de gain systématique ici et fabrique des clients synthétiques dans un espace one-hot où l'interpolation n'a pas de sens métier ; la pondération est plus simple, sans hyperparamètre, et laisse les données intactes.

5. Pipeline de préparation

Tout est encapsulé dans un Pipeline scikit-learn (`ColumnTransformer`) :

- numériques → imputation médiane → `StandardScaler` **pour les modèles à distance ou linéaires seulement** (logistique, ordinale, ridge, KNN, SVM, MLP, Naive Bayes) ; rien pour les arbres — deux préparations, pas un compromis ;
- catégorielles → imputation mode → `OneHotEncoder(handle_unknown='ignore')` , pour que l'application tolère une modalité jamais vue sans planter ;
- CatBoost reçoit les catégorielles **brutes** : c'est l'hypothèse qu'il teste (phase 4 § 3).

Rien n'est transformé hors du pipeline. C'est ce qui rend le modèle sérialisable d'un bloc et exempt de fuite entraînement → test. Le découpage répondants / silencieux est décrit en phase 4 § 2.

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Cible M3 : 1–2 Détracteur, 3 Passif, 4–5 Promoteur	arbitrage empirique des « 3 » ; NPS dans la fourchette sectorielle	§ 1.2, test <code>test_mappings_et_nps</code>
Aucun étiquetage individuel des « 3 » par le modèle	évite la circularité cible ← features	§ 1.3, test <code>test_indicateur_profil_detracteur_reserve_aux_ambigus</code>
Neuf variables dérivées, chacune avec son hypothèse	exigence § 4.3 de l'énoncé	§ 3.2
Colinéarité conservée	régularisation L2 et arbres insensibles ; lecture par blocs	§ 3.5
Pondération de classes plutôt que rééchantillonnage	comparaison de cinq stratégies ; simplicité	§ 4
Préprocessing dans le Pipeline uniquement	aucune fuite de statistiques ; sérialisation d'un bloc	§ 5, test <code>test_modele_tolere_entrees_vides_et_modalites_inconnues</code>

Phase 4 — Modélisation

En bref. Le découpage 15/85 est **simulé avec un biais de non-réponse** (trois scénarios, du plus optimiste au plus réaliste) et le modèle est toujours entraîné sur les répondants, évalué sur les silencieux dont on connaît la vérité. **Quinze modèles en sept familles**, couvrant les trois formulations de l'énoncé, sont comparés sur 3 scénarios × 3 mappings, puis réglés et sélectionnés **par validation croisée sur les répondants** — sans jamais regarder les silencieux — avec une règle de parcimonie. Retenu : **logistique ordinale** (réglée). Le meilleur kappa CV brut était ridge seuils ; le meilleur sur les silencieux est ridge seuils. L'écart entre ce que la validation croisée promet (0.61) et ce que les silencieux donnent (0.38) est le coût mesuré du biais de réponse.

1. Les trois formulations, instanciées et comparées

Formulation	Comment elle traite l'ordre des classes	Modèles du catalogue
Classification nominale	ne le voit pas ; l'ordre est réintroduit par la métrique (kappa quadratique) et par la pondération	logistique, arbre, forêt, boosting (×5), KNN, SVM, MLP, Naive Bayes
Classification ordinale	l'impose par la structure : une variable latente et deux seuils	logistique ordinale (mord, all-threshold)
Régression 1–5 puis seuillage	exploite la note fine à l'entraînement ; seuils optimisés sur le kappa	ridge + seuils, HGB + seuils

Résultat par formulation (meilleur modèle de chaque, S3/M3) :

Formulation	Modèles	Meilleur (CV)	Kappa CV IPW	Kappa silencieux	Macro-F1 silencieux
classification nominale	12	catboost	0.616	0.366	0.440
classification ordinale	1	logistique_ordinale	0.597	0.384	0.490
régression 1-5 puis seuillage	2	ridge_seuils	0.621	0.387	0.478

Lecture, en deux temps, parce que les deux colonnes ne disent pas la même chose.

En validation croisée sur les répondants, les trois formulations sont indiscernables. Les kappas tiennent dans un mouchoir et l'écart-type entre plis est du même ordre que l'écart entre formulations : il n'y a rien à conclure de ce tableau seul, et prétendre le contraire serait lire du bruit.

Sur les silencieux, celles qui exploitent l'ordre prennent un avantage — et il est surtout dans le profil par classe, pas dans le kappa. Le gain de kappa est faible ; le vrai écart est le rappel de la classe **Passif**, que les formulations ordinales tiennent et que les meilleures formulations nominales écrasent. C'est cohérent : le kappa quadratique pénalise peu une erreur d'un cran, donc un modèle qui abandonne le milieu de l'échelle peut afficher un bon kappa tout en étant inutilisable pour qui veut distinguer un passif d'un détracteur.


⚠ **La comparaison est asymétrique et il faut le savoir en la lisant** : la colonne « nominale » retient le meilleur de douze modèles, la colonne « ordinale » n'en a qu'un seul (mord LogisticAT) et la régression à seuils deux. Comparer le meilleur de douze à un unique candidat avantage mécaniquement le premier — c'est donc une borne **basse** de ce que l'ordre apporte. Le choix final se fait sur la mesure (§ 6), et l'évaluation métier (phase 5 § 3) vérifie que le classement des appels n'en souffre pas.

2. Protocole de validation 15 % / 85 %

Un `train_test_split` stratifié rate l'intention de l'énoncé : les répondants à une enquête NPS ne sont pas un échantillon aléatoire — les très mécontents et les très contents répondent plus. C'est du **MNAR** (*missing not at random*). L'avantage rare de ce dataset : on connaît la satisfaction des 100 %, donc on peut simuler le biais et **mesurer ce qu'il coûte**, ce qu'aucun praticien ne peut faire en production.

Scénario	Mécanisme de réponse	Ce qu'il mesure
S1 — MCAR	15 % tirés au hasard	borne haute optimiste
S2 — MAR	propension = f(ancienneté, facture dématérialisée, engagement)	biais de covariables seul
S3 — MNAR	propension = f(covariables, écart de la satisfaction au centre)	le cas réaliste, retenu pour le modèle final

Dans tous les cas : **entraînement sur les 15 % répondants, évaluation sur les 85 % silencieux**. Validation croisée stratifiée à 5 plis à l'intérieur des 15 % pour le réglage et la sélection.



Scénario	Taux de réponse	Satisf. base	Satisf. répondants	Extrêmes base	Extrêmes répondants
S1_MCAR	15.2%	3.245	3.230	36.8%	39.7%
S2_MAR	15.4%	3.245	3.316	36.8%	33.0%
S3_MNAR	15.3%	3.245	3.373	36.8%	71.4%

Sous S3, la part des notes extrêmes passe de **37% dans la base à 71% chez les répondants** : le modèle apprend sur une population qui ne ressemble pas à celle sur laquelle il sera appliqué. Kannan et al. (2022) observent un taux de réponse réel de **2,6 %** : notre 15 % est optimiste.

Repondération par l'inverse de la propension (IPW). La propension à répondre est **estimée** comme un praticien le ferait — logistique P(répondre | covariables) sur les 7 043 clients, hypothèse MAR (poids entre 0.51 et 3.26). Ces poids servent (a) à pondérer la validation croisée pour estimer la performance sur la population entière plutôt que sur les répondants, (b) en test comme poids d'entraînement : κ 0.384 sans $\rightarrow$ 0.371 avec, **retenu : sans IPW**. L'effet est faible parce que la propension vraie sous S3 dépend de la satisfaction, que l'estimation MAR ne voit pas : c'est la limite structurelle de l'IPW face au MNAR. Le cadre canonique serait le modèle de sélection de Heckman, qui exige une restriction d'exclusion introuvable ici.


3. Le catalogue — quinze modèles, sept familles, une raison chacun

L'énoncé demande une baseline puis au moins deux familles justifiées ; les quatre études de référence en comparent six à neuf. On ne compare pas des algorithmes pour remplir un tableau : chaque modèle est là pour tester un **hypothèse** sur les données.

Famille	Modèle	Formulation	Pourquoi il est là	Hypothèse testée	Référence
Linéaire	logistique	classification nominale	la baseline exigée par l'énoncé (§ 4.5) ; ses coefficients sont une explication exacte et additive	les frontières entre classes sont proches du linéaire dans l'espace des variables standardisées	Chong et al. 2023 (LR 79,2 % sur ce dataset) ; Kannan et al. 2022
Linéaire	logistique_ordinale	classification ordinale	la formulation ordinale demandée au § 2 : un seul vecteur de coefficients et deux seuils (mord, all-threshold), trois fois moins de paramètres que la multinomiale	l'ordre Détracteur < Passif < Promoteur est porté par une seule direction latente	énoncé § 5 (mord) ; Agresti, Categorical Data Analysis
Régression + seuils	ridge_seuils	régression 1-5 puis seuillage	la troisième formulation de l'énoncé, en version linéaire : régression ridge sur la note 1-5, puis deux seuils optimisés sur le kappa quadratique	la note fine 1-5 contient plus d'information que les trois classes et mérite d'être exploitée à l'entraînement	énoncé § 2 (« regression with thresholding »)
Régression + seuils	hgb_seuils	régression 1-5 puis seuillage	même formulation avec un régresseur non linéaire (gradient boosting d'histogrammes)	la relation variables $\rightarrow$ note comporte des interactions qu'un modèle linéaire ne capte pas	énoncé § 2
Arbres et bagging	arbre_decision	classification nominale	des règles lisibles par un non-technicien ; le modèle de Kannan et al. et le CART de Mustafa et al. ; témoin de surapprentissage d'un arbre seul	quelques règles contractuelles (contrat, ancienneté, parrainage) suffisent à séparer les classes	Kannan et al. 2022 ; Mustafa et al. 2021
Arbres et bagging	foret_aleatoire	classification nominale	l'ensemble d'arbres « calibré » cité par l'énoncé ; co-premier chez Elero et al. sur une cible NPS à trois classes ; robuste avec peu de réglage	le bagging stabilise les arbres sur un petit échantillon bruité mieux que le boosting ne le fait	Elero et al. 2026 ; Chong et al. 2023
Boosting	hist_gradient_boosting	classification nominale	le boosting natif de scikit-learn, sans dépendance ; premier sur neuf algorithmes chez Elero et al. (modèle 3, trois classes)	des interactions et non-linéarités sont apprenables avec ~1 000 lignes	Elero et al. 2026
Boosting	lightgbm	classification nominale	cité par l'énoncé ; croissance feuille par feuille et régularisation fine (min_child_samples) — le boosting le plus déployé en production tabulaire	même famille que HGB : l'écart entre les deux mesure la variance d'implémentation, pas une différence de méthode	énoncé § 4.5 ; Ke et al. 2017
Boosting	xgboost	classification nominale	cité par l'énoncé ; le boosting de référence de la littérature churn (meilleur modèle chez Chong et al., 79,7 %)	idem LightGBM ; régularisation L2 des feuilles utile sur petit échantillon	Chong et al. 2023 ; Chen & Guestrin 2016
Boosting	catboost	classification nominale	cité par l'énoncé ; encode nativement les catégorielles par statistiques de cible ordonnées — le seul modèle du catalogue qui ne passe pas par le one-hot	le one-hot fait perdre de l'information sur Offer, Contract, Payment Method ; un encodage cible ordonné fait mieux sur petit échantillon	énoncé § 4.5 ; Prokhorenkova et al. 2018
Boosting	adaboost	classification nominale	le boosting historique ; meilleur modèle chez Lalwani et al. (81,7 %, cité par Chong) ; teste un boosting d'arbres courts	repondérer les erreurs suffit, sans gradient ni régularisation	Chong et al. 2023 (revue) ; Elero et al. 2026
Voisinage et noyaux	knn	classification nominale	présent dans les quatre études de référence ; « les clients qui se ressemblent se notent pareil » ; standardisé, sinon dominé par les montants	la structure locale (voisinage) porte l'information ; si KNN égale les arbres, des « jumeaux » existent dans les données — signal de fuite	Chong et al. 2023 ; Elero et al. 2026 ; Mustafa et al. 2021
Voisinage et noyaux	svm_rbf	classification nominale	noyau gaussien, marge maximale ; présent chez Elero, Chong, Mustafa ; probabilités par Platt interne	la marge maximale est plus robuste au bruit d'étiquettes que les modèles qui ajustent chaque point	Elero et al. 2026 ; Chong et al. 2023
Réseau de neurones	mlp	classification nominale	le meilleur modèle de Kannan et al. (F 0,876) et l'ANN d'Elero et al. ; deux couches, arrêt précoce	une représentation apprise bat les variables construites à la main — attendu faux sur ~1 000 lignes, inclus pour trancher, pas pour décorer	Kannan et al. 2022 ; Elero et al. 2026
Probabiliste	naive_bayes	classification nominale	le GaussianNB de Mustafa et al. ; coût nul ; témoin bas	l'indépendance conditionnelle des variables — fausse ici (colinéarité mesurée en phase 3), ce qui rend sa contre-performance informative	Mustafa et al. 2021

Réglages par défaut : pondération de classes `balanced` partout (ou `sample_weight` équivalent) ; préparation adaptée à chaque famille (phase 3 § 5). **Écartés avec argument** : CORAL / CORN (apprentissage profond ordinal, sans objet sur ~1 000 lignes) ; les modèles de fondation sont évalués à part (§ 8) car ils ne s'entraînent pas au sens classique.

4. La grille : 3 scénarios × 3 mappings × 15 modèles



Effet du mapping (scénario réaliste S3, kappa sur les silencieux) :

Famille	Modèle	M1	M2	M3
Arbres et bagging	arbre_decision	0.203	0.316	0.324
Arbres et bagging	foret_aleatoire	0.221	0.320	0.357
Boosting	adaboost	0.209	0.325	0.341
Boosting	catboost	0.219	0.330	0.366
Boosting	hist_gradient_boosting	0.219	0.302	0.343
Boosting	lightgbm	0.227	0.317	0.358
Boosting	xgboost	0.233	0.326	0.373
Linéaire	logistique	0.230	0.344	0.370
Linéaire	logistique_ordinale	0.247	0.351	0.376
Probabiliste	naive_bayes	0.196	0.316	0.320
Régression + seuils	hgb_seuils	0.252	0.353	0.365
Régression + seuils	ridge_seuils	0.212	0.342	0.387
Réseau de neurones	mlp	0.177	0.291	0.329
Voisinage et noyaux	knn	0.190	0.269	0.291
Voisinage et noyaux	svm_rbf	0.210	0.319	0.342

Effet du biais de non-réponse (cible M3) :

Modèle	S1_MCAR	S2_MAR	S3_MNAR	Chute S1→S3
arbre_decision	0.339	0.370	0.324	-0.016
foret_aleatoire	0.397	0.405	0.357	-0.040
adaboost	0.401	0.392	0.341	-0.060
catboost	0.406	0.401	0.366	-0.039
hist_gradient_boosting	0.329	0.322	0.343	+0.014
lightgbm	0.358	0.352	0.358	-0.000
xgboost	0.391	0.388	0.373	-0.019
logistique	0.416	0.409	0.370	-0.046
logistique_ordinale	0.407	0.402	0.376	-0.030
naive_bayes	0.354	0.355	0.320	-0.035
hgb_seuils	0.369	0.367	0.365	-0.004
ridge_seuils	0.404	0.410	0.387	-0.016
mlp	0.324	0.332	0.329	+0.005
knn	0.322	0.321	0.291	-0.031
svm_rbf	0.383	0.380	0.342	-0.041

Deux lectures, dont une seule est un résultat.

La chute de S1 à S3 est le résultat scientifique du protocole. Presque tous les modèles perdent en passant d'une non-réponse aléatoire à une non-réponse qui dépend de la satisfaction : c'est le coût mesuré du biais de réponse, et il est comparable d'une colonne à l'autre puisque la cible ne change pas.

En revanche, le kappa plus élevé de M3 ne prouve pas que M3 est « la meilleure cible ». Les kappas ne sont **pas comparables entre mappings** : déplacer le milieu ambigu change la difficulté de la tâche elle-même, ainsi que la prévalence des classes. Un mapping qui rendrait la cible triviale obtiendrait le meilleur kappa sans rien démontrer. Ce tableau se lit donc **colonne par colonne** (quel modèle pour un mapping donné), jamais ligne par ligne pour départager les mappings. Ce qui justifie M3 est ailleurs : l'arbitrage empirique du bloc des « 3 » (phase 3 § 1.2), l'hypothèse d'échelle explicite sur le « 4 » (phase 3 § 1.3), et la **stabilité du sens des effets** d'un mapping à l'autre (phase 5 § 5.1).


5. Porte de contrôle : y a-t-il une fuite ?

Diagnostic	Valeur	Seuil	Verdict
Exactitude maximale observée (toute la grille)	0.655	0,85 (littérature : Elero 0,77 ; Chong 0,80)	✅ dans la fourchette honnête
Écart arbres – linéaire (S1, M3)	-0.012	+0,30 (signature Mustafa et al.)	✅ aucun écart suspect

Un troisième indice, qualitatif : le KNN — qui détecterait des « jumeaux » — est parmi les plus faibles. Aucune fuite.

6. Réglage et sélection — sans regarder le jeu de test

6.1 Hyperparamètres. Recherche aléatoire (RandomizedSearchCV, 5 plis stratifiés sur les répondants, score = kappa quadratique), espaces modestes à dessin : sur ~1 000 lignes, le risque de surajuster la recherche dépasse vite le gain. La version réglée n'est retenue que si elle gagne plus de 0,005 de kappa **en validation croisée pondérée** — jamais sur les silencieux.




Modèle	Famille	Configurations	Kappa CV IPW défaut	Kappa CV IPW réglé	Gain CV	Silencieux défaut	Silencieux réglé	Version retenue	Meilleurs paramètres
logistique	Linéaire	12	0.546	0.573	+0.027	0.370	0.371	réglée	C=0.09006280202112786
logistique_ordinale	Linéaire	12	0.587	0.597	+0.010	0.376	0.384	réglée	alpha=7.305271542664457
ridge_seuils	Régression + seuils	—	0.621			0.387		par défaut (pas d'espace de réglage)	—
hgb_seuils	Régression + seuils	—	0.581			0.365		par défaut (pas d'espace de réglage)	—
arbre_decision	Arbres et bagging	12	0.486	0.516	+0.030	0.324	0.341	réglée	min_samples_leaf=20.0, max_depth=3.0
foret_aleatoire	Arbres et bagging	10	0.578	0.589	+0.011	0.357	0.362	réglée	n_estimators=600.0, min_samples_leaf=5.0, max_features=0.5, max_depth=10.0
hist_gradient_boosting	Boosting	12	0.569	0.592	+0.024	0.343	0.369	réglée	min_samples_leaf=20.0, max_leaf_nodes=15.0, max_iter=100.0, learning_rate=0.03, l2_regularization=0.5
lightgbm	Boosting	12	0.571	0.605	+0.034	0.358	0.375	réglée	reg_lambda=0.0, num_leaves=7.0, n_estimators=400.0, min_child_samples=20.0, learning_rate=0.02
xgboost	Boosting	12	0.594	0.598	+0.004	0.373	0.366	par défaut	reg_lambda=5.0, n_estimators=400.0, min_child_weight=5.0, max_depth=6.0, learning_rate=0.05
catboost	Boosting	6	0.597	0.616	+0.020	0.366	0.366	réglée	learning_rate=0.06, l2_leaf_reg=3.0, iterations=400.0, depth=4.0
adaboost	Boosting	8	0.521	0.537	+0.017	0.341	0.341	réglée	n_estimators=200.0, learning_rate=1.0
knn	Voisinage et noyaux	8	0.468	0.487	+0.019	0.291	0.295	réglée	weights=distance, n_neighbors=101.0
svm_rbf	Voisinage et noyaux	8	0.539	0.560	+0.021	0.342	0.347	réglée	gamma=0.03, C=3.0
mlp	Réseau de neurones	8	0.539	0.611	+0.072	0.329	0.354	réglée	learning_rate_init=0.003, hidden_layer_sizes=(64,), alpha=0.0001
naive_bayes	Probabiliste	—	0.525			0.320		par défaut (pas d'espace de réglage)	—

6.2 Règle de sélection, fixée avant de regarder les résultats. 1. Critère : kappa quadratique en validation croisée sur les répondants, **pondéré IPW** (estimation de la performance sur la population), départage par macro-F1 CV. 2. **Parcimonie** (« one standard error rule », Hastie, Tibshirani & Friedman, ESL § 7.10) : parmi les modèles à moins d'un écart-type (entre plis) du meilleur, le plus simple l'emporte. L'ordre de simplicité est fixé **a priori**, publié ci-dessous, et repose sur trois critères pris dans cet ordre : (a) le nombre de paramètres libres ajustés sur les données ; (b) le modèle produit-il nativement des **probabilités de classe** — la liste d'appels et l'application en dépendent entièrement ; (c) l'explication est-elle exacte et lisible (coefficients) ou approchée et coûteuse (SHAP, permutation).

Rang	Modeles	Ce qui justifie ce rang
1	logistique, logistique ordinale, naive bayes	un vecteur de coefficients ajusté directement, probabilités natives, explication exacte et additive
2	arbre decision, ridge seuils	coefficients simples mais une étape d'ajustement supplémentaire (deux seuils optimisés a posteriori sur le kappa) ou une structure d'arbre à lire
3	knn	aucun paramètre appris mais aucune explication intrinsèque : la prédiction dépend de l'échantillon entier
4	adaboost, foret aleatoire, hgb seuils	ensemble d'arbres (centaines de règles) ; explication par SHAP, approchée et coûteuse
5	catboost, hist gradient boosting, lightgbm, svm rbf, xgboost	ensemble d'arbres régularisé à nombreux hyperparamètres, ou noyau non linéaire sans explication native
6	mlp	réseau de neurones : représentation apprise, aucune lecture directe des poids

Ce tableau tranche le cas le plus disputé de la sélection. La logistique ordinale et la régression ridge à seuils ont la **même paramétrisation** — un vecteur de coefficients et deux seuils — et pourtant elles ne sont pas au même rang. Deux raisons, et la seconde est décisive : les seuils de la régression sont **optimisés a posteriori** sur le kappa, ce qui est une étape d'ajustement de plus ; et surtout, la régression à seuils **n'a pas de probabilités de classe natives** — les siennes sont approchées par la distance aux seuils. Or toute la couche de décision de ce projet (classement des appels par P(Détracteur), calibration, seuils d'équité, affichage client) repose sur ces probabilités. Ce n'est donc pas une préférence esthétique pour un modèle linéaire, c'est une contrainte d'usage. 3. Les 85 % silencieux sont le **test final** : rapportés pour tous, utilisés pour aucun choix.



Rang CV	Modèle	Famille	Formulation	Version	Simplicité	Kappa CV IPW	± (plis)	Macro-F1 CV	Dans la marge	Kappa silencieux	Macro-F1 sil.	Rappel Dét. sil.	Rappel Passif sil.	Rang silencieux
1	ridge_seuils	Régression + seuils	régression 1-5 puis seuillage	par défaut (pas d'espace de réglage)	2	0.621	0.035	0.534	✓	0.387	0.478	0.572	0.344	1
2	catboost	Boosting	classification nominale	réglée	5	0.616	0.053	0.603	✓	0.366	0.440	0.833	0.135	7
3	mlp	Réseau de neurones	classification nominale	réglée	6	0.611	0.063	0.529	✓	0.354	0.370	0.743	0.000	10
4	lightgbm	Boosting	classification nominale	réglée	5	0.605	0.057	0.585	✓	0.375	0.464	0.820	0.188	3
5	logistique_ordinale	Linéaire	classification ordinale	réglée	1	0.597	0.037	0.514	✓	0.384	0.490	0.629	0.481	2
6	xgboost	Boosting	classification nominale	par défaut	5	0.594	0.054	0.563	✓	0.373	0.427	0.805	0.099	4
7	hist_gradient_boosting	Boosting	classification nominale	réglée	5	0.592	0.050	0.576	✓	0.369	0.447	0.816	0.156	6
8	foret_aleatoire	Arbres et bagging	classification nominale	réglée	4	0.589	0.054	0.574	✓	0.362	0.420	0.835	0.091	9
9	hgb_seuils	Régression + seuils	régression 1-5 puis seuillage	par défaut (pas d'espace de réglage)	4	0.581	0.049	0.534		0.365	0.446	0.651	0.183	8
10	logistique	Linéaire	classification nominale	réglée	1	0.573	0.038	0.562		0.371	0.498	0.805	0.326	5
11	svm_rbf	Voisinage et noyaux	classification nominale	réglée	5	0.560	0.036	0.570		0.347	0.447	0.806	0.177	11
12	adaboost	Boosting	classification nominale	réglée	4	0.537	0.037	0.576		0.341	0.466	0.823	0.246	12
13	naive_bayes	Probabiliste	classification nominale	par défaut (pas d'espace de réglage)	1	0.525	0.034	0.508		0.320	0.477	0.818	0.399	14
14	arbre_decision	Arbres et bagging	classification nominale	réglée	2	0.516	0.054	0.574		0.341	0.466	0.823	0.246	13
15	knn	Voisinage et noyaux	classification nominale	réglée	3	0.487	0.016	0.490		0.295	0.345	0.778	0.000	15

6.3 Ce que le tableau dit. - Meilleur kappa CV brut : **ridge seuils** (0.621). Dans la marge de parcimonie (≥ 0.586) : ridge seuils, catboost, mlp, lightgbm, logistique ordinale, xgboost, hist gradient boosting, foret aleatoire. **Retenu : logistique ordinale** (réglée), le plus simple de la marge. - Corrélation de rang entre ce que la CV promet et ce que les silencieux donnent : $\rho = \mathbf{0.79}$ (0.79 sans pondération IPW). La CV sur les répondants classe correctement les modèles malgré le biais. - Meilleur sur les silencieux : **ridge seuils** (0.387) ; le modèle retenu fait 0.384 (rang 2 sur 15). L'écart (-0.003) est le prix d'une sélection honnête ; choisir a posteriori serait choisir sur le test. - Pour le modèle retenu, la CV promet 0.610 et les silencieux donnent 0.384 : **+0.238**. En production, personne ne verrait cet écart. C'est la quantité à retenir de toute la phase. - **Ce que les quinze modèles apprennent sur les données** : tous les kappas sur les silencieux tiennent dans une bande étroite (0.30–0.39). Le plafond n'est pas algorithmique, il est dans le signal : ~1 000 répondants biaisés et une cible bruitée. Changer de modèle rapporte moins que corriger le biais de réponse (groupe de contrôle, vraies réponses de la population cible, phase 6).

7. Calibration des probabilités

Les probabilités servent à prioriser des appels : un modèle mal calibré fait mal allouer le budget. Deux méthodes testées (isotonique, Platt). Résultat sur le modèle retenu, classe Détracteur :

	Brier	ECE	Rappel Passif
Non calibré	0.143	0.131	0.48
Calibré (Platt, 3 plis)	0.148	0.147	0.00

La calibration écrase la classe Passif (rappel < 0,05) : sous MNAR, les Passifs sont rares parmi les répondants et le calibrateur, ajusté sur peu de lignes, ne prédit plus jamais la classe intermédiaire. **Décision — stratégie hybride** : la **classe** vient du modèle non calibré ; la **probabilité de détraction**, seule utilisée pour classer les appels, vient du modèle calibré. Vérifié par test automatisé (aucune classe sous 0,05 de rappel). La courbe de fiabilité et sa lecture sont en phase 5 § 2.

8. Modèles de fondation tabulaires (bonus § 4.5)

Consigne de l'énoncé : « *do not frame it as the winner if it is not* ». Même découpage S3/M3, mêmes features préparées que la logistique, CPU.

Modèle	Versión du paquet	Kappa	Macro-F1	Rappel Dét.	Rappel Passif	Ajustement (s)	Inférence (s)	ms / client	Statut
TabICL	2.2.0	0.379	0.377	0.789	0.000	5.6	206.48	34.63	évalué
TabPFN 2.5	9.0.0								indisponible — licence PriorLabs non acceptée sur cette machine : le téléchargement d
TabPFN v2	9.0.0								indisponible — écarté pour raison de coût, pas d'accès : l'inférence sur processeur r
logistique ordinale — modèle retenu		0.384	0.490	0.629			0.18	0.03	référence
lightgbm — meilleur gradient boosting		0.375	0.464			0.9	0.36	0.06	référence

- **TabICL** ne dépasse pas le modèle retenu en kappa (0.379 contre 0.384), mais son macro-F1 est de 0.377 contre 0.490 et son rappel Passif de **0.000**. Inférence : 34.6 ms par client, soit 1173× le modèle retenu et 572× lightgbm.
- **Le compromis demandé, chiffré**. Face à lightgbm, le meilleur gradient boosting du catalogue : kappa 0.379 contre 0.375, macro-F1 0.377 contre 0.464, ajustement 5.6 s contre 0.9 s, inférence 206.5 s contre 0.36 s sur les mêmes 5963 clients. Le modèle de fondation peut gagner un peu de kappa et perdre nettement en macro-F1, pour un coût d'inférence sans commune mesure.

TabPFN 2.5 n'a pas pu être évalué. Cause : licence PriorLabs non acceptée sur cette machine : le téléchargement des poids exige un compte et une clé API (TABPFN_TOKEN) Ce qu'il faudrait faire : créer un compte sur ux.priorlabs.ai, accepter la licence, puis renseigner TABPFN_TOKEN dans .env Trace brute : dépôt Hugging Face à accès contrôlé (gated) : l'acceptation des conditions d'utilisation et huggingface-cli login sont requis pour télécharger les poids — OSError: [WinError 10038] Une opération a é **TabPFN v2 n'a pas pu être évalué.** Cause : écarté pour raison de coût, pas d'accès : l'inférence sur processeur rejoue le jeu d'entraînement à chaque prédiction et demande plusieurs minutes pour 5 963 clients, sans changer la conclusion que TabICL établit déjà Ce qu'il faudrait faire : évaluable en une commande sur une machine avec GPU, ou sur un échantillon (NPS_FONDATION_N) Trace brute : ``

Avantages. Aucun réglage d'hyperparamètres, aucun entraînement au sens classique — l'apprentissage se fait en contexte, au moment de la prédiction. Sur un jeu de cette taille, cela donne en quelques secondes un kappa du même ordre que quinze modèles réglés, ce qui en fait un excellent **étalon de première heure** : si un modèle de fondation sans réglage atteint votre score, votre pipeline n'a pas encore trouvé de signal que lui n'a pas.

Limites, et la principale n'est pas la latence. - **La classe Passif est abandonnée** (rappel 0.000) : le modèle se comporte en classifieur binaire Détracteur / Promoteur. Le kappa quadratique le pénalise peu — une erreur d une classe coûte quatre fois moins qu une erreur de deux — ce qui est exactement pourquoi un bon kappa ne suffit pas à valider un modèle sur cette cible. - **La comparaison n'est pas à protocole égal, et c'est en défaveur du modèle de fondation.** Les quinze modèles du catalogue reçoivent une pondération de classes `balanced` (phase 3 § 4) ; ni TabICL ni TabPFN n'exposent ce réglage. La classe minoritaire est donc désavantagée chez eux par construction, et une part de l'écart de macro-F1 vient de là, pas du modèle. - **Latence d'inférence de plusieurs ordres de grandeur supérieure** : le jeu d'entraînement est rejoué à chaque prédiction. - **Aucune explication native** : ni coefficients, ni SHAP d'arbre. Il faudrait passer par une explication par permutation, coûteuse — alors que les drivers et l'affichage client sont au cœur du livrable (phase 5 § 6). - **Dépendance à des poids externes** et à leurs conditions d'accès : voir la note ci-dessus. - **Domaine de validité borné** : environ 50 000 lignes et 2 000 features pour TabPFN-2.5. Nos 5963 clients et 63 features sont largement dedans — ce n'est donc pas un cas limite, et cette limite ne joue pas ici. - *L'empreinte mémoire n'a pas été mesurée et n'est donc pas avancée comme argument.*

Compromis. Pour un scoring mensuel de 7 000 clients, la latence reste acceptable. Pour l'application interactive, pour l'explication client par client et pour tenir la classe Passif, le modèle retenu reste préférable — et c'est la conclusion, même si elle est moins spectaculaire.

Sur le nom de version. le paquet `tabpfm 9.x` sert le modèle TabPFN-2.5 ; son dépôt de poids s'appelle `Prior-Labs/tabpfm_3_5` (numérotation interne). Ce dépôt est **public** : ce qui bloque est l'acceptation de la licence PriorLabs, qui demande un compte et une clé API — pas un contrôle d'accès Hugging Face, contrairement à ce qu'une première lecture de l'erreur laissait croire.

9. Verbatims synthétiques et fusion texte (bonus § 4.4)

Génération. 7043 notes de dernier contact, une par client. Sources : `gabarit_stochastique_seed (6010) + claude_code_agent (1033)`. Chaque note a été produite par l'API Anthropic (claude-opus-5), prompt versionné `prompts/verbatim_v1.txt`. Le chemin API Anthropic reste prêt (`src/verbatim.py` : détection de `ANTHROPIC_API_KEY`, appels par lots à `claude-opus-5` avec reprise, prompt `prompts/verbatim_v1.txt`, même schéma). Conditionnement : tonalité tirée de la classe M3 avec **25 % de bruit** et cas contre-intuitifs, ancrage sur contrat, ancienneté, internet, offre, parrainages, facture, support premium, streaming. Concordance tonalité / classe observée : **83.2%** (plafond théorique 83.3%).

Représentation et fusion. TF-IDF (1-2 grammes) + logistique pour le texte seul ; fusion tardive (moyenne pondérée des probabilités, poids choisi par validation croisée sur les répondants) et fusion précoce (SVD à 20 composantes du TF-IDF concaténée aux features tabulaires). Des plongements de phrases (sentence-transformers) ou une classification zero-shot par LLM sont possibles mais n'ont pas été retenus : sur du texte synthétique fabriqué à partir de la classe, ils ne mesureraient rien de plus.

Configuration	Kappa	Macro-F1	Rappel Détracteur
Tabulaire seul (référence)	0.384	0.490	0.629
Texte seul (TF-IDF 1-2 grammes + logistique)	0.390	0.430	0.533
Fusion tardive (poids texte 0.3, choisi par CV)	0.391	0.380	0.778
Fusion précoce (tabulaire + SVD 20 du TF-IDF)	0.412	0.510	0.800

Ce que le texte apporte — et pourquoi le chiffre ne prouve rien. Le texte encode la classe par construction (tonalité tirée de la classe, bruit 25 %). Tout gain est un artefact du protocole de génération : il valide la chaîne, pas la valeur de vrais verbatims. Le dispositif démontre que la chaîne texte → fusion fonctionne ; il ne dit rien de la valeur de vrais verbatims, qui pourraient être bien plus riches (incidents non enregistrés) ou bien plus pauvres (notes laconiques). C'est le « *spot when the added complexity is not worth it* » de l'énoncé : **pas de composante texte en production sur la base de cette seule expérience** ; l'application la montre en démonstration, avec l'avertissement.

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Trois formulations instanciées, arbitrées par la mesure	l'énoncé demande une justification, pas un a priori	§ 1
Découpage 15/85 par propension simulée, MNAR retenu	les répondants ne sont pas aléatoires ; le coût du biais est mesuré	§ 2, tests du protocole
IPW estimée sous MAR, effet mesuré	ce qu'un praticien peut faire ; limite face au MNAR explicitée	§ 2
Quinze modèles, sept familles, une hypothèse chacun	au-delà du minimum de l'énoncé ; alignés sur les quatre études de référence	§ 3
Sélection par CV sur les répondants, pondérée IPW, avec parcimonie	les silencieux sont le test : les utiliser pour choisir serait une fuite de sélection	§ 6
Retenu : logistique ordinale (réglée)	le plus simple des modèles à moins d'un écart-type du meilleur kappa CV	§ 6.3
Stratégie de décision hybride si la calibration écrase une classe	vérifié, pas supposé ; test automatisé	§ 7
Modèles de fondation et texte : évalués, non retenus en production	consigne d'honnêteté de l'énoncé ; gain texte artificiel par construction	§ 8, § 9

Phase 5 — Évaluation

En bref. Le modèle retenu (logistique ordinaire, réglée) atteint un kappa quadratique de **0.384** sur les 5963 clients silencieux, rappelle **63%** des détracteurs et garde les trois classes vivantes. Sur 500 appels, **51%** touchent un vrai détracteur contre 18% au hasard (lift $\times 2.8$) — 18 585 € de gain net par campagne à hypothèses constantes. Le NPS des silencieux est estimé à **+4** (IC 95 % +2 à +5) pour une vérité de +20. Les drivers sont contractuels (engagement, ancienneté, parrainage, prix) et stables quel que soit le mapping. Le modèle rappelle moins bien les jeunes détracteurs (47% vs 73% pour les 60+) alors qu'il n'a aucune variable d'âge : les features retenues **reconstruisent** l'âge (AUC 0.92). Une mitigation par seuils est chiffrée ; l'arbitrage est remonté au métier.

1. Évaluation technique — jamais une métrique globale sans son détail par classe



Pourquoi ces métriques.

Métrique	Rôle	Pourquoi elle est là
Kappa quadratique pondéré	métrique principale de sélection	cible ordonnée : une erreur de deux crans (Promoteur prédit Détracteur) doit coûter plus qu'une erreur d'un cran ; le kappa quadratique le fait, l'exactitude et le F1 ne le font pas ; corrigé du hasard
Macro-F1	départage	moyenne non pondérée des F1 des trois classes : une classe minoritaire abandonnée fait chuter le score, ce que l'exactitude masque
Exactitude équilibrée	lecture	moyenne des rappels par classe ; même logique que le macro-F1 côté rappel
Rappel / précision / F1 par classe	obligatoire à chaque publication	la règle du projet : le Détracteur est la classe qui compte pour le métier, le Passif celle qu'un modèle abandonne en premier
AUC un-contre-tous et AP (Détracteur)	qualité du classement	l'application classe les clients par P(Détracteur) : l'AUC et l'aire précision-rappel mesurent ce classement indépendamment du seuil ; l'AP est préférée sous déséquilibre
Brier et ECE (Détracteur)	qualité des probabilités	les probabilités servent à allouer un budget d'appels : Brier mesure leur erreur quadratique, l'ECE l'écart entre probabilité annoncée et fréquence observée
Précision@K, rappel@K, lift	métrique métier	la question de l'équipe rétention : « sur les K clients qu'on peut appeler ce mois-ci, combien sont réellement des détracteurs ? »
Exactitude brute	rapportée pour montrer qu'elle trompe	prédire toujours Passif donne ~0,43 ; l'énoncé la disqualifie comme critère

Résultat sur les 5963 silencieux (modèle entraîné sur 1080 répondants, S3, cible M3) :


Métrique globale	Valeur
Kappa quadratique pondéré	0.384
Macro-F1	0.490
Exactitude équilibrée	0.511
AUC un-contre-tous (macro) · AUC Détracteur · AP Détracteur	0.677 · 0.820 · 0.462
Exactitude brute	0.486 — rapportée pour montrer qu'elle trompe : 0,43 en prédisant toujours « Passif »

Classe	Précision	Rappel	F1	Effectif
Détracteur	0.438	0.629	0.516	1083
Passif	0.473	0.481	0.477	2590
Promoteur	0.547	0.423	0.477	2290



- Le **Détracteur est rappelé à 63%** — c'est la classe qui compte pour le métier. Sa précision est de 44% : le modèle appelle large. C'est le bon arbitrage pour une campagne de rétention où manquer un détracteur coûte plus qu'un appel inutile ; la précision@K en tient compte.
- Le **Passif est la classe la plus difficile** (rappel 48%) : milieu ambigu par définition, rare à l'entraînement (phase 3 § 4). Cohérent avec Elero et al. (2026), où la classe neutre est aussi la moins bien prédite.
- La courbe précision-rappel est plus informative que la ROC sous déséquilibre : le Détracteur a une AP de 0.46 pour un taux de base de 0.18.
- Référence : la baseline logistique fait 0.370 de kappa sur les mêmes silencieux (le modèle retenu est au-dessus).

2. Calibration : ce que la courbe de fiabilité révèle



Les deux courbes sont **sous la diagonale** : le modèle surestime P(Détracteur), calibré ou non (ECE 0.15 après Platt). Cause : le calibrateur est ajusté sur les répondants, où les détracteurs sont sur-représentés par le biais MNAR ; il apprend le taux de base des répondants, pas celui de la population silencieuse. **La calibration sur un échantillon biaisé calibre vers la mauvaise population** — le problème MNAR réapparaît à un autre étage. Conséquence : le **classement** des clients par P(Détracteur) reste valide (l'ordre est préservé, AUC 0.82), mais la **valeur absolue** ne doit pas être lue comme une fréquence — l'application l'affiche. Correction possible en production : recalibrer sur les premières vraies réponses de la population cible (phase 6 § 4).

3. Évaluation métier

La vraie question n'est pas « quel taux de bonnes réponses » mais « **sur les K clients que l'équipe peut appeler ce mois-ci, combien sont réellement des détracteurs ?** »

K appels	Précision@K	Rappel@K	Lift	Détracteurs captés
100	59.0%	5.5%	×3.25	59
250	54.8%	12.7%	×3.02	137
500	51.2%	23.6%	×2.82	256
750	50.0%	34.6%	×2.75	375
1000	48.0%	44.3%	×2.64	480
1500	43.9%	60.9%	×2.42	659
2000	40.6%	74.9%	×2.23	811

Taux de base (part de détracteurs parmi les silencieux) : **18.2%**. À K = 500, **51.2% des clients appelés sont de vrais détracteurs — 2.8× mieux qu'au hasard**.

Traduction en euros. Hypothèses (paramètres dans `config.yaml`, à valider avec l'équipe rétention) : coût d'un appel 12 €, valeur d'un client retenu 450 €, taux de succès 25%.


	Campagne ciblée par le modèle	Campagne aléatoire de même taille
Coût	6 000 €	6 000 €
Clients retenus (estimés)	64.0	—
Gain net	22 800 €	4 215 €
ROI	3.80	—

Apporté par le modèle : 18 585 € par campagne de 500 appels, à hypothèses constantes.

CLTV en couche de décision. Interdite comme feature (sortie de modèle IBM : elle fuit), CLTV est légitime pour pondérer *qui appeler* parmi les détracteurs prédits : c'est un choix métier, pas une information sur la cible. Gómez-Vargas et al. (EJOR 2025) montrent qu'une CLV individuelle bat une CLV moyenne pour cibler une campagne. L'application propose cette pondération en option.

4. Simuler le NPS des 85 % silencieux

Simuler le NPS des 85 % silencieux (§ 2 de l'énoncé)



	NPS
Répondants — ce que l'opérateur observe	+26.9
Silencieux — prédit par le modèle (IC 95 % bootstrap)	+3.6 [+1.6 ; +5.3]
Silencieux — vrai (connu ici seulement)	+20.2
Base complète — prédit	+4.2

Classe	Prédit (silencieux)	Vrai (silencieux)
Détracteur	26.1%	18.2%
Passif	44.2%	43.4%
Promoteur	29.7%	38.4%

Lecture : le modèle sous-estime le NPS des silencieux de 16.6 pts (écart marqué, la vérité est hors de l'intervalle bootstrap : celui-ci ne couvre que l'aléa d'échantillonnage, pas le biais du modèle). Composition par classe : trop de Détracteurs ; trop peu de Promoteurs ; la part de Passifs est juste. Ce sont les conséquences du biais de réponse — le modèle apprend sur des répondants polarisés et une pondération de classes qui rééquilibre le Passif — et le NPS, différence de deux parts, cumule les erreurs sur les Détracteurs et les Promoteurs. À rapporter avec l'intervalle et cette réserve ; la correction passe par les premières vraies réponses de la population cible (phase 6 § 4). **Par segment** (silencieux) :

Segment	Clients	NPS prédit	NPS vrai	Part Dét. prédite	Part Dét. vraie
Contrat mensuel	3087	-40.9	-1.3	49.0%	32.1%
Contrat 1–2 ans	2876	51.5	43.4	1.5%	3.2%
Ancienneté < 12 mois	1815	-36.1	-2.6	49.5%	33.8%
Ancienneté ≥ 24 mois	3266	28.1	32.7	11.3%	9.1%
Fibre	2510	-31.4	2.0	42.7%	27.8%
DSL	1454	4.7	26.1	18.4%	13.3%
Sans internet	1278	80.8	50.9	0.0%	4.5%

Le classement des segments par NPS est respecté (contrats mensuels et clients récents sont bien les plus critiques) ; les niveaux sont déformés — effet du biais de réponse.

Peut-on corriger l'estimateur ? Estimer la composition d'une population à partir d'un classifieur est un problème connu — la *quantification* (Forman 2005 ; González et al. 2017). Quatre estimateurs ont été testés, avec la matrice de confusion que le praticien peut estimer — par validation croisée sur les répondants :

Estimateur	Détracteurs	Passifs	Promoteurs	NPS	Écart à la vérité
CC — Classify & Count — parts des classes prédites (estimateur retenu, affiché)	26.1%	44.2%	29.7%	+3.6 [+2 ; +5]	-16.6
PCC — Probabilistic CC — moyenne des probabilités	31.2%	32.4%	36.4%	+5.1	-15.1
ACC — Adjusted CC — inversion de la matrice de confusion (CV répondants)	19.3%	64.1%	16.6%	-2.7 [-9 ; +3]	-22.9
PACC — Probabilistic ACC — idem avec les probabilités moyennes	27.0%	34.0%	39.1%	+12.1	-8.1
Vérité (connue ici)	18.2%	43.4%	38.4%	+20.2	—

Le plus proche est PACC (-8.1 pts) ; **aucun ne retrouve la vérité**. La raison est structurelle : les corrections ACC et PACC supposent que la matrice de confusion $P(\text{prédit} | \text{vrai})$ est la même chez les répondants et chez les silencieux (décalage d'a priori pur). Sous MNAR, ce n'est pas le cas — dans une même classe, les répondants sont plus « extrêmes » que les silencieux, donc mieux classés. Une correction statistique à partir des seuls répondants ne peut pas compenser ce biais : c'est l'argument le plus précis en faveur de vraies réponses tirées de la population cible (phase 6 § 4).

5. Robustesse et sensibilité

5.1 Sensibilité au mapping de la cible (énoncé § 4.1). Kappa du modèle retenu sous les trois mappings (S3) : $M1\ 0.247 \cdot M2\ 0.351 \cdot M3\ 0.376$. **▲ Ces trois nombres ne sont pas comparables** : déplacer le milieu ambigu change la difficulté de la tâche et la prévalence des classes. Les mettre côte à côte pour désigner un gagnant serait une erreur de lecture — il faut donc comparer autre chose, et deux choses seulement se comparent.


(a) Le sens des effets. Le modèle **retenu** est réajusté sous chaque mapping sur les mêmes répondants, et l'on regarde si une variable qui pousse vers la détraction sous M3 y pousse encore sous M1 et M2. Sur les **12 variables les plus influentes, 12 conservent le même sens d'effet** sous les trois mappings. Aucune ne change de signe : la lecture métier — engagement, ancienneté, parrainage, prix — ne dépend pas du mapping choisi. C'est l'amplitude qui varie, pas la direction, et c'est la seule stabilité qu'on pouvait espérer démontrer ici.

Variable	M1	M2	M3
Contract	+0.196	+0.221	+0.253
Phone Service	-0.228	-0.259	-0.233
Online Security	-0.324	-0.313	-0.226
Internet Service	+0.053	+0.060	+0.138
Ancienneté	+0.023	+0.060	+0.086
Facture mensuelle	-0.066	-0.070	-0.068
Total Charges	+0.060	+0.056	+0.060
Streaming Music	+0.044	+0.047	+0.052
Total Long Distance Charges	-0.030	-0.029	-0.046
Unlimited Data	+0.028	+0.026	+0.046
Device Protection Plan	+0.012	+0.022	+0.046
Premium Tech Support	+0.056	+0.054	+0.040

(b) L'effet métier. C'est ce qui change vraiment pour l'équipe rétention : la part de clients prédits détracteurs, et la qualité de la liste d'appels.

Mapping	Taux de détracteurs réel	Détracteurs prédits	Précision@500	Lift
M1	61.6%	29.3%	82.2%	×1.33
M2	18.2%	27.6%	46.0%	×2.53
M3	18.2%	26.1%	51.0%	×2.81

Le mapping ne change pas seulement un score : il change la **taille du problème**. Sous M1, 62% de la base est détractrice contre 18% sous M3. La précision@500 paraît donc bien plus élevée sous M1 (82%) que sous M3 (51%) — mais c'est un mirage : le **lift**, qui rapporte la précision au taux de base, dit l'inverse (×1.33 contre ×2.81). Sous M1, viser les détracteurs n'apporte presque rien puisqu'ils sont déjà majoritaires ; c'est une raison métier supplémentaire de ne pas retenir ce mapping, indépendante de toute considération de score.




5.2 Bruit d'étiquettes (énoncé § 4.1 : « adding realistic noise »). On corrompt une part des étiquettes d'entraînement et on mesure sur les silencieux, dont les étiquettes restent vraies.

Le mot important de la consigne est **realistic**, et il commande la forme du bruit. Une note d'enquête ne se trompe pas au hasard : un promoteur mal mesuré devient passif bien plus souvent que détracteur, et ce sont les notes du milieu qui sont les plus fragiles. Le bruit **ordinal** appliqué ici bascule donc vers une classe adjacente dans 80 % des cas et vers la classe opposée dans 20 %, en exposant trois fois plus les clients notés 3. Le bruit **uniforme** — toutes les erreurs équiprobables, promoteur → détracteur compris — est rapporté à côté comme borne pessimiste, et non comme scénario crédible.

Bruit	Forme	Étiquettes modifiées	Kappa	Macro-F1	Rappel Dét.	Rappel Passif	Rappel Prom.
0%	ordinal	0	0.384	0.490	0.629	0.481	0.423
5%	ordinal	57	0.379	0.484	0.575	0.518	0.396
5%	uniforme	67	0.384	0.485	0.593	0.520	0.388
10%	ordinal	112	0.376	0.479	0.542	0.523	0.398
10%	uniforme	120	0.385	0.487	0.573	0.558	0.363
20%	ordinal	220	0.358	0.468	0.532	0.548	0.355
20%	uniforme	245	0.354	0.467	0.510	0.609	0.307
30%	ordinal	306	0.361	0.475	0.520	0.575	0.352
30%	uniforme	362	0.311	0.436	0.351	0.693	0.271

À 30% d'étiquettes corrompues, le kappa passe de 0.384 à **0.361** sous bruit ordinal (−0.023) et à 0.311 sous bruit uniforme (−0.073). La dégradation est graduelle : le modèle ne s'effondre pas quand la cible est bruitée, ce qui importe d'autant plus que le label construit ici est probablement plus propre qu'une vraie enquête (phase 3 § 1.6). L'écart entre les deux formes (0.049) mesure ce que coûterait un bruit non ordinal — un scénario improbable, gardé comme borne basse.

5.3 Ablation de features — ce que chaque bloc coûte ou rapporte, modèle retenu, S3/M3, silencieux :



Configuration	Variables	Kappa	Macro-F1	Rappel Dét.	Rappel Passif	AUC Dét.	Δ kappa
base (retenue)	35	0.384	0.490	0.629	0.481	0.818	+0.000
+ démographie	42	0.393	0.491	0.642	0.471	0.825	+0.009
+ géographie (lat, lon, population)	38	0.382	0.490	0.621	0.479	0.818	-0.002
+ démographie + géographie	45	0.386	0.490	0.639	0.471	0.825	+0.001
- variables dérivées	26	0.367	0.481	0.608	0.481	0.806	-0.017
- parrainage (Number of Referrals, a_parraine)	33	0.357	0.481	0.597	0.501	0.796	-0.027
- Offer et a_recu_offre	33	0.383	0.488	0.629	0.478	0.819	-0.001
- Contract	34	0.357	0.481	0.560	0.501	0.796	-0.027
- top-3 proxies d'âge (Avg Monthly GB Download, Streaming Music, Monthly Charge)	32	0.375	0.484	0.609	0.488	0.817	-0.009


Trois lectures. **Démographie et géographie** : ajouter la démographie change le kappa de +0.009, la géographie de -0.002, les deux de +0.001 — c'est le **coût mesuré du choix d'équité** (énoncé § 4.7 : « Removing a feature often costs accuracy. Make the trade-off explicit »). Il est assumé : un gain de cet ordre ne justifie pas de décider sur l'âge, le genre ou le code postal, et § 7 montre que le modèle retrouve de toute façon ces attributs par proxies. **Parrainage** : retirer Number of Referrals et a_parraine change le kappa de -0.027 — c'est le driver le plus proche de la cible sans être une fuite (comportement passé observable). **Variables dérivées** : -0.017 — elles portent une part réelle du signal. Retirer Contract : -0.027 ; retirer Offer : -0.001.

6. Drivers de détraction

Méthode : coefficients × valeur (exact, additif) — la même que dans l'application, client par client. **Agrégation** : contributions sommées par variable d'origine (modalités one-hot regroupées ; blocs parrainage, ancienneté, facture mensuelle). **Périmètre** : 5963 clients silencieux ; segments d'ancienneté « < 12 mois » et « ≥ 24 mois » (la bande 12–24 mois est volontairement écartée pour contraster) ; accès « Fibre » et « DSL » (câble et sans internet non représentés).

Un mot sur l'agrégation, parce qu'elle change la lecture du tableau. L'encodage one-hot crée une colonne par modalité et le modèle répartit l'effet entre elles ; lire Online Security = No et Online Security = Yes comme deux variables de signes opposés n'a aucun sens, ce sont les deux faces d'une seule. Les colonnes d'une même variable d'origine sont donc **sommées avant tout classement**, et les blocs métier redondants sont regroupés — le parrainage réunit Number of Referrals et a_parraine, dont les coefficients se compensaient et faisaient apparaître « avoir parrainé » comme un facteur de risque. Après agrégation, l'effet net du parrainage est protecteur, conformément au texte de cette section.

Les 15 variables qui pèsent le plus sur la détraction (rouge : pousse vers la détraction · vert : protège)



Variable	Importance	Sens de l'effet	Nature
Contract	0.7112	▲ « Month-to-Month » pousse vers la détraction	catégorielle
Facture mensuelle	0.7110	▲ une valeur élevée pousse vers la détraction	numérique
Online Security	0.5603	▲ « Yes » pousse vers la détraction	catégorielle
Total Charges	0.4013	▼ une valeur élevée protège	numérique
Phone Service	0.2903	▲ « No » pousse vers la détraction	catégorielle
Parrainage	0.2893	▼ une valeur élevée protège	numérique
Ancienneté	0.2856	▲ « 0-6m » pousse vers la détraction	catégorielle
Total Long Distance Charges	0.2833	▲ une valeur élevée pousse vers la détraction	numérique
Internet Service	0.2423	▲ « Yes » pousse vers la détraction	catégorielle
Total Revenue	0.2284	▼ une valeur élevée protège	numérique
Paperless Billing	0.2230	▲ « Yes » pousse vers la détraction	catégorielle
Avg Monthly Long Distance Charges	0.2061	▼ une valeur élevée protège	numérique
Streaming Music	0.1722	▲ « No » pousse vers la détraction	catégorielle
Internet Type	0.1544	▲ « Cable » pousse vers la détraction	catégorielle
Avg Monthly GB Download	0.1485	▼ une valeur élevée protège	numérique
Device Protection Plan	0.1432	▲ « No » pousse vers la détraction	catégorielle
Unlimited Data	0.1330	▲ « Yes » pousse vers la détraction	catégorielle
Payment Method	0.1235	▲ « Bank Withdrawal » pousse vers la détraction	catégorielle
Online Backup	0.1171	▲ « No » pousse vers la détraction	catégorielle
Streaming Movies	0.0983	▲ « Yes » pousse vers la détraction	catégorielle

Lecture du sens : ▲ = pousse vers la détraction, ▼ = protège. Pour une variable numérique, le sens est celui de l'effet d'une valeur élevée ; pour une variable catégorielle, la modalité en cause est nommée, car « Contract » ne pousse ni ne protège en soi — c'est « Month-to-Month » qui pousse. ⚠ La colonne « contribution moyenne » ne donne PAS le sens : pour une variable numérique standardisée elle vaut environ zéro par construction.

Ce que dit le modèle, et ce que disent les données. Un coefficient et une statistique descriptive ne répondent pas à la même question. Les confronter est le seul moyen de savoir quand on peut lire un driver comme un conseil d'action.

Variable	Effet dans le modèle (toutes choses égales)	Association brute observée	
Contract	▲ « Month-to-Month » pousse vers la détraction	32.1% de détracteurs pour « Month-to-Month » contre 1.2% pour « Two Year »	✅ concordent
Facture mensuelle	▲ une valeur élevée pousse vers la détraction	22.2% de détracteurs dans le quart le plus élevé de Monthly Charge contre 7.5% dans le quart le plus bas	✅ concordent
Online Security	▲ « Yes » pousse vers la détraction	21.3% de détracteurs pour « No » contre 10.7% pour « Yes »	⚠️ divergent
Total Charges	▼ une valeur élevée protège	9.3% de détracteurs dans le quart le plus élevé de Total Charges contre 30.9% dans le quart le plus bas	✅ concordent
Phone Service	▲ « No » pousse vers la détraction	écart brut négligeable entre modalités (18.2% contre 17.7%)	— rien à conclure
Parrainage	▼ une valeur élevée protège	3.7% de détracteurs dans le quart le plus élevé de Number of Referrals contre 22.1% dans le quart le plus bas	✅ concordent
Ancienneté	▲ « 0-6m » pousse vers la détraction	36.9% de détracteurs pour « 0-6m » contre 5.7% pour « 4a+ »	✅ concordent
Total Long Distance Charges	▲ une valeur élevée pousse vers la détraction	8.0% de détracteurs dans le quart le plus élevé de Total Long Distance Charges contre 29.1% dans le quart le plus bas	⚠️ divergent
Internet Service	▲ « Yes » pousse vers la détraction	21.9% de détracteurs pour « Yes » contre 4.5% pour « No »	✅ concordent
Total Revenue	▼ une valeur élevée protège	9.5% de détracteurs dans le quart le plus élevé de Total Revenue contre 31.9% dans le quart le plus bas	✅ concordent

⚠️ **Sur 2 variable(s), l'effet du modèle et l'association brute pointent en sens contraires.** Ce n'est pas une anomalie à corriger, c'est une distinction à comprendre, et la signaler vaut mieux que de laisser le lecteur la découvrir seul.

- **Online Security** — le modèle dit « ▲ « Yes » pousse vers la détraction », les données disent 21.3% de détracteurs pour « No » contre 10.7% pour « Yes ».
- **Total Long Distance Charges** — le modèle dit « ▲ une valeur élevée pousse vers la détraction », les données disent 8.0% de détracteurs dans le quart le plus élevé de Total Long Distance Charges contre 29.1% dans le quart le plus bas.

Comment les deux peuvent être vrais. Le coefficient est un effet *toutes choses égales par ailleurs* : il répond à « entre deux clients qui ont le même contrat, la même ancienneté, la même facture et le même nombre de services, lequel est le plus à risque ? ». L'association brute répond à une autre question : « dans la base telle qu'elle est, qui est le plus à risque ? ». Souscrire une option augmente aussi la facture et le nombre de services, qui sont dans le modèle ; une fois ces effets tenus constants, il ne reste du signal de l'option que ce qu'elle apporte en plus, et ce résidu peut changer de signe.


Ce qu'il faut en faire, côté métier. Pour cibler, c'est le modèle qui décide : il classe des clients réels avec toutes leurs caractéristiques à la fois. Pour agir, c'est l'association brute qui doit primer tant qu'aucune expérience n'a tranché : recommander de retirer une option parce que son coefficient est positif serait une faute, puisque les clients qui l'ont sont, dans les faits, deux fois moins détracteurs. C'est la raison de fond du groupe de contrôle demandé en phase 6 § 5.

(Deux rédactions antérieures étaient fautives et il vaut mieux le dire que de laisser croire que ce tableau a toujours eu cette forme. La première affichait une « corrélation entre la valeur et la contribution » : pour un modèle additif elle vaut ±1 par construction et ne mesurait rien. La seconde affichait la contribution moyenne signée : pour une variable numérique standardisée, cette moyenne vaut environ zéro, et elle faisait apparaître la facture mensuelle comme protectrice — le contraire de ce que dit le modèle. Le sens est désormais calculé selon la nature de la variable.)

Ce que le modèle dit. Les associations sont fortes et cohérentes avec la littérature sur ce dataset (Chong et al. 2023) et sur le NPS télécom (Elero et al. 2026) : **contrat sans engagement, faible ancienneté, absence de parrainage, charge mensuelle élevée** vont avec la détraction ; l'offre E ressort comme marqueur de clients déjà fragiles (phase 2 § 5.5), pas comme cause. **Le modèle établit des associations, pas des causes** : un coefficient positif est un signal, pas un levier prouvé.

Drivers par segment (énoncé § 4.6) — où chaque variable pèse le plus :

⚠️ **Ce tableau ne dit pas ce qu'on croit qu'il dit, et la nuance est importante.** Le modèle retenu est additif, sans terme d'interaction : le coefficient d'une variable est **le même dans tous les segments**. Ce qui change d'un segment à l'autre, c'est la *distribution des valeurs*, donc le poids que la variable prend dans le total. Un « driver de segment » est donc un **effet de composition**, pas un effet propre au segment, et l'affirmer autrement serait faux. La variable qui définit un segment est par ailleurs exclue de son propre classement : dire que « contrat mensuel » est le premier driver du segment « contrat mensuel » ne renseigne personne, puisqu'elle y vaut 1 partout. Pour obtenir de vrais drivers propres à chaque segment, il faudrait ajuster un modèle par segment ou introduire des interactions — c'est hors du périmètre retenu (phase 1 § 5.2).



Segment	Clients	Driver 1	Driver 2	Driver 3	Driver 4	Driver 5
Contrat mensuel	3087	Facture mensuelle (0.63)	Online Security (0.56)	Ancienneté (0.40)	Total Charges (0.37)	Phone Service (0.29)
Contrat 1–2 ans	2876	Facture mensuelle (0.80)	Online Security (0.56)	Total Charges (0.43)	Parrainage (0.38)	Total Long Distance Charges (0.31)
Ancienneté < 12 mois	1815	Contract (0.88)	Facture mensuelle (0.65)	Online Security (0.56)	Total Charges (0.47)	Total Long Distance Charges (0.30)
Ancienneté ≥ 24 mois	3266	Facture mensuelle (0.75)	Contract (0.60)	Online Security (0.56)	Total Charges (0.39)	Parrainage (0.38)
Fibre	2510	Contract (0.76)	Facture mensuelle (0.66)	Online Security (0.56)	Total Charges (0.46)	Parrainage (0.29)
DSL	1454	Contract (0.69)	Online Security (0.56)	Facture mensuelle (0.45)	Total Charges (0.35)	Total Long Distance Charges (0.30)

Chaque cellule donne la variable et son poids dans le segment. Aucun sens n'y figure, et c'est volontaire : le modèle étant additif, le sens d'une variable est le même dans tous les segments — il se lit dans le tableau global ci-dessus. Ce qui change ici, c'est uniquement l'importance relative.

Ce qu'on y lit. chez **ancienneté ≥ 24 mois** (3266 clients), la variable qui pèse le plus est **Facture mensuelle** (poids 0.75) ; chez **ancienneté < 12 mois** (1815 clients), la variable qui pèse le plus est **Contract** (poids 0.88) ; chez **fibre** (2510 clients), la variable qui pèse le plus est **Contract** (poids 0.76) ; chez **dsl** (1454 clients), la variable qui pèse le plus est **Contract** (poids 0.69) ; chez **contrat mensuel** (3087 clients), la variable qui pèse le plus est **Facture mensuelle** (poids 0.63) ; chez **contrat 1–2 ans** (2876 clients), la variable qui pèse le plus est **Facture mensuelle** (poids 0.80). Ces différences sont des effets de composition : le même coefficient appliqué à des populations dont les valeurs diffèrent. Elles restent utiles au ciblage — elles disent sur quoi insister dans quel segment — mais elles ne prouvent pas qu'une variable agit différemment ailleurs.

Actionnable ou non, et levier — construit à partir des **dix premiers drivers réels** du tableau ci-dessus, pas d'une liste écrite à la main. La distinction que demande l'énoncé est celle-ci : une entreprise peut changer un contrat, elle ne peut pas changer une démographie.

Driver (rang)	Contribution moyenne	Actionnable ?	Levier
1. Contract	+0.253	oui	proposer un engagement 12 mois avec avantage
2. Facture mensuelle	-0.068	oui	revue tarifaire, bundle
3. Online Security	-0.226	oui	inclure la sécurité en ligne dans l'offre
4. Total Charges	+0.060	non directement	conséquence du prix et de l'ancienneté — agir sur ceux-ci
5. Phone Service	-0.233	partiellement	revoir le couplage voix / internet
6. Parrainage	-0.027	indirectement	programme de parrainage, invitation ciblée
7. Ancienneté	+0.086	partiellement	parcours d'accueil renforcé les six premiers mois
8. Total Long Distance Charges	-0.046	partiellement	forfait longue distance adapté
9. Internet Service	+0.138	à qualifier avec le métier	—
10. Total Revenue	+0.038	non directement	conséquence du prix et de l'ancienneté — agir sur ceux-ci

À part, parce qu'il ne vient pas du modèle : **l'offre E** ressort de l'analyse exploratoire (phase 2 § 5.5) comme marqueur de clients déjà fragiles, et non comme cause. Elle ne figure pas dans les dix premiers drivers ; la conclusion métier est de comprendre **à qui** elle a été proposée, pas de la supprimer.

Règle de recommandation individuelle (implémentée, affichée pour chaque client) : - le levier retenu est le premier levier actionnable parmi les facteurs de risque propres au client, classés par contribution décroissante à P(Détracteur) - Engagement → Proposer un engagement 12 mois avec avantage — déclenché par : Contract - Prix → Revue tarifaire / bundle (charge par service élevée) — déclenché par : Facture mensuelle, Monthly Charge, charge_par_service - Accueil → Parcours d'accueil renforcé (client récent) — déclenché par : Ancienneté, Tenure in Months, tranche_anciennete - Support → Proposer le support technique premium ou la sécurité en ligne — déclenché par : Premium Tech Support, Online Security, Online Backup - Parrainage → Inviter au programme de parrainage — déclenché par : Parrainage, Number of Referrals, a_parraine - aucun levier actionnable chez ce client → Appel de courtoisie et diagnostic

Répartition parmi les détracteurs prédits :

Levier recommandé	Détracteurs prédits concernés
Proposer un engagement 12 mois avec avantage	1476
Revue tarifaire / bundle (charge par service élevée)	45
Proposer le support technique premium ou la sécurité en ligne	15
Appel de courtoisie et diagnostic	11
Parcours d'accueil renforcé (client récent)	9

95 % des détracteurs prédits reçoivent le même premier levier.

le premier levier est concentré parce que la base l'est : le contrat mensuel est à la fois le premier facteur de risque et la situation de la quasi-totalité des détracteurs prédits. La recommandation reste vraie, mais elle ne trie pas — c'est le SECOND levier qui différencie deux clients également mensuels, et c'est pourquoi les deux sont livrés.

Les couples (premier levier ▶ second levier) les plus fréquents :


Premier levier ▶ second levier	Clients
Proposer un engagement 12 mois avec avantage ▶ Parcours d'accueil renforcé (client récent)	734
Proposer un engagement 12 mois avec avantage ▶ Revue tarifaire / bundle (charge par service élevée)	363
Proposer un engagement 12 mois avec avantage ▶ Proposer le support technique premium ou la sécurité en ligne	305
Proposer un engagement 12 mois avec avantage ▶ Inviter au programme de parrainage	47
Revue tarifaire / bundle (charge par service élevée) ▶ Proposer un engagement 12 mois avec avantage	37
Proposer un engagement 12 mois avec avantage ▶ —	27
Appel de courtoisie et diagnostic ▶ —	11
Proposer le support technique premium ou la sécurité en ligne ▶ —	9
Parcours d'accueil renforcé (client récent) ▶ Revue tarifaire / bundle (charge par service élevée)	4
Revue tarifaire / bundle (charge par service élevée) ▶ Proposer le support technique premium ou la sécurité en ligne	4

Le second levier prend **6 valeurs distinctes** : c'est lui qui rend deux fiches client différentes, et c'est lui qu'il faut lire en priorité quand le premier est « engagement ».

heuristique dérivée des drivers — donc d'associations, pas d'un effet causal mesuré. Un levier est une hypothèse à tester en campagne, avec groupe de contrôle (10 à 20 % des ciblés non appelés).

7. Équité et biais (énoncé § 4.7)

Les variables démographiques et géographiques sont **exclues du modèle** et servent **uniquement ici**. On mesure, par sous-groupe, le rappel Détracteur (le modèle rate-t-il davantage certains détracteurs ?), la précision, et le **taux de sélection** (quelle part du groupe est prédite détracteur — c'est ce qui alloue le budget d'appels). zone = tertiles de population du code postal (proxy de densité).



Dimension	Groupe	Clients	Détracteurs réels	Taux de sélection	Rappel Dét.	Précision Dét.
Gender	Female	2939	18.4%	27.1%	64.1%	43.5%
Gender	Male	3024	18.0%	25.2%	61.7%	44.0%
Senior Citizen	No	5019	16.3%	23.9%	58.5%	39.7%
Senior Citizen	Yes	944	28.3%	37.6%	76.4%	57.5%
Married	No	3110	22.4%	31.9%	60.7%	42.7%
Married	Yes	2853	13.5%	19.8%	66.8%	45.7%
Dependents	No	4568	22.3%	30.0%	62.9%	46.7%
Dependents	Yes	1395	4.6%	13.2%	62.5%	21.7%
tranche_age	30-45	1656	16.9%	26.2%	60.0%	38.8%
tranche_age	45-60	1619	16.7%	26.6%	62.0%	39.0%
tranche_age	60+	1503	24.6%	33.4%	72.9%	53.6%
tranche_age	<30	1185	13.8%	16.0%	46.6%	40.0%
zone	densité moyenne	1998	16.1%	25.0%	62.6%	40.3%
zone	faible densité	1982	17.4%	25.0%	63.8%	44.4%
zone	forte densité	1983	21.0%	28.3%	62.4%	46.3%

Dimension	Écart max de rappel (pts)	Écart max de sélection (pts)
Gender	2.4	1.9
Senior Citizen	17.9	13.7
Married	6.2	12.1
Dependents	0.4	16.9
tranche_age	26.3	17.4
zone	1.4	3.4


Tranches d'âge fermées à gauche : « <30 » = [0 ; 30[, « 60+ » = [60 ; 120[. Les bornes disent donc exactement ce que les libellés annoncent, et le groupe « moins de 30 ans » est le même ici et dans l'audit des proxies (§ 7.2).

7.1 Ce qu'on trouve. L'écart le plus important porte sur **tranche_age : 26 points** de rappel entre le groupe le mieux servi et le moins bien servi — le modèle rappelle 47% des détracteurs de moins de 30 ans contre 73% des 60 ans et plus. C'est exactement le cas de figure que l'énoncé décrit comme inacceptable, **en sens inverse** : ce sont les jeunes détracteurs qu'on rate.

Et les écarts de taux de sélection ? Le tableau en montre de larges sur d'autres dimensions — le taux de sélection est la part du groupe qu'on prédit détractrice, donc ce qui **alloue réellement le budget d'appels**. Il faut les lire, et ils ne disent pas tous la même chose.

- **tranche_age** — sélection 33% pour « 60+ » contre 16% pour « <30 » (17 pts d'écart), alors que le taux de détracteurs *réel* passe de 14% à 25% (11 pts). L'écart de budget **ne s'explique pas entièrement** par l'écart de besoin : à examiner. ⚠ Mais le rappel diffère aussi de 26 points sur cette dimension : c'est un défaut de **détection**, pas une différence de besoin — c'est le cas de l'âge, et c'est lui qu'il faut corriger.
- **Dependents** — sélection 30% pour « No » contre 13% pour « Yes » (17 pts d'écart), alors que le taux de détracteurs *réel* passe de 5% à 22% (18 pts). L'écart de budget **suit l'écart de besoin** : le modèle appelle davantage là où il y a davantage de clients mécontents, ce qui est le comportement attendu et non un biais. Le rappel, lui, est homogène sur cette dimension.
- **Senior Citizen** — sélection 38% pour « Yes » contre 24% pour « No » (14 pts d'écart), alors que le taux de détracteurs *réel* passe de 16% à 28% (12 pts). L'écart de budget **suit l'écart de besoin** : le modèle appelle davantage là où il y a davantage de clients mécontents, ce qui est le comportement attendu et non un biais. ⚠ Mais le rappel diffère aussi de 18 points sur cette dimension : c'est un défaut de **détection**, pas une différence de besoin — c'est le cas de l'âge, et c'est lui qu'il faut corriger.

7.2 Les features « proxont »-elles les attributs protégés ? Pour chaque attribut exclu, on mesure à quel point les features du modèle permettent de le reconstruire (AUC en validation croisée) :



Attribut (exclu du modèle)	Prévalence	AUC de reconstruction	Lecture
Moins de 30 ans	19.9%	0.920	fortement restructurable
Senior (65+)	15.8%	0.874	fortement restructurable
Femme	49.3%	0.486	non restructurable
Marié(e)	47.9%	0.982	fortement restructurable
A des dépendants	23.4%	0.793	fortement restructurable
Zone de forte densité	33.3%	0.505	non restructurable

Exclure une variable ne suffit pas à ce que le modèle l'ignore. C'est la raison structurelle de l'écart d'âge : le modèle « voit » l'âge sans en avoir la colonne. Mais dire cela ne suffit pas non plus — encore faut-il nommer **quelles** variables le reconstruisent, sinon le constat ne peut être ni vérifié ni corrigé. Les voici, tirées des coefficients du classifieur de reconstruction :

Attribut	Variable du modèle	Coefficient (standardisé)
Moins de 30 ans	Avg Monthly GB Download	+2.72
Moins de 30 ans	Streaming Music_Yes	+1.92
Moins de 30 ans	Streaming Music_No	-1.90
Moins de 30 ans	Streaming Movies_No	+1.68
Moins de 30 ans	Streaming Movies_Yes	-1.66
Senior (65+)	Streaming Music_Yes	-2.95
Senior (65+)	Streaming Music_No	+2.80
Senior (65+)	Streaming Movies_No	-2.34
Senior (65+)	Streaming Movies_Yes	+2.19
Senior (65+)	Monthly Charge	+1.24
Femme	Unlimited Data_Yes	-0.26
Femme	Unlimited Data_No	+0.25
Femme	Internet Type_Fiber Optic	+0.22
Femme	Offer_Offer C	-0.21
Femme	Internet Type_Pas d'internet	-0.20
Marié(e)	a_parraine	+4.48
Marié(e)	Number of Referrals	+1.35
Marié(e)	Tenure in Months	+0.84
Marié(e)	Unlimited Data_Yes	+0.45
Marié(e)	Internet Type_Pas d'internet	+0.34
A des dépendants	a_parraine	+0.81
A des dépendants	Avg Monthly GB Download	+0.55
A des dépendants	Unlimited Data_Yes	-0.34
A des dépendants	Offer_Offer D	+0.34
A des dépendants	Unlimited Data_No	+0.32
Zone de forte densité	Offer_Offer C	+0.23
Zone de forte densité	tranche_anciennete_6-12m	+0.22
Zone de forte densité	tranche_anciennete_4a+	-0.19
Zone de forte densité	Tenure in Months	+0.17
Zone de forte densité	Unlimited Data_Yes	-0.14

Et si on les retirait ? La question mérite un chiffre, pas une opinion. Une configuration d'ablation « – top-3 proxys d'âge » (Avg Monthly GB Download, Streaming Music, Monthly Charge) a été ajoutée au tableau du § 5.3 : le kappa y varie de **-0.009** pour 32 variables conservées. Le coût est faible, mais le bénéfice l'est tout autant : l'âge reste reconstituable par les variables restantes, parce qu'il l'est par la structure même de la clientèle (les jeunes sont en contrat mensuel et récents). Retirer trois variables déplacerait le problème sans le résoudre.

Ce qu'on garde, ce qu'on retire, et pourquoi. On **garde** ces variables. Elles ne sont pas des substituts commodes de l'âge : ce sont les leviers du métier — le contrat, l'ancienneté, la facture, les services. Les retirer coûterait de la performance sans faire disparaître l'information, puisque d'autres variables corrélées prendraient le relais, et priverait la recommandation de tout contenu actionnable. On **retire** en revanche les attributs protégés eux-mêmes (âge, genre, situation familiale, code postal), ce qui empêche une décision *explicite* sur l'attribut. Ce choix est défendable, il n'est pas suffisant : il appelle l'audit ci-dessus à chaque réentraînement.

⚠ Une limite à ne pas taire. L'énoncé cite le code postal comme proxy du niveau socio-économique. Ici, la seule variable géographique disponible est la **densité de population** du code postal, et c'est elle qui est testée — pas le revenu. Aucune donnée de revenu par code postal n'a été jointe (phase 2 § 6), donc la reconstruction d'un **niveau socio-économique** par la facture ou les services **n'a pas pu être audité**. Si un enrichissement Census était un jour ajouté, il devrait l'être d'abord pour cet audit, et non pour le modèle.

7.3 Mitigation testée : un seuil de décision par tranche d'âge, calé pour que chaque groupe atteigne le rappel global (63%).

Deux précautions de méthode, sans lesquelles les chiffres seraient flatteurs. D'abord, les seuils sont appris **sur les répondants** puis appliqués aux silencieux. Les caler sur les silencieux eux-mêmes — c'est-à-dire sur la population qui sert ensuite à juger la mitigation — égaliserait les rappels *par construction* : on mesurerait l'ajustement, pas l'effet. Ensuite, le seuil retenu est le seuil **exact**, non arrondi : comme il vaut par construction la probabilité d'un détracteur précis, l'arrondir à quatre décimales excluait ce client de chaque groupe et faisait diverger le tableau global du tableau par groupe.

Politique	Écart max de rappel	Appels	Vrais détracteurs appelés	Gain net	Rappel 30-45	Rappel 45-60	Rappel 60+	Rappel <30
aucune (seuil unique, classe la plus probable)	26.3%	1556	681	57 940 €	60.0%	62.0%	72.9%	46.6%
nivellement — seuils appris sur les répondants, tous les groupes visent le rappel global	16.4%	1829	754	62 877 €	65.7%	77.1%	71.0%	60.7%
rattrapage — seul le groupe le moins bien servi (<30) est relevé	12.9%	1659	704	59 292 €	60.0%	62.0%	72.9%	60.7%
nivellement in-sample — seuils calés sur les silencieux (optimiste, pour comparaison)	0.1%	1631	684	57 378 €	63.2%	63.1%	63.1%	63.2%

La promesse et le réel. Calés sur les silencieux eux-mêmes, les seuils égalisent les rappels presque parfaitement (0.1% d'écart résiduel). Appris sur les répondants et appliqués aux silencieux — la seule façon honnête de procéder — ils ramènent l'écart de 26.3% à **16.4%**, sans l'annuler. C'est l'écart entre ce qu'une mitigation promet sur le papier et ce qu'elle tient en production.

Ce que coûte le nivellement, en euros. Il ajoute **273 appels** par campagne, soit 3 276 € au coût d'appel retenu (12 € l'appel), pour un gain net qui passe de 57 940 € à 62 877 €. Et il faut dire ce que « niveler » veut dire : ramener **tous** les groupes au rappel global **abaisse** la couverture de ceux qui étaient les mieux servis. Les seniors mécontents aujourd'hui détectés le seraient moins. Égaliser par le bas est une décision, pas une correction technique.

La variante qui ne prend rien à personne. Ne relever que le groupe le moins bien servi (« <30 »), sans toucher aux autres seuils, ramène l'écart à **12.9%** pour **103 appels** de plus (1 236 €) et un gain net de 59 292 €. C'est la politique que cette étude recommande de soumettre au métier : elle corrige l'inégalité sans dégrader la détection d'un seul groupe.

C'est un arbitrage **métier et juridique**, pas technique.

7.4 À remonter avant production. L'énoncé demande de signaler ce qui doit remonter à une équipe Expérience Client ou juridique. Trois points, formulés comme des **questions à poser**, pas comme des conclusions que la data science n'a pas qualité à rendre.

- 1. L'écart d'âge (26 points) et sa cause.** Le modèle n'utilise pas l'âge, mais le contrat, l'ancienneté et les services le reconstruisent (§ 7.2). *Question au métier* : une couverture inégale des clients mécontents selon l'âge est-elle acceptable pendant le temps qu'il faudra pour la corriger, et si non, quelle politique du § 7.3 retient-on ?
- 2. La mitigation est possible et chiffrée, mais c'est un traitement différencié selon l'âge.** *Question au juridique*, et elle n'a pas la même réponse partout : un seuil par tranche d'âge est-il un traitement différencié prohibé ou une mesure correctrice admise ? Les cadres à consulter : en France et dans l'Union européenne, la prohibition des discriminations fondées sur l'âge dans la fourniture de biens et services (loi n° 2008-496 et article 225-1 du code pénal), ainsi que les obligations du règlement européen sur l'IA pour les systèmes affectant l'accès à des services ; aux États-Unis — le dataset est californien — il n'existe pas de protection générale de l'âge en marketing grand public hors crédit (ECOA), mais le Unruh Civil Rights Act s'applique en Californie. *(L'étude ne tranche pas ce point : elle le pose, chiffré, à qui a qualité pour le faire.)*
- 3. L'audit doit être répété à chaque réentraînement.** Il l'est : le rappel Détracteur par tranche d'âge est recalculé sur les réponses cumulées de chaque mois et lève une alerte au-delà du seuil de signalement (phase 6 § 4). Le seuil est celui de la phase 1 — 10% — et le même partout dans l'étude ; une version antérieure de la carte de monitoring en annonçait 15, incohérence corrigée.

8. Limites de la règle de ciblage

Cette étude classe les clients par **risque** d'être détracteur, comme demandé. Or Ascarza (2018, *Journal of Marketing Research*) établit, par deux expériences de terrain, que cibler les clients au risque le plus élevé est inefficace : il faut cibler ceux dont la **sensibilité à l'intervention** est la plus forte — même campagne, même budget, jusqu'à 7 points de churn en moins.

On l'appelle	On ne l'appelle pas	
reste	reste	acquis — appel gaspillé
part	part	perdu d'avance — appel gaspillé
reste	part	persuadable — seul cas qui crée de la valeur
part	reste	à ne pas déranger — l'appel nuit

Les détracteurs les plus certains sont massivement des *perdus d'avance*. **On ne peut pas estimer cette sensibilité ici** : aucune campagne enregistrée, aucune assignation aléatoire (la table *offer* prouve que les offres ont été ciblées). Prétendre faire de l'uplift serait la faute reprochée à Mustafa et al. La seule chose à faire, gratuite, est en phase 6 § 5.

9. Revue du processus

Critère de succès (phase 1)	Résultat	Verdict
Précision@500 ≥ 35% et lift ≥ 2	51.2% vs 18.2% de base (×2.8)	
Gain net vs aléatoire, en euros	18 585 € par campagne	(hypothèses à valider)
Kappa au niveau de la baseline ou au-dessus	retenu logistique ordinaire : 0.384 ; baseline logistique : 0.370	
Rappel Détracteur au niveau de la baseline ou au-dessus	retenu 0.629 ; baseline 0.785	non atteint — voir la note sous le tableau
Aucune classe abandonnée	rappel Passif 0.48	
Écart d'équité mesuré, signalé si > 10 pts	26 pts sur l'âge, cause identifiée, mitigation chiffrée	signalé, arbitrage remonté

Le critère de rappel Détracteur n'est pas atteint, et ce n'est pas un oubli. La baseline logistique capte 78% des détracteurs contre 63% pour le modèle retenu. Elle y parvient en prédisant « Détracteur » beaucoup plus souvent : sa précision est plus faible et elle écrase la classe Passif. Le critère qui décide de l'usage réel est la précision à capacité d'appel fixe, et il départage dans l'autre sens — 51% pour le modèle retenu contre 54% pour la baseline. Un rappel élevé obtenu en sur-prédisant une classe n'est pas une performance : on publie le chiffre défavorable, et la raison de ne pas le suivre.

Solide : registre de fuites quantifié ; arbitrage empirique des « 3 » sans circularité ; protocole 15/85 avec coût du MNAR mesuré ; quinze modèles, sélection sans regarder le test ; calibration vérifiée ; audit d'équité avec proxys et mitigation. **Approximatif** : hypothèses économiques (placeholders) ; propension à répondre simulée ; verbatims synthétiques sans clé API ; TabPFN 2.5 non évalué, faute d'acceptation de licence PriorLabs. **Impossible avec ces données** : estimer l'effet d'un appel, et distinguer une note d'enquête d'une note construite en cohérence avec le churn (phase 3 § 1.6).

Reproductibilité — test à blanc depuis une copie vierge. Protocole : copie de *src/*, *prompts/*, *config.yaml* et *data/raw/* seuls dans un répertoire vierge, exécution de `python -m src.run`, comparaison des indicateurs clés. Durée : 1336.3 s.

Indicateur	Original	Copie vierge	Identique
NPS M1	-42.0	-42.0	✓
NPS M3	21.3	21.3	✓
part des 3 -> détracteur	0.2788	0.2788	✓
modèle retenu	logistique_ordinale	logistique_ordinale	✓
version retenue	réglée	réglée	✓
kappa final (silencieux)	0.384446	0.384446	✓
macro-F1 final	0.490177	0.490177	✓
précision@K	0.512	0.512	✓
NPS silencieux prédit	3.6	3.6	✓
écart d'équité (âge)	0.2558	0.2558	✓

Reproductible à l'identique.

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Toute métrique globale accompagnée de son détail par classe	règle du projet ; contre-exemple Kannan et al.	§ 1
Probabilités utilisées pour classer, pas pour lire une fréquence	calibrateur ajusté sur une population biaisée	§ 2
K = 500 et hypothèses économiques dans config.yaml	paramètres métier, à valider avec l'équipe	§ 3
NPS des silencieux rapporté avec intervalle et réserve de composition	excès compensés de Détracteurs et Promoteurs	§ 4
Coût de l'exclusion des démographiques et de la géographie chiffré et assumé	énoncé § 4.7 ; proxies mesurés	§ 5-3, § 7.2
Mitigation par seuils d'âge chiffrée, non appliquée par défaut	traitement différencié : décision métier/juridique	§ 7.3
Pas d'uplift modeling	aucune assignation aléatoire ; le prétendre serait une faute	§ 8

Phase 6 — Déploiement

En bref. Le modèle est persisté d'un bloc (préprocessing + modèle + calibrateur) et consommé par une application Streamlit de huit pages, filtrable, pour l'équipe rétention : liste d'appels priorisée, analyse d'un client avec ses drivers et son levier, saisie manuelle tolérante aux inconnus, verbatim en démonstration. Un monitoring implémenté surveille la dérive des entrées et des prédictions, la performance sur les nouvelles réponses d'enquête, et déclenche le réentraînement sur seuil, volume ou échéance. La décision demandée à la direction : **un groupe de contrôle non contacté** à la prochaine campagne.

1. Carte du modèle

Nom	Prédiction de catégorie NPS — clients silencieux
Version	1.1 · seed 42 · régénéré par <code>python -m src.run</code>
Modèle	logistique ordinaire (Linéaire, classification ordinaire), version réglée, dans un Pipeline scikit-learn (imputation + encodage + modèle)
Cible	M3 — Détracteur (satisfaction 1–2) · Passif (3) · Promoteur (4–5)
Données d'entraînement	1080 répondants simulés (S3 — MNAR), IBM Telco 11.1.3+
Évaluation	5963 clients silencieux, vérité connue
Kappa quadratique · macro-F1	0.384 · 0.490
Rappel / précision Détracteur	0.63 / 0.44
Décision	hybride — classe : modèle non calibré (la calibration écrasait la classe Passif) ; P(Détracteur) : modèle calibré (Platt), pour le classement des appels
Explication	coefficients × valeur (exact, additif)
Variables exclues	tout ce qui touche au churn, CLTV, démographie, géographie (phase 2 § 4)
Usage prévu	prioriser une liste d'appels de rétention mensuelle ; comprendre les drivers
Usage interdit	décider d'une offre ou d'un tarif individuel ; toute décision fondée sur un attribut protégé ; lire P(Détracteur) comme une fréquence
Limites connues	écart de rappel de 26 pts entre groupes d'âge (proxies) ; classe Passif mal rappelée ; probabilités surestimées ; propension à répondre simulée
Fichiers	<code>models/modele_final.joblib</code> (pipelines calibré, brut, de décision, métadonnées) · <code>data/processed/clients_scores.parquet</code>

2. L'application — choix de conception (énoncé § 4.8)

`docker compose up` ou `streamlit run app/app.py` · huit pages, adressables par `?page=` · toutes les valeurs sont lues dans les artefacts du pipeline, rien n'est recopié.

Page	Pour qui	Ce qu'elle permet
Synthèse	direction	les cinq chiffres, le NPS des silencieux, les trois résultats, la décision demandée
Prioriser les appels	équipe rétention	liste des silencieux classés par P(Détracteur), filtres, capacité K, pondération CLTV optionnelle, levier recommandé, export CSV
Analyser un client	conseiller	client existant ou saisie manuelle → classe, probabilités, drivers de ce client, levier ; verbatim collé (bonus, démonstration)
Données et cible	data / métier	exploration, qualité, registre de fuites, construction de la cible
Modèles et performance	data	catalogue justifié, grille, CV vs test, réglage, par classe, calibration, robustesse, fondation, texte
Drivers et équité	métier / CX	drivers globaux et par segment, leviers, audit par sous-groupe, proxies, mitigation
Suivi et méthode	data / direction	monitoring, carte du modèle, conformité à l'énoncé, reproductibilité

Pourquoi Streamlit : l'énoncé demande une interface utilisable par un responsable rétention, pas une API ; Streamlit livre une application complète en Python pur, sans front séparé, versionnable avec le pipeline. Une API (FastAPI) serait la brique suivante pour intégrer le score au CRM — hors périmètre.

Robustesse aux entrées (exigence « behave gracefully ») : chaque champ de saisie accepte « (inconnu) » ; le pipeline impute (médiane / mode) et `OneHotEncoder(handle_unknown='ignore')` absorbe toute modalité jamais vue. Testé automatiquement (`test_modele_tolere_entrees_vides_et_modalites_inconnues`).

Ce que l'application dit toujours : les probabilités servent à classer, pas à lire une fréquence ; les drivers sont des associations ; le modèle texte est une démonstration sur du texte synthétique.

Performance : modèle et données chargés une fois (`st.cache_resource`) ; explication d'un client en moins d'une seconde pour les modèles linéaires et à arbres.

3. Reproductibilité et livraison


`python -m src.run` (données → cible → 15 modèles → sélection → évaluation) · `python -m src.fondation_eval` · `python -m src.verbatims` et `python -m src.texte` · `python -m src.monitoring` · `python -m src.rapports` · `python -m src.writeup` · `python -m pytest tests -q`. Seed unique ; aucune clé dans le dépôt (`.env` ignoré, `.env.example` fourni) ; test à blanc depuis une copie vierge (phase 5 § 9).

Livraison par conteneur. « Someone else should be able to re-run your pipeline » (énoncé § 7) suppose que cette personne parvienne d'abord à installer l'environnement — ce qui, avec quinze modèles et une contrainte `numpy < 2`, n'est pas acquis. Le dépôt embarque donc une image Docker :

```
bash docker compose up --build # l'application sur http://localhost:8501
```

L'image de livraison contient le modèle entraîné, le jeu de données dérivé, les rapports et les figures : **aucune donnée brute ni clé n'est nécessaire pour voir l'outil**. Elle tourne sans privilèges et expose une sonde de santé. Un second étage, construit à la demande (`docker compose --profile pipeline run --rm pipeline`), ajoute le catalogue de modèles et rejoue tout le calcul depuis les cinq classeurs IBM, avec les mêmes versions épinglées — c'est la réponse la plus forte à l'exigence de reproductibilité, puisqu'elle fige l'environnement en même temps que le code. Les modèles de fondation (PyTorch, TabICL, TabPFN) restent hors image : ils la feraient passer de 0,8 à plus de 3 Go pour des résultats déjà calculés et lus dans `reports/fondation.json`.

4. Monitoring et réentraînement (énoncé § 4.9) — implémenté



Référence = population d'entraînement (répondants S3). **Courant** = population scorée. **Mois simulé** = tarif +12 %, 15 % des contrats basculés en mensuel, 10 % migrés vers la fibre.

	PSI des prédictions	Part de détracteurs prédits
Courant vs référence	0.025	31.4% (réf. 32.9%)
Mois simulé vs référence	0.054	36.4%

Variables les plus dérivantes — courant :


Variable	PSI	Statut
Total Charges	0.0482	stable
Total Revenue	0.0443	stable
Monthly Charge	0.0414	stable
Tenure in Months	0.0396	stable
Total Long Distance Charges	0.0385	stable
nb_services	0.0357	stable
Internet Type	0.0313	stable
tranche_anciennete	0.0301	stable

Variables les plus dérivantes — mois simulé :

Variable	PSI	Statut
Monthly Charge	1.3813	ALERTE
charge_par_service	0.6490	ALERTE
Total Charges	0.0482	stable
Contract	0.0475	stable
Total Revenue	0.0443	stable
Tenure in Months	0.0396	stable
Total Long Distance Charges	0.0385	stable
nb_services	0.0357	stable

Déclencheur de dérive sur le mois simulé : DÉCLENCHÉ (variables en alerte : Monthly Charge, charge_par_service). Le mécanisme détecte une hausse tarifaire et une migration de contrats que personne n'aurait signalées au modèle. Note : le PSI « courant » n'est pas nul alors que les deux populations viennent de la même base — c'est le **biais de sélection S3** qui s'affiche, et c'est exactement ce que le monitoring doit voir.

Performance sur les nouvelles réponses d'enquête (simulation : ~150 réponses par mois, tirées parmi les silencieux selon la propension biaisée S3) :



Mois	Nouvelles réponses	Cumul	Kappa (lot)	Rappel Dét. (lot)	Kappa (cumul)	Rappel Dét. (cumul)	Écart d'équité (âge, cumul)	Alerte équité	Chute	Volume atteint
1	150	150	0.510	0.583	0.510	0.583	13.6%	⚠		
2	150	300	0.556	0.622	0.534	0.602	20.8%	⚠		
3	150	450	0.523	0.595	0.531	0.600	12.4%	⚠		
4	150	600	0.600	0.641	0.549	0.612	18.2%	⚠		✓
5	150	750	0.451	0.476	0.530	0.587	17.8%	⚠		✓
6	150	900	0.420	0.609	0.513	0.591	13.4%	⚠		✓

Référence : kappa 0.384, rappel 0.629. Seuils : chute de kappa > 0.05, chute de rappel

0.1, volume minimal 500 nouveaux labels (atteint au mois 4), échéance 6 mois. Chute détectée sur la simulation : non. réponses tirées parmi les silencieux selon la propension S3 (les extrêmes répondent plus) : la performance sur les nouveaux répondants est donc optimiste par rapport à la base — exactement le biais que le monitoring réel subira.

L'équité est surveillée, pas seulement auditée une fois. le rappel Détracteur est recalculé par tranche d'âge sur les réponses cumulées ; une alerte est levée au-delà de 10% d'écart entre le groupe le mieux et le moins bien servi. Un groupe comptant moins de 10 détracteurs n'est pas évalué : le rappel y serait trop bruité pour décider. Sur cette simulation, l'alerte d'équité se déclenche dès le mois 1 — ce qui est attendu : l'écart mesuré en phase 5 dépasse le seuil de signalement, et le monitoring le retrouve sur les nouvelles réponses.

Les déclencheurs de réentraînement, et leur état sur le mois simulé — on montre qu'ils se déclenchent, on ne se contente pas de les annoncer :

Déclencheur	Règle	Déclenché sur la simulation
dérive des entrées	PSI > 0.2 sur au moins une variable du modèle	⚠ oui
chute de performance	kappa cumulé < référence - 0,05 ou rappel Détracteur < référence - 0,10	non
volume de nouveaux labels	500 nouvelles réponses d'enquête cumulées	⚠ oui
équité	écart de rappel Détracteur entre tranches d'âge > 10%	⚠ oui
échéance	réentraînement au plus tard tous les 6 mois	⚠ oui

Ce qu'on surveille, et quand on réentraîne :

Signal	Mesure	Déclencheur
Dérive des entrées	PSI par variable, mensuel, vs population d'entraînement	PSI > 0,20 sur une variable majeure (Contract, Tenure, Monthly Charge)
Dérive des prédictions	PSI de P(Détracteur) ; part de Détracteurs prédits	PSI > 0,20 ou variation > 5 points sans cause métier connue
Performance réelle	kappa et rappel Détracteur sur les nouvelles réponses d'enquête	chute > 0,05 de kappa ou > 10 points de rappel
Équité	rappel Détracteur par tranche d'âge sur le cumul des nouvelles réponses — implémenté , drapeau <code>alerte_equite</code>	écart > 10 points, le seuil de la phase 1
Volume de labels	nouvelles réponses reçues	réentraînement dès 500 nouveaux labels, au plus tard tous les 6 mois
Calibration	ECE sur les nouvelles réponses	recalibrer (Platt) sur les vraies réponses de la population cible dès 300 labels

Le seuil d'équité est le même partout dans l'étude — celui fixé à la phase 1. Une version antérieure de cette carte en annonçait 15 quand le critère de succès en annonçait 10 : deux seuils pour une même règle, donc aucune règle. L'écart n'est lisible qu'en cumul : sur 150 réponses par mois, un groupe d'âge compte trop peu de détracteurs pour qu'un rappel y soit interprétable, et le monitoring n'évalue donc un groupe qu'à partir de dix détracteurs observés.

Outil recommandé en production : Evidently (rapports HTML autonomes), cité par l'énoncé ; ici le PSI est implémenté directement pour rester sans dépendance.

5. La boucle de rétroaction — et la décision demandée

Un détracteur appelé puis retenu **change de classe**. Si on réentraîne sur ces données, le modèle apprend l'effet de sa propre intervention comme s'il s'agissait d'une propriété du client. Il se dégrade, et personne ne voit pourquoi. Trois parades, par ordre de coût :

- 1. **Journaliser chaque contact** (qui, quand, quel levier, quelle issue) et exclure du réentraînement les réponses postérieures à un contact, ou les traiter comme une strate séparée.
- 2. **Ne pas contacter 10 à 20 % des clients ciblés, tirés au hasard**, à chaque campagne. Ce groupe de contrôle coûte quelques clients non retenus et achète deux choses irremplaçables : la mesure de l'effet réel de la campagne, et les données d'un modèle d'**uplift** au cycle suivant — passer du ciblage par *risque* (cette étude) au ciblage par *sensibilité* (Ascarza 2018).
- 3. À terme, réentraîner sur les non-contactés et les contrôles seulement.

La décision demandée à la direction : autoriser le groupe de contrôle dès la prochaine campagne. C'est le seul passage de l'étude qui demande une décision plutôt que de présenter un résultat.

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Persistance d'un bloc : pipelines calibré, brut, de décision + métadonnées	rejouable sans réentraînement ; l'application n'a aucune logique de préparation	§ 1, <code>models/modele_final.joblib</code>
Streamlit, huit pages filtrables, contenu lu dans les artefacts	interface pour un responsable rétention ; aucune valeur recopiée ; les filtres croisés évitent de chercher dans 5 963 lignes	§ 2
Tolérance aux inconnus par le pipeline, pas par l'interface	un seul endroit à tester	§ 2, test dédié
Monitoring : PSI + performance sur nouvelles réponses + volume + équité + échéance	cinq déclencheurs, chacun avec sa règle et son état sur le mois simulé	§ 4
Groupe de contrôle recommandé	seule façon de mesurer l'effet et d'éviter la boucle de rétroaction	§ 5

Conformité à l'énoncé — chaque exigence, où elle est traitée

Relecture complète de l'énoncé (« Take-Home Challenge — Customer NPS Prediction for a Telecom Operator ») ; une ligne par exigence ou bonus.  traité ·  traité partiellement, raison indiquée.

Énoncé	Exigence	Réponse	Où	Statut
§ 2	Prioriser les appels vers les Détracteurs prédits	liste classée par P(Détracteur) calibrée, K réglable, export	phase 5 § 3 ; app <i>Prioriser les appels</i>	✓
§ 2	Drivers de détraction, individuels et par segment	contributions par client ; drivers par segment ; leviers	phase 5 § 6 ; app <i>Drivers et équité, Analyser un client</i>	✓
§ 2	Simuler le NPS des 85 % silencieux	NPS prédit avec IC bootstrap, vs répondants et vs vérité ; par segment	phase 5 § 4 ; app <i>Synthèse</i>	✓
§ 2	Formulation : classification / ordinale / régression + seuils, justifiée	les trois instanciées et comparées par la mesure	phase 4 § 1	✓
§ 3	IBM Telco 11.1.3+ comme source	cinq tables, jointure contrôlée	phase 2 § 1	✓
§ 3	Enrichissement externe justifié si utilisé	décision motivée de ne pas enrichir	phase 2 § 6	✓
§ 4.1	Mapping satisfaction → NPS justifié, raffiné, sensibilité discutée	M1/M2/M3, arbitrage empirique, sensibilité des drivers	phase 3 § 1 ; phase 5 § 5.1	✓
§ 4.1	Bruit réaliste	test de robustesse au bruit d'étiquettes 0–30 %	phase 5 § 5.2	✓
§ 4.1	Fuites dans la cible : Churn Score, Churn Value	registre de fuites en trois natures, information mutuelle, exclusion, test	phase 2 § 4	✓
§ 4.2	Schéma documenté (gardé / supprimé / transformé)	dictionnaire avec statut par colonne	phase 2 § 2 ; phase 3 § 3	✓
§ 4.2	Manquants et incohérences traités de façon transparente	cinq contrôles qualité	phase 2 § 3	✓
§ 4.2	Découpage reflétant 15 % répondants / 85 % silencieux, stratégie de validation	trois scénarios de non-réponse, MNAR retenu, CV sur les répondants	phase 4 § 2, § 6	✓
§ 4.2	Déséquilibre des classes discuté explicitement	double déséquilibre ; cinq stratégies comparées	phase 3 § 4	✓
§ 4.3	Features construites et justifiées ; fuites évitées	justification variable par variable ; neuf dérivées ; auto-pay	phase 3 § 3	✓
§ 4.3	Features géographiques / démographiques	testées en ablation, exclues par équité, coût chiffré	phase 5 § 5.3	✓
§ 4.4	Verbatims synthétiques par LLM, conditionnés, bruités, reproductibles, commités	7 043 verbatims : 1033 rédigés par un modèle de langage (15%, agents Claude Code, prompt versionné <code>prompts/verbatim_v1.txt</code> , textes commités), le reste par gabarit stochastique seeded — la source de chaque texte est tracée dans la colonne <code>source</code>	phase 4 § 9 ; <code>data/processed/verbatim.parquet</code>	⚠ (mixte, part LLM chiffrée)
§ 4.4	Combiner texte et tabulaire, expliquer ce que le texte apporte	texte seul, fusion tardive, fusion précoce ; gain qualifié d'artificiel	phase 4 § 9 ; app <i>Analyser un client</i>	✓
§ 4.5	Baseline	logistique multinomiale pondérée	phase 4 § 3	✓
§ 1	Time box de deux semaines, gestion du périmètre plutôt que sur-ingénierie	périmètre arbitré et publié : ce qui est dedans, ce qui est dehors, et pourquoi (CORAL/CORN, enrichissement Census, MLflow, API payantes)	phase 1 § 5.2	✓
§ 4.5	Au moins deux familles justifiées (boosting, ordinal, ensembles calibrés, fondation)	quinze modèles, sept familles ; XGBoost, LightGBM, CatBoost, mord, forêt, TabICL	phase 4 § 3, § 8	✓
§ 4.5	Métriques adaptées : macro-F1, balanced accuracy, kappa, rappel par classe, calibration, lift	toutes, avec la raison de chacune	phase 5 § 1–3	✓
§ 4.5	Validation simulant l'écart répondants / silencieux	S3 MNAR ; sélection sans regarder les silencieux	phase 4 § 2, § 6	✓
§ 4.5	Interprétabilité : importance / SHAP, drivers	coefficients ou SHAP selon le modèle ; méthode unique app + étude	phase 5 § 6	✓
§ 4.5	Discussion fuites, biais, bruit, qualité, limites du label	réparties et récapitulées	phases 2, 3, 5 § 9	✓
§ 4.5 bonus	Modèle de fondation tabulaire (TabPFN-2.5, TabICL), avantages / limites / coût	TabICL évalué ; TabPFN v2 non évalué ; TabPFN 2.5 indisponible — licence PriorLabs à accepter (compte + clé API), le dépôt de poids lui-même est public ; compromis coût/latence chiffré face au meilleur gradient boosting	phase 4 § 8	✓
§ 4.6	Drivers par segment ; actionnable vs non ; levier unique par Détracteur prédit ; corrélation ≠ causalité	segments contrat / ancienneté / accès ; règle de levier implémentée	phase 5 § 6	✓
§ 4.7	Audit par sous-groupe démographique, rappel Détracteur	genre, senior, marié, dépendants, âge, densité de zone ; rappel, précision, sélection	phase 5 § 7	✓
§ 4.7	Proxies d'attributs protégés ; gardé / supprimé / pourquoi	audit de reconstruction (AUC) des attributs exclus	phase 5 § 7.2	✓
§ 4.7	Conséquence métier des choix d'équité, arbitrage explicite	coût de l'exclusion chiffré ; mitigation par seuils chiffrée	phase 5 § 5.3, § 7.3	✓
§ 4.7	Points à escalader à CX / juridique	liste explicite	phase 5 § 7.4	✓
§ 4.8	Persistance du modèle	<code>models/modele_final.joblib</code>	phase 6 § 1	✓
§ 4.8	Interface : saisie ou ID → classe + probabilités ; drivers ; verbatim (bonus) ; robuste aux inconnus ; choix expliqués	Streamlit huit pages, filtres croisés sur toutes les pages ; test de robustesse	phase 6 § 2 ; app/app.py	✓

Énoncé	Exigence	Réponse	Où	Statut
§ 4.8	Utilisable par une équipe métier sans installation	image Docker et <code>docker compose up</code> : l'application démarre seule, modèle et données embarqués, sans clé ni fichier brut	README, Dockerfile, <code>docker-compose.yml</code>	✓
§ 4.9	Monitoring : dérive des entrées, des prédictions, performance sur nouvelles réponses	PSI, mois simulé, lots mensuels de nouvelles réponses	phase 6 § 4	✓
§ 4.9	Déclencheur de réentraînement (planning, seuil, volume de labels)	les trois, implémentés	phase 6 § 4	✓
§ 4.9	Boucle de rétroaction actions ↔ données	journalisation, groupe de contrôle, réentraînement sur non-contactés	phase 6 § 5	✓
§ 6	Code source ; notebook ; README + <code>.env.example</code> ; dataset dérivé ; verbatims + script ; artefact modèle ; captures ; write-up 3–6 pages	tous présents	dépôt ; <code>notebooks/</code> ; <code>livrable/</code>	✓
§ 7	Reproductible ; implémenté / approximatif / futur explicites ; usage d'IA déclaré ; pas de clés	test à blanc réussi ; environnement figé dans une image Docker (versions épinglées) ; revue ; README	phase 5 § 9 ; README ; Dockerfile	✓

Ce qui est implémenté, approximatif, ou laissé en travail futur (énoncé § 7)

Implémenté : tout le périmètre obligatoire (§ 4.1 à § 4.8), le monitoring (§ 4.9), les trois bonus (verbatims + fusion texte, drivers par segment, modèles de fondation via TabICL et TabPFN v2).

Approximatif, et dit comme tel : les paramètres économiques (coût d'appel, valeur client, taux de succès) sont des placeholders ; la propension à répondre est simulée ; les verbatims viennent d'un générateur local seedé, pas d'un appel API (aucune clé disponible ; le chemin est prêt) ; le NPS des silencieux est estimé avec une composition par classe déformée.

Travail futur : TabPFN 2.5 dès acceptation de la licence PriorLabs ; recalibration sur les vraies premières réponses ; groupe de contrôle puis modèle d'uplift ; API de scoring pour le CRM ; enrichissement texte sur de vrais verbatims.