

Étude complète — Prédiction de la catégorie NPS des clients silencieux

Annexe au write-up. Un document par phase CRISP-DM, généré par `python -m src.rapports`.

Synthèse — Prédire la catégorie NPS des clients silencieux

Pour un lecteur non technique. Chaque chiffre est calculé et retrouvable dans les six documents de l'étude.

Ce qu'on a construit

Un modèle qui, pour chacun des clients n'ayant pas répondu à l'enquête NPS, estime s'il est Détracteur, Passif ou Promoteur ; une application qui en tire une **liste d'appels priorisée** avec, pour chaque client, les raisons de la prédiction et le levier à proposer ; une estimation du **NPS des 85 % silencieux** ; et un dispositif de suivi.

Les cinq chiffres

NPS estimé de la base complète	+21 (secteur : +19 à +34) — contre -42 avec la grille de l'énoncé prise au pied de la lettre
NPS des silencieux, estimé par le modèle	+4 (intervalle +2 à +5) ; les répondants seuls donnent +27
Sur 500 appels, part de vrais détracteurs	51% contre 18% au hasard — ×2.8
Gain net supplémentaire par campagne	18 585 € à hypothèses de coût constantes (à valider)
Détracteurs retrouvés	63% — mais 48% seulement chez les moins de 30 ans

Les trois résultats à retenir

- 1. La grille NPS proposée dans l'énoncé fabrique un résultat faux.** Appliquée telle quelle, elle donne un NPS de **-42**, à 60–75 points des benchmarks télécom, parce qu'elle classe en détracteurs 2665 clients « moyennement satisfaits » (38% de la base) dont 84 % sont restés fidèles. En demandant aux données à qui ces clients ressemblent, on trouve qu'ils penchent à **72% du côté des promoteurs**. Le NPS corrigé est de **+21**, dans la fourchette du secteur.
- 2. Le modèle multiplie par 2.8 l'efficacité des appels**, et il a été choisi honnêtement. Quinze modèles de sept familles ont été comparés ; le choix s'est fait **sans regarder les clients sur lesquels il est évalué**, avec une règle qui préfère le plus simple quand les écarts sont dans le bruit. Retenu : logistique ordinale. Évalué dans les conditions réelles : entraîné sur 15 % de répondants dont la composition est biaisée (les mécontents et les enthousiastes répondent plus), testé sur les 85 % restants.
- 3. Il rate davantage les jeunes détracteurs** : 48% de rappel chez les moins de 30 ans contre 73% chez les 60 ans et plus — alors qu'aucune variable d'âge n'entre dans le modèle. On a mesuré pourquoi : les variables contractuelles **reconstruisent** l'âge. Une correction est chiffrée ; la décision de l'appliquer appartient au métier et au juridique, pas au modèle.

Ce qu'il faut savoir sur la fiabilité

- Aucune variable liée au départ des clients n'est utilisée.** Le dataset en contient plusieurs qui auraient donné un score presque parfait et un modèle inutilisable. Identifiées, mesurées, exclues.
- Les probabilités servent à classer les clients entre eux, pas à lire une fréquence** : ajustées sur des répondants biaisés, elles sont surestimées. L'application le dit à chaque écran.
- Ce que le modèle appelle « drivers » sont des associations**, pas des causes. Contrat sans engagement, faible ancienneté, absence de parrainage et facture élevée vont avec la détraction ; l'offre commerciale E « prédit » le départ parce qu'elle a été proposée à des clients déjà fragiles.

La décision demandée

Appeler les clients les plus à risque n'est pas la stratégie la plus rentable : la recherche établit qu'il faut cibler ceux **dont le comportement change le plus quand on les appelle**. Mesurer cela ne demande qu'une chose, gratuite : **ne pas contacter 10 à 20 % des clients ciblés à la prochaine campagne, tirés au hasard**. Sans ce groupe de contrôle, on ne saura jamais si la campagne a servi — et le modèle se dégradera en réapprenant ses propres effets.

Ce que cette étude ne fait pas

Elle n'estime pas l'effet d'un appel (aucune campagne dans les données). Ses verbatims clients sont synthétiques et le signal texte, démontré techniquement, n'est pas déployable sur cette base. Ses hypothèses économiques sont des paramètres à valider avec l'équipe rétention. TabPFN n'a pas pu être évalué (accès aux poids soumis à acceptation) ; TabICL l'a été.

Lire la suite

[Phase 1 — métier](#) · [Phase 2 — données](#) · [Phase 3 — préparation](#) · [Phase 4 — modélisation](#) · [Phase 5 — évaluation](#) · [Phase 6 — déploiement](#) · [Conformité à l'énoncé](#)

Phase 1 — Compréhension métier

En bref. Un opérateur télécom ne connaît le NPS que de ~15 % de ses clients. On construit un modèle qui estime la catégorie NPS des 85 % silencieux, une liste d'appels priorisée pour l'équipe rétention, et une lecture des drivers de détraction. La cible est **ordonnée** (Détracteur < Passif < Promoteur) et **déséquilibrée** ; les critères de succès sont chiffrés avant toute ligne de code.

1. Le problème et ses trois usages

Usage demandé (énoncé § 2)	Ce que le livrable fournit	Où
Prioriser les appels vers les détracteurs prédicts	liste classée par P(Détracteur) calibrée, capacité K réglable, export CSV	application, page <i>Prioriser les appels</i>
Identifier les drivers de détraction, au niveau individuel et par segment	contributions par client ; drivers par segment (contrat, ancienneté, type d'accès) ; leviers actionnables	phase 5 § 6, application
Simuler le NPS attendu des 85 % silencieux	NPS prédit des silencieux avec intervalle bootstrap, comparé au NPS observé des répondants et, ici seulement, à la vérité	phase 5 § 4

2. Critères de succès, fixés a priori

Niveau	Critère	Cible	Résultat (phase 5)
Métier	Précision@K sur les détracteurs, K = 500 appels/mois	nettement au-dessus du taux de base	51% vs 18% (×2.8)
Métier	Gain net d'une campagne ciblée vs ciblage aléatoire	positif, chiffré en euros	18 585 € par campagne
Data science	Kappa quadratique pondéré et rappel Détracteur	au niveau de la baseline ou au-dessus	voir phase 4 § 6
Data science	Aucune classe abandonnée	rappel > 0,05 sur les trois classes	vérifié (test automatisé)
Éthique	Écart de rappel Détracteur entre sous-groupes	mesuré, signalé s'il dépasse 10 points	26 pts sur l'âge, signalé

3. Formulation du problème d'apprentissage

L'énoncé demande d'arbitrer entre classification nominale, classification ordinale et régression avec seuillage, et de **justifier**. On ne tranche pas a priori : les trois formulations sont instanciées dans le catalogue de modèles (phase 4 § 3) et comparées par la même mesure — le kappa quadratique pondéré, qui pénalise une erreur de deux crans plus qu'une erreur d'un cran, ce qui est le comportement métier correct sur une cible ordonnée.

4. Hypothèses déclarées

- Satisfaction Score (1–5) est un proxy acceptable d'une note NPS (0–10). C'est une hypothèse, pas une identité : le NPS mesure une intention de recommandation, la satisfaction une expérience. Elero et al. (2026) font la même approximation et la discutent.
- Le biais de non-réponse simulé (les mécontents et les enthousiastes répondent plus) ressemble au biais réel. Sa forme est plausible, pas observée.
- Les patterns d'un opérateur californien fictif se transposent au cadrage panafricain de l'énoncé.

5. Contraintes et ce qu'elles interdisent

Dataset fictif (IBM), une seule photographie, aucun historique, aucune campagne de rétention enregistrée. Conséquence directe : **aucune estimation d'effet causal n'est possible** — le modèle classe par risque, pas par sensibilité à l'appel (phase 5 § 8, phase 6 § 5).

6. Registre de risques

Risque	Parade dans l'étude
Fuite de données → score irréal, modèle inutilisable	registre de fuites quantifié (phase 2 § 4) + double diagnostic (phase 4 § 5)
Cible mal construite → tout le reste invalide	arbitrage empirique des « 3 » + sensibilité au mapping + bruit d'étiquettes (phases 3, 5)
Sélection de modèle sur le jeu de test	sélection par validation croisée sur les répondants ; les silencieux ne servent qu'au test (phase 4 § 6)
Modèle inéquitable non détecté	audit par sous-groupe, audit des proxies, mitigation chiffrée (phase 5 § 7)
Livrable non reproductible	seed unique, python -m src.run, test à blanc depuis copie vierge, tests automatisés

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Cible traitée comme ordonnée et déséquilibrée	trois classes ordonnées par construction ; Passif = 38 % de la base, Détracteur = 20 %	phase 3 § 4
Métrique principale = kappa quadratique pondéré	seule métrique usuelle qui distingue une erreur d'un cran d'une erreur de deux crans	phase 5 § 1
Critères de succès chiffrés avant modélisation	exigence CRISP-DM ; évite de choisir la métrique qui arrange	ce document § 2

Phase 2 — Compréhension des données

En bref. Cinq tables IBM Telco 11.1.3+ jointes sans perte (7043 clients × 51 colonnes). Trois faits structurent tout le projet : (1) la note **3** pèse 38% de la base et 84% de ces clients sont restés ; (2) le dataset **contient sa propre réponse** — satisfaction 1–2 → 100 % de départs, 4–5 → 0 % — donc toute colonne liée au churn est une fuite ; (3) les offres commerciales ont été **ciblées** sur des clients fragiles, ce qui interdit toute lecture causale.

1. Sources et jointure

Table	Lignes × colonnes	Clé	Contenu
demographics	7 043 × 9	Customer ID	genre, âge, situation familiale
location	7 043 × 9	Customer ID	ville, code postal, coordonnées
population	1 671 × 3	Zip Code	population du code postal
services	7 043 × 30	Customer ID	contrat, services, facturation, parrainage, Satisfaction Score
status	7 043 × 11	Customer ID	churn (label, valeur, score, catégorie, raison), CLTV

Jointure interne sur `Customer ID`, `population` rattachée par `Zip Code`. Porte de contrôle : **7043 lignes** après jointure, 0 doublon d'identifiant (test automatisé).

2. Dictionnaire des données

Statut de chaque colonne, décidé au registre de fuites (§ 4) : `feature` = variable explicative candidate (27) · `audit_seulement` = exclue du modèle, utilisée pour l'audit d'équité (12) · `fuite_*` = interdite (7) · `techniques` = identifiant ou constante (4) · `cible` (1).

Colonne	Type	Manquants	Modalités	Exemple	Statut
Customer ID	object	0.0%	7043	8779-QRDMV	techniques
Gender	object	0.0%	2	Male	audit_seulement
Age	int64	0.0%	62	78	audit_seulement
Under 30	object	0.0%	2	No	audit_seulement
Senior Citizen	object	0.0%	2	Yes	audit_seulement
Married	object	0.0%	2	No	audit_seulement
Dependents	object	0.0%	2	No	audit_seulement
Number of Dependents	int64	0.0%	10	0	audit_seulement
Country	object	0.0%	1	United States	techniques
State	object	0.0%	1	California	techniques
City	object	0.0%	1106	Los Angeles	audit_seulement
Zip Code	int64	0.0%	1626	90022	audit_seulement
Lat Long	object	0.0%	1679	34.02381, -118.156582	techniques
Latitude	float64	0.0%	1626	34.02381	audit_seulement
Longitude	float64	0.0%	1625	-118.156582	audit_seulement
Referred a Friend	object	0.0%	2	No	feature
Number of Referrals	int64	0.0%	12	0	feature
Tenure in Months	int64	0.0%	72	1	feature
Offer	object	55.0%	5	Offer E	feature
Phone Service	object	0.0%	2	No	feature
Avg Monthly Long Distance Charges	float64	0.0%	3584	0.0	feature
Multiple Lines	object	0.0%	2	No	feature
Internet Service	object	0.0%	2	Yes	feature
Internet Type	object	21.7%	3	DSL	feature
Avg Monthly GB Download	int64	0.0%	50	8	feature
Online Security	object	0.0%	2	No	feature
Online Backup	object	0.0%	2	No	feature
Device Protection Plan	object	0.0%	2	Yes	feature
Premium Tech Support	object	0.0%	2	No	feature
Streaming TV	object	0.0%	2	No	feature
Streaming Movies	object	0.0%	2	Yes	feature
Streaming Music	object	0.0%	2	No	feature
Unlimited Data	object	0.0%	2	No	feature
Contract	object	0.0%	3	Month-to-Month	feature
Paperless Billing	object	0.0%	2	Yes	feature
Payment Method	object	0.0%	3	Bank Withdrawal	feature
Monthly Charge	float64	0.0%	1585	39.65	feature
Total Charges	float64	0.0%	6540	39.65	feature
Total Refunds	float64	0.0%	500	0.0	feature
Total Extra Data Charges	int64	0.0%	16	20	feature
Total Long Distance Charges	float64	0.0%	6110	0.0	feature
Total Revenue	float64	0.0%	6996	59.65	feature
Satisfaction Score	int64	0.0%	5	3	cible
Customer Status	object	0.0%	3	Churned	fuite_consequence
Churn Label	object	0.0%	2	Yes	fuite_consequence
Churn Value	int64	0.0%	2	1	fuite_consequence
Churn Score	int64	0.0%	81	91	fuite_modele_amont
CLTV	int64	0.0%	3438	5433	fuite_modele_amont
Churn Category	object	73.5%	5	Competitor	fuite_disponibilite
Churn Reason	object	73.5%	20	Competitor offered mor	fuite_disponibilite
Population	int64	0.0%	1569	68701	audit_seulement


3. Qualité des données — cinq contrôles

3.1 Valeurs manquantes. Quatre colonnes, toutes à manquants **structurels** (le vide a un sens), aucune imputation :

Colonne	Manquants	Part	Nature	Traitement
Churn Category	5174	73.5%	structurel	colonne exclue (fuite de disponibilité)
Churn Reason	5174	73.5%	structurel	colonne exclue (fuite de disponibilité)
Offer	3877	55.0%	structurel	catégorie « Aucune offre »
Internet Type	1526	21.7%	structurel	catégorie « Pas d'internet »

3.2 Doublons. 0 sur l'identifiant, 0 sur l'ensemble des colonnes hors identifiant.

3.3 Valeurs aberrantes (règle $IQR \times 1,5$) — **conservées** : un client à 100 Go/mois ou à 120 \$/mois est un client réel, précisément le profil qu'un modèle de détraction doit voir ; les modèles retenus (standardisation + régularisation, arbres) y sont robustes.



Variable	Hors $IQR \times 1,5$
Tenure in Months	0
Monthly Charge	0
Total Charges	0
Total Revenue	21
Avg Monthly GB Download	362

3.4 Cohérence interne. Ancienneté nulle : 0 client. Écart > 50 % entre Total Charges et Monthly Charge × Tenure : 2 lignes — attendu (tarif variable sur la durée de vie), non corrigé, documenté.

3.5 Colonnes constantes. Country, State — base 100 % Californie. Supprimées.

4. Registre de fuites — l'étape la plus discriminante

Le fait fondateur.

Satisfaction	Restés	Partis	% départ
1.0	0.0	922.0	100.0
2.0	0.0	518.0	100.0
3.0	2236.0	429.0	16.1
4.0	1789.0	0.0	0.0
5.0	1149.0	0.0	0.0

Satisfaction 1–2 → **100 % de départs** ; 4–5 → **0 %**. Connaître le churn, c'est connaître la cible. Or au moment où l'on veut détecter un détracteur, il n'est pas encore parti : l'information n'existe pas. Toute colonne liée au churn est donc une fuite — et une fuite de trois natures :


Nature	Définition	Colonnes	Décision
Conséquence	la colonne est un effet de la cible	Churn Label, Churn Value, Customer Status	exclues
Disponibilité	la colonne n'existe que pour une partie de la population — sa présence trahit la réponse	Churn Category, Churn Reason (5 174 vides = clients restés)	exclues
Modèle amont	la colonne est la sortie d'un autre modèle (IBM SPSS)	Churn Score, CLTV	exclues des features ; CLTV admise en couche de décision (phase 5 § 3)

Churn Score et CLTV par niveau de satisfaction :

Satisfaction	Churn Score moyen	CLTV moyenne
1.0	82.0	4158.0
2.0	82.0	4104.0
3.0	55.0	4473.0
4.0	50.0	4514.0
5.0	50.0	4381.0

Churn Score passe de ~82 à ~50 : une prédiction déguisée en donnée. CLTV est plate — peu informative comme feature, mais légitime pour pondérer *qui appeler* parmi les détracteurs prédits.

Quantifier au lieu d'affirmer. Information mutuelle de chaque colonne avec la cible :



Colonne	Information mutuelle	Statut
Customer Status	0.421	fuite_consequence
Churn Value	0.416	fuite_consequence
Churn Score	0.281	fuite_modele_amont
Contract	0.092	feature
Number of Referrals	0.058	feature
Internet Type	0.052	feature
Tenure in Months	0.046	feature
Monthly Charge	0.045	feature
Offer	0.033	feature
CLTV	0.016	fuite_modele_amont


Les colonnes exclues portent une information sans commune mesure avec les features légitimes. C'est la mesure qui justifie l'exclusion, pas l'intuition.

Contre-exemple publié. Mustafa et al. (2021) annoncent 98 % d'exactitude en prédisant le churn avec la note NPS et la catégorie NPS parmi les features, alors que leur cible en dérive. Leurs modèles linéaires font 41 %, leurs arbres 98 % : cet écart est la **signature** d'une variable qui fuit. On applique ce test en phase 4 § 5.

Démographie et géographie : exclues du modèle, gardées pour l'audit. Gender, Age, Under 30, Senior Citizen, Married, Dependents, Number of Dependents, City, Zip Code, Latitude, Longitude, Population. Précédent : Elero et al. (2026) excluent délibérément les démographiques. Position cohérente avec le métier (les leviers actionnables sont contractuels) et avec l'énoncé § 4.7 (le code postal est un proxy socio-économique). Le coût de cette exclusion est **chiffré** en phase 5 § 5, et la mesure de ce que les features retenues révèlent malgré tout de ces attributs en phase 5 § 7.

5. Analyse exploratoire


5.1 La cible.




Note	Clients	Part
1	922	13.1%
2	518	7.4%
3	2665	37.8%
4	1789	25.4%
5	1149	16.3%

La note 3 pèse **2665 clients, 37.8% de la base**, et 2236 d'entre eux (84%) sont toujours clients. Où les placer dans la grille NPS décide de tout le reste (phase 3 § 1).


5.2 Numériques par niveau de satisfaction. L'ancienneté et le nombre de parrainages croissent nettement avec la satisfaction ; la charge mensuelle varie peu.




5.3 Catégorielles : force d'association. Le type de contrat et l'offre reçue dominent ; les variables démographiques (gris) sont faiblement associées à la satisfaction — leur exclusion devrait donc coûter peu (vérifié en phase 5).



5.4 Corrélations entre numériques. Total Charges, Total Revenue et Tenure in Months sont mécaniquement liés (le total cumule le mensuel sur la durée). Traité en phase 3 § 3 (colinéarité).



5.5 La quasi-expérience du dataset : Offer.



Offre	Clients	Taux de départ	Satisfaction moy.
Offer A	520	6.7%	3.55
Offer B	824	12.3%	3.48
Offer C	415	22.9%	3.32
Offer D	602	26.7%	3.25
Aucune offre	3877	27.1%	3.24
Offer E	805	52.9%	2.81

Les clients ayant reçu l'**offre E partent deux fois plus** que ceux qui n'ont rien reçu. Lire « l'offre E fait fuir » serait une erreur : c'est un **biais d'indication** — l'offre a été proposée à des clients déjà en difficulté, comme un médicament à des patients déjà malades. On ne lit pas un effet causal dans des données observationnelles ; ce constat fonde les limites du ciblage (phase 5 § 8).

6. Enrichissement externe : décision

L'énoncé autorise des sources externes (recensement par code postal, benchmarks télécom) à condition d'en justifier la pertinence métier. **Décision : aucune.** Deux raisons. (1) Le dataset contient déjà la seule variable de contexte géographique disponible à la maille du client (*Population* du code postal), et elle est exclue du modèle au titre de l'équité — ajouter des revenus médians par code postal reviendrait à réintroduire par la fenêtre le proxy socio-économique qu'on a sorti par la porte (énoncé § 4.7). (2) Le dataset est fictif : un enrichissement réel sur des coordonnées californiennes fictives n'aurait aucune validité. Les **benchmarks NPS télécom** publiés sont en revanche utilisés comme corroboration externe de la construction de la cible (phase 3 § 1).

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Jointure interne, porte de contrôle à 7 043 lignes	aucune perte tolérée ; un client sans ligne de services est une erreur, pas un cas	test <code>test_jointure_sans_perte</code>
Manquants structurels → catégorie explicite, jamais imputés	le vide a un sens métier (pas d'offre, pas d'internet) ; imputer fabriquerait de l'information	§ 3.1
Aberrantes conservées	profils réels ; robustesse des modèles retenus	§ 3.3
Toute colonne liée au churn exclue, en trois natures nommées	fait fondateur : satisfaction ⇔ churn ; information mutuelle mesurée	§ 4, test <code>test_aucune_colonne_churn_dans_les_features</code>
Démographie et géographie hors modèle, audit seulement	leviers non actionnables ; proxies d'attributs protégés (énoncé § 4.7)	§ 4, phase 5 § 7
Aucun enrichissement externe	réintroduirait un proxy socio-économique ; dataset fictif	§ 6


Phase 3 — Préparation des données

En bref. La cible NPS est construite à partir de la satisfaction 1–5 par trois mappings ; le mapping de l'énoncé donne un NPS de **-42**, hors de toute plausibilité sectorielle, parce qu'il envoie les 2665 clients « 3 » chez les détracteurs. Un arbitrage **empirique** (modèle entraîné sur les seuls extrêmes) montre qu'ils penchent à 72% côté promoteur ; le bloc rejoint les Passifs (NPS **+21**). 18 variables numériques et 17 catégorielles sont retenues, chacune avec l'hypothèse qui la justifie ; le déséquilibre est traité par pondération de classes, choix comparé à quatre alternatives ; tout le préprocessing vit dans un `Pipeline` scikit-learn.

1. Construction de la cible NPS

Le dataset donne une satisfaction de 1 à 5. Le NPS a trois classes. Personne ne fournit la traduction : c'est à nous de la construire et de la défendre.


	Détracteur	Passif	Promoteur	NPS	Logique
M1	1, 2, 3	4	5	-42.0	mapping baseline de l'énoncé (fidèle à l'échelle : $3/5 \approx 5/10$ = détracteur)
M2	1, 2	3, 4	5	-4.1	recentré : le 3 est le milieu, donc passif
M3	1, 2	3	4, 5	+21.3	arbitré par les données (§ 1.2)



1.1 Pourquoi M1 pose problème. M1 est le mapping *fidèle à l'échelle* — et c'est précisément pour ça qu'il est faux : une échelle à 5 points compressée dans les bandes NPS envoie 58 % de la base chez les détracteurs, dont 2665 clients à « 3 » qui, à 84 %, sont restés. Un NPS de -42 est à 60–75 points des benchmarks télécom publiés (+19 à +34 ; sources commerciales, dispersion forte). Ce n'est pas un résultat, c'est un signal d'alerte sur la construction.

1.2 L'arbitrage empirique des « 3 » (méthode d'Elero et al., 2026, qui l'appliquent aux notes 7 et 8). Plutôt que de décider où vont les 2665 clients ambigus, on demande aux données :

- entraîner un modèle **uniquement sur les extrêmes non ambigus** — satisfaction 1–2 contre 4–5 (4378 clients), avec les seules features légitimes ;
- contrôler qu'il sépare ces extrêmes : **80.1%** d'exactitude en validation croisée — dans la fourchette attendue de la littérature (0,77–0,80), donc sans fuite ;
- faire passer les 2665 clients à « 3 », jamais vus, à travers ce modèle.



Résultat : 27.9% des « 3 » ressemblent à des détracteurs, 72.1% à des promoteurs. Le bloc rejoint les **Passifs**. Le NPS qui en découle (+21.3) tombe dans la fourchette sectorielle — corroboration externe, pas preuve.

1.3 Le piège évité — la circularité. Il était tentant d'étiqueter *chaque* « 3 » par la prédiction du modèle. Ce serait une faute : la cible deviendrait une fonction des features, et le modèle aval réapprendrait sa propre sortie — une circularité cousine de la fuite `Churn Score`. On tranche donc **le bloc** par la mesure agrégée, et on conserve la probabilité individuelle comme simple **indicateur métier** (« ce passif a un profil de détracteur à X % »), affiché dans l'application, jamais utilisé à l'entraînement.

1.4 Ce que l'énoncé suggérerait et qu'on a refusé. Enrichir la cible par Churn Value ou CLTV transformerait le projet en modèle de churn déguisé (phase 2 § 4). Enrichir par l'ancienneté rendrait la cible fonction d'une feature (même circularité qu'en 1.3). Le **bruit réaliste** suggéré par l'énoncé est traité en phase 5 § 5 comme test de robustesse : on corrompt les étiquettes d'entraînement et on mesure la dégradation.

2. Nettoyage

- Manquants structurels (Offer, Internet Type) → catégorie explicite (phase 2 § 3).
- Manquants accidentels (aucun dans ce dataset, mais l'application en produira) → imputation **dans le pipeline** (médiane / modalité la plus fréquente), jamais en amont, pour qu'aucune statistique calculée sur tout le jeu ne fuie vers l'évaluation.
- Aberrantes conservées ; colonnes constantes supprimées.

3. Feature engineering — chaque variable adossée à une hypothèse

3.1 Variables brutes retenues et pourquoi.

Variable(s)	Pourquoi elle devrait aider à prédire le NPS
Contract	l'engagement contractuel est le premier marqueur de la relation ; un client mensuel peut partir demain
Tenure in Months	l'ancienneté cumule l'expérience vécue ; les premiers mois concentrent les déceptions
Offer	un geste commercial reçu signale à la fois une politique de l'opérateur et un client jugé fragile
Number of Referrals	recommander est le comportement que le NPS mesure : proxy comportemental direct, observable, antérieur
Monthly Charge	le prix payé chaque mois ; la perception du rapport qualité-prix passe par lui
Total Charges / Total Revenue	l'intensité économique cumulée de la relation
Total Refunds / Total Extra Data Charges / Total Long Distance Charges	traces d'incidents de facturation et d'usages hors forfait — sources classiques de friction
Avg Monthly GB Download / Avg Monthly Long Distance Charges	intensité d'usage : un gros consommateur subit davantage les défauts de qualité
Internet Service / Internet Type	la fibre et le DSL n'ont ni la même qualité ni la même clientèle (Elero : vitesse et stabilité = premiers drivers)
Services optionnels (sécurité, sauvegarde, protection, support premium, streaming, données illimitées)	la composition du bouquet dit ce que le client attend et ce qu'il a accepté de payer
Phone Service / Multiple Lines	périmètre du service souscrit
Paperless Billing	proxy d'engagement numérique cité par l'énoncé
Payment Method	le mode de paiement révèle l'automatisation de la relation (auto-pay) et le canal préféré

3.2 Variables dérivées.

Variable dérivée	Hypothèse métier
nb_services	intensité de la relation commerciale : plus de services, plus de raisons de rester — ou de se plaindre
charge_par_service	perception du rapport qualité-prix : ce que coûte chaque service souscrit
tranche_anciennete	l'insatisfaction d'un nouveau client (attentes déçues) n'a pas la même nature que celle d'un ancien (usure)
a_recu_offre	un geste commercial a-t-il été fait ? (indicateur binaire, complémentaire du type d'offre)
a_eu_remboursement	trace d'un incident de facturation reconnu par l'opérateur
a_frais_supplementaires	trace d'un dépassement de forfait — friction tarifaire
revenu_par_mois	intensité économique moyenne de la relation, indépendante de l'ancienneté
a_parraine	proxy comportemental direct de la recommandation, donc du NPS lui-même ; comportement passé observable, pas une conséquence de la note
paiement_automatique	auto-pay (énoncé § 4.3) : un paiement automatisé signale une relation installée et sans friction

3.3 Variables retenues. 18 numériques : Number of Referrals, Tenure in Months, Avg Monthly Long Distance Charges, Avg Monthly GB Download, Monthly Charge, Total Charges, Total Refunds, Total Extra Data Charges, Total Long Distance Charges, Total Revenue, nb_services, charge_par_service, a_recu_offre, a_eu_remboursement, a_frais_supplementaires, revenu_par_mois, a_parraine, paiement_automatique. **17 catégorielles :** Offer, Phone Service, Multiple Lines, Internet Service, Internet Type, Online Security, Online Backup, Device Protection Plan, Premium Tech Support, Streaming TV, Streaming Movies, Streaming Music, Unlimited Data, Contract, Paperless Billing, Payment Method, tranche_anciennete.


3.4 Variables écartées et pourquoi. Démographie (Gender, Age, Senior Citizen, Married, Dependents...) et géographie (Zip Code, Latitude, Longitude, Population, City) : hors modèle par décision d'équité (phase 2 § 4), **coût chiffré** en phase 5 § 5 ; Referred a Friend : redondant avec Number of Referrals (recodé en a_parraine) ; identifiants et constantes.

3.5 Colinéarité (VIF).

Variable	VIF
Total Revenue	> 1 000 (identité comptable)
Total Charges	> 1 000 (identité comptable)
Total Refunds	> 1 000 (identité comptable)
Total Extra Data Charges	> 1 000 (identité comptable)
Total Long Distance Charges	> 1 000 (identité comptable)
revenu_par_mois	86.5
Monthly Charge	68.2
nb_services	19.4
Avg Monthly Long Distance Charges	18.7
Tenure in Months	7.7
charge_par_service	4.9
a_eu_remboursement	4.3
a_frais_supplementaires	3.1
a_parraine	2.1
Number of Referrals	2.1
Avg Monthly GB Download	1.3
paiement_automatique	1.0
a_recu_offre	1.0

Total Charges, Total Revenue, Total Refunds, Total Extra Data Charges et Total Long Distance Charges sont liés par une **identité comptable** (le revenu total est la somme des autres) : VIF infini par construction. **Décision : conservées.** Les modèles linéaires du catalogue sont régularisés (L2), ce qui absorbe la colinéarité ; les arbres y sont insensibles. La colinéarité brouillerait l'interprétation coefficient par coefficient : l'interprétabilité (phase 5 § 6) lit donc les variables corrélées comme un bloc.

4. Déséquilibre des classes



Deux déséquilibres se superposent. Dans la base, le Passif domine (38%) et le Détracteur est minoritaire (20%). Mais le modèle apprend sur les **répondants**, où le biais de réponse (phase 4 § 2) inverse la structure : 33% de Détracteurs, 7% de Passifs seulement. Le Passif est donc à la fois la classe la plus fréquente à l'évaluation et la plus rare à l'entraînement — c'est **elle** qu'un modèle abandonne en premier, et c'est ce que le rappel par classe surveille (phase 5 § 1).

Stratégies comparées (baseline logistique, S3/M3, évaluées sur les silencieux) :

Stratégie	Kappa	Macro-F1	Rappel Dét.	Rappel Passif	Rappel Prom.	Précision Dét.
aucune (logistique non pondérée)	0.365	0.380	0.764	0.012	0.793	0.399
pondération de classes 'balanced' (retenue)	0.370	0.497	0.785	0.323	0.559	0.395
sur-échantillonnage aléatoire	0.372	0.498	0.776	0.329	0.560	0.396
SMOTE (k=5)	0.357	0.489	0.737	0.323	0.565	0.388
sous-échantillonnage aléatoire	0.323	0.479	0.691	0.418	0.446	0.372

Décision : pondération de classes `balanced`. Elle est appliquée à tous les modèles du catalogue qui l'acceptent (ou par `sample_weight` équivalent). Le rééchantillonnage (SMOTE, sur/sous-échantillonnage) n'apporte pas de gain systématique ici et fabrique des clients synthétiques dans un espace one-hot où l'interpolation n'a pas de sens métier ; la pondération est plus simple, sans hyperparamètre, et laisse les données intactes.

5. Pipeline de préparation

Tout est encapsulé dans un Pipeline scikit-learn (`ColumnTransformer`) :

- numériques → imputation médiane → `StandardScaler` **pour les modèles à distance ou linéaires seulement** (logistique, ordinale, ridge, KNN, SVM, MLP, Naive Bayes) ; rien pour les arbres — deux préparations, pas un compromis ;
- catégorielles → imputation mode → `OneHotEncoder(handle_unknown='ignore')` , pour que l'application tolère une modalité jamais vue sans planter ;
- CatBoost reçoit les catégorielles **brutes** : c'est l'hypothèse qu'il teste (phase 4 § 3).

Rien n'est transformé hors du pipeline. C'est ce qui rend le modèle sérialisable d'un bloc et exempt de fuite entraînement → test. Le découpage répondants / silencieux est décrit en phase 4 § 2.

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Cible M3 : 1–2 Détracteur, 3 Passif, 4–5 Promoteur	arbitrage empirique des « 3 » ; NPS dans la fourchette sectorielle	§ 1.2, test <code>test_mappings_et_nps</code>
Aucun étiquetage individuel des « 3 » par le modèle	évite la circularité cible ← features	§ 1.3, test <code>test_indicateur_profil_detracteur_reserve_aux_ambigus</code>
Neuf variables dérivées, chacune avec son hypothèse	exigence § 4.3 de l'énoncé	§ 3.2
Colinéarité conservée	régularisation L2 et arbres insensibles ; lecture par blocs	§ 3.5
Pondération de classes plutôt que rééchantillonnage	comparaison de cinq stratégies ; simplicité	§ 4
Préprocessing dans le Pipeline uniquement	aucune fuite de statistiques ; sérialisation d'un bloc	§ 5, test <code>test_modele_tolere_entrees_vides_et_modalites_inconnues</code>

Phase 4 — Modélisation

En bref. Le découpage 15/85 est **simulé avec un biais de non-réponse** (trois scénarios, du plus optimiste au plus réaliste) et le modèle est toujours entraîné sur les répondants, évalué sur les silencieux dont on connaît la vérité. **Quinze modèles en sept familles**, couvrant les trois formulations de l'énoncé, sont comparés sur 3 scénarios × 3 mappings, puis réglés et sélectionnés **par validation croisée sur les répondants** — sans jamais regarder les silencieux — avec une règle de parcimonie. Retenu : **logistique ordinale** (réglée). Le meilleur kappa CV brut était ridge seuils ; le meilleur sur les silencieux est ridge seuils. L'écart entre ce que la validation croisée promet (0.61) et ce que les silencieux donnent (0.38) est le coût mesuré du biais de réponse.

1. Les trois formulations, instanciées et comparées

Formulation	Comment elle traite l'ordre des classes	Modèles du catalogue
Classification nominale	ne le voit pas ; l'ordre est réintroduit par la métrique (kappa quadratique) et par la pondération	logistique, arbre, forêt, boosting (×5), KNN, SVM, MLP, Naive Bayes
Classification ordinale	l'impose par la structure : une variable latente et deux seuils	logistique ordinale (mord, all-threshold)
Régression 1–5 puis seuillage	exploite la note fine à l'entraînement ; seuils optimisés sur le kappa	ridge + seuils, HGB + seuils

Résultat par formulation (meilleur modèle de chaque, S3/M3) :

Formulation	Modèles	Meilleur (CV)	Kappa CV IPW	Kappa silencieux	Macro-F1 silencieux
classification nominale	12	catboost	0.616	0.366	0.440
classification ordinale	1	logistique_ordinale	0.597	0.384	0.490
régression 1-5 puis seuillage	2	ridge_seuils	0.621	0.387	0.478


Lecture : les trois formulations arrivent à des kappas voisins ; celles qui **exploitent l'ordre** (ordinale, régression à seuils) sont construites pour la métrique qui respecte l'ordre et en tirent un léger avantage, avec un **profil par classe** propre à chacune (rappels Détracteur et Passif dans le tableau de sélection, § 6.2). Le choix final se fait sur la mesure (§ 6), et l'évaluation métier (phase 5 § 3) vérifie que le classement des appels n'en souffre pas.

2. Protocole de validation 15 % / 85 %

Un `train_test_split` stratifié rate l'intention de l'énoncé : les répondants à une enquête NPS ne sont pas un échantillon aléatoire — les très mécontents et les très contents répondent plus. C'est du **MNAR** (*missing not at random*). L'avantage rare de ce dataset : on connaît la satisfaction des 100 %, donc on peut simuler le biais et **mesurer ce qu'il coûte**, ce qu'aucun praticien ne peut faire en production.

Scénario	Mécanisme de réponse	Ce qu'il mesure
S1 — MCAR	15 % tirés au hasard	borne haute optimiste
S2 — MAR	propension = f(ancienneté, facture dématérialisée, engagement)	biais de covariables seul
S3 — MNAR	propension = f(covariables, écart de la satisfaction au centre)	le cas réaliste, retenu pour le modèle final

Dans tous les cas : **entraînement sur les 15 % répondants, évaluation sur les 85 % silencieux**. Validation croisée stratifiée à 5 plis à l'intérieur des 15 % pour le réglage et la sélection.



Scénario	Taux de réponse	Satisf. base	Satisf. répondants	Extrêmes base	Extrêmes répondants
S1_MCAR	15.2%	3.245	3.230	36.8%	39.7%
S2_MAR	15.4%	3.245	3.316	36.8%	33.0%
S3_MNAR	15.3%	3.245	3.373	36.8%	71.4%

Sous S3, la part des notes extrêmes passe de **37% dans la base à 71% chez les répondants** : le modèle apprend sur une population qui ne ressemble pas à celle sur laquelle il sera appliqué. Kannan et al. (2022) observent un taux de réponse réel de **2,6 %** : notre 15 % est optimiste.

Repondération par l'inverse de la propension (IPW). La propension à répondre est **estimée** comme un praticien le ferait — logistique P(répondre | covariables) sur les 7 043 clients, hypothèse MAR (poids entre 0.51 et 3.26). Ces poids servent (a) à pondérer la validation croisée pour estimer la performance sur la population entière plutôt que sur les répondants, (b) en test comme poids d'entraînement : kappa 0.384 sans → 0.371 avec, **retenu : sans IPW**. L'effet est faible parce que la propension vraie sous S3 dépend de la satisfaction, que l'estimation MAR ne voit pas : c'est la limite structurelle de l'IPW face au MNAR. Le cadre canonique serait le modèle de sélection de Heckman, qui exige une restriction d'exclusion introuvable ici.


3. Le catalogue — quinze modèles, sept familles, une raison chacun

L'énoncé demande une baseline puis au moins deux familles justifiées ; les quatre études de référence en comparent six à neuf. On ne compare pas des algorithmes pour remplir un tableau : chaque modèle est là pour tester une **hypothèse** sur les données.

Famille	Modèle	Formulation	Pourquoi il est là	Hypothèse testée	Référence
Linéaire	logistique	classification nominale	la baseline exigée par l'énoncé (§ 4.5) ; ses coefficients sont une explication exacte et additive	les frontières entre classes sont proches du linéaire dans l'espace des variables standardisées	Chong et al. 2023 (LR 79,2 % sur ce dataset) ; Kannan et al. 2022
Linéaire	logistique_ordinale	classification ordinale	la formulation ordinale demandée au § 2 : un seul vecteur de coefficients et deux seuils (mord, all-threshold), trois fois moins de paramètres que la multinomiale	l'ordre Détracteur < Passif < Promoteur est porté par une seule direction latente	énoncé § 5 (mord) ; Agresti, Categorical Data Analysis
Régression + seuils	ridge_seuils	régression 1-5 puis seuillage	la troisième formulation de l'énoncé, en version linéaire : régression ridge sur la note 1-5, puis deux seuils optimisés sur le kappa quadratique	la note fine 1-5 contient plus d'information que les trois classes et mérite d'être exploitée à l'entraînement	énoncé § 2 (« regression with thresholding »)
Régression + seuils	hgb_seuils	régression 1-5 puis seuillage	même formulation avec un régresseur non linéaire (gradient boosting d'histogrammes)	la relation variables → note comporte des interactions qu'un modèle linéaire ne capte pas	énoncé § 2
Arbres et bagging	arbre_decision	classification nominale	des règles lisibles par un non-technicien ; le modèle de Kannan et al. et le CART de Mustafa et al. ; témoin de surapprentissage d'un arbre seul	quelques règles contractuelles (contrat, ancienneté, parrainage) suffisent à séparer les classes	Kannan et al. 2022 ; Mustafa et al. 2021
Arbres et bagging	foret_aleatoire	classification nominale	l'ensemble d'arbres « calibré » cité par l'énoncé ; co-premier chez Elero et al. sur une cible NPS à trois classes ; robuste avec peu de réglage	le bagging stabilise les arbres sur un petit échantillon bruité mieux que le boosting ne le fait	Elero et al. 2026 ; Chong et al. 2023
Boosting	hist_gradient_boosting	classification nominale	le boosting natif de scikit-learn, sans dépendance ; premier sur neuf algorithmes chez Elero et al. (modèle 3, trois classes)	des interactions et non-linéarités sont apprenables avec ~1 000 lignes	Elero et al. 2026
Boosting	lightgbm	classification nominale	cité par l'énoncé ; croissance feuille par feuille et régularisation fine (min_child_samples) — le boosting le plus déployé en production tabulaire	même famille que HGB : l'écart entre les deux mesure la variance d'implémentation, pas une différence de méthode	énoncé § 4.5 ; Ke et al. 2017
Boosting	xgboost	classification nominale	cité par l'énoncé ; le boosting de référence de la littérature churn (meilleur modèle chez Chong et al., 79,7 %)	idem LightGBM ; régularisation L2 des feuilles utile sur petit échantillon	Chong et al. 2023 ; Chen & Guestrin 2016
Boosting	catboost	classification nominale	cité par l'énoncé ; encode nativement les catégorielles par statistiques de cible ordonnées — le seul modèle du catalogue qui ne passe pas par le one-hot	le one-hot fait perdre de l'information sur Offer, Contract, Payment Method ; un encodage cible ordonné fait mieux sur petit échantillon	énoncé § 4.5 ; Prokhorenkova et al. 2018
Boosting	adaboost	classification nominale	le boosting historique ; meilleur modèle chez Lalwani et al. (81,7 %, cité par Chong) ; teste un boosting d'arbres courts	repondérer les erreurs suffit, sans gradient ni régularisation	Chong et al. 2023 (revue) ; Elero et al. 2026
Voisinage et noyaux	knn	classification nominale	présent dans les quatre études de référence ; « les clients qui se ressemblent se notent pareil » ; standardisé, sinon dominé par les montants	la structure locale (voisinage) porte l'information ; si KNN égale les arbres, des « jumeaux » existent dans les données — signal de fuite	Chong et al. 2023 ; Elero et al. 2026 ; Mustafa et al. 2021
Voisinage et noyaux	svm_rbf	classification nominale	noyau gaussien, marge maximale ; présent chez Elero, Chong, Mustafa ; probabilités par Platt interne	la marge maximale est plus robuste au bruit d'étiquettes que les modèles qui ajustent chaque point	Elero et al. 2026 ; Chong et al. 2023
Réseau de neurones	mlp	classification nominale	le meilleur modèle de Kannan et al. (F 0,876) et l'ANN d'Elero et al. ; deux couches, arrêt précoce	une représentation apprise bat les variables construites à la main — attendu faux sur ~1 000 lignes, inclus pour trancher, pas pour décorer	Kannan et al. 2022 ; Elero et al. 2026
Probabiliste	naive_bayes	classification nominale	le GaussianNB de Mustafa et al. ; coût nul ; témoin bas	l'indépendance conditionnelle des variables — fausse ici (colinéarité mesurée en phase 3), ce qui rend sa contre-performance informative	Mustafa et al. 2021

Réglages par défaut : pondération de classes `balanced` partout (ou `sample_weight` équivalent) ; préparation adaptée à chaque famille (phase 3 § 5). **Écartés avec argument** : CORAL / CORN (apprentissage profond ordinal, sans objet sur ~1 000 lignes) ; les modèles de fondation sont évalués à part (§ 8) car ils ne s'entraînent pas au sens classique.

4. La grille : 3 scénarios × 3 mappings × 15 modèles



Effet du mapping (scénario réaliste S3, kappa sur les silencieux) :

Famille	Modèle	M1	M2	M3
Arbres et bagging	arbre_decision	0.203	0.316	0.324
Arbres et bagging	foret_aleatoire	0.221	0.320	0.357
Boosting	adaboost	0.209	0.325	0.341
Boosting	catboost	0.219	0.330	0.366
Boosting	hist_gradient_boosting	0.219	0.302	0.343
Boosting	lightgbm	0.227	0.317	0.358
Boosting	xgboost	0.233	0.326	0.373
Linéaire	logistique	0.230	0.344	0.370
Linéaire	logistique_ordinale	0.247	0.351	0.376
Probabiliste	naive_bayes	0.196	0.316	0.320
Régression + seuils	hgb_seuils	0.252	0.353	0.365
Régression + seuils	ridge_seuils	0.212	0.342	0.387
Réseau de neurones	mlp	0.177	0.291	0.329
Voisinage et noyaux	knn	0.190	0.269	0.291
Voisinage et noyaux	svm_rbf	0.210	0.319	0.342

Effet du biais de non-réponse (cible M3) :

Modèle	S1_MCAR	S2_MAR	S3_MNAR	Chute S1→S3
arbre_decision	0.339	0.370	0.324	-0.016
foret_aleatoire	0.397	0.405	0.357	-0.040
adaboost	0.401	0.392	0.341	-0.060
catboost	0.406	0.401	0.366	-0.039
hist_gradient_boosting	0.329	0.322	0.343	+0.014
lightgbm	0.358	0.352	0.358	-0.000
xgboost	0.391	0.388	0.373	-0.019
logistique	0.416	0.409	0.370	-0.046
logistique_ordinale	0.407	0.402	0.376	-0.030
naive_bayes	0.354	0.355	0.320	-0.035
hgb_seuils	0.369	0.367	0.365	-0.004
ridge_seuils	0.404	0.410	0.387	-0.016
mlp	0.324	0.332	0.329	+0.005
knn	0.322	0.321	0.291	-0.031
svm_rbf	0.383	0.380	0.342	-0.041

Deux lectures. **M3 domine M1 et M2 pour toutes les familles** : la cible arbitrée par les données est aussi la plus apprenable. **La performance chute de S1 à S3** pour presque tous les modèles : c'est le coût mesuré du biais de non-réponse — le résultat scientifique du protocole.


5. Porte de contrôle : y a-t-il une fuite ?

Diagnostic	Valeur	Seuil	Verdict
Exactitude maximale observée (toute la grille)	0.655	0,85 (littérature : Elero 0,77 ; Chong 0,80)	✅ dans la fourchette honnête
Écart arbres – linéaire (S1, M3)	-0.012	+0,30 (signature Mustafa et al.)	✅ aucun écart suspect

Un troisième indice, qualitatif : le KNN — qui détecterait des « jumeaux » — est parmi les plus faibles. Aucune fuite.


6. Réglage et sélection — sans regarder le jeu de test

6.1 Hyperparamètres. Recherche aléatoire (`RandomizedSearchCV`, 5 plis stratifiés sur les répondants, score = kappa quadratique), espaces modestes à dessin : sur ~1 000 lignes, le risque de surajuster la recherche dépasse vite le gain. La version réglée n'est retenue que si elle gagne plus de 0,005 de kappa **en validation croisée pondérée** — jamais sur les silencieux.



Modèle	Famille	Configurations	Kappa CV IPW défaut	Kappa CV IPW réglé	Gain CV	Silencieux défaut	Silencieux réglé	Version retenue	Meilleurs paramètres
logistique	Linéaire	12	0.546	0.573	+0.027	0.370	0.371	réglée	C=0.09006280202112786
logistique_ordinale	Linéaire	12	0.587	0.597	+0.010	0.376	0.384	réglée	alpha=7.305271542664457
ridge_seuils	Régression + seuils	—	0.621			0.387		par défaut (pas d'espace de réglage)	—
hgb_seuils	Régression + seuils	—	0.581			0.365		par défaut (pas d'espace de réglage)	—
arbre_decision	Arbres et bagging	12	0.486	0.516	+0.030	0.324	0.341	réglée	min_samples_leaf=20.0, max_depth=3.0
foret_aleatoire	Arbres et bagging	10	0.578	0.589	+0.011	0.357	0.362	réglée	n_estimators=600.0, min_samples_leaf=5.0, max_features=0.5, max_depth=10.0
hist_gradient_boosting	Boosting	12	0.569	0.592	+0.024	0.343	0.369	réglée	min_samples_leaf=20.0, max_leaf_nodes=15.0, max_iter=100.0, learning_rate=0.03, l2_regularization=0.5
lightgbm	Boosting	12	0.571	0.605	+0.034	0.358	0.375	réglée	reg_lambda=0.0, num_leaves=7.0, n_estimators=400.0, min_child_samples=20.0, learning_rate=0.02
xgboost	Boosting	12	0.594	0.598	+0.004	0.373	0.366	par défaut	reg_lambda=5.0, n_estimators=400.0, min_child_weight=5.0, max_depth=6.0, learning_rate=0.05
catboost	Boosting	6	0.597	0.616	+0.020	0.366	0.366	réglée	learning_rate=0.06, l2_leaf_reg=3.0, iterations=400.0, depth=4.0
adaboost	Boosting	8	0.521	0.537	+0.017	0.341	0.341	réglée	n_estimators=200.0, learning_rate=1.0
knn	Voisinage et noyaux	8	0.468	0.487	+0.019	0.291	0.295	réglée	weights=distance, n_neighbors=101.0
svm_rbf	Voisinage et noyaux	8	0.539	0.560	+0.021	0.342	0.347	réglée	gamma=0.03, C=3.0
mlp	Réseau de neurones	8	0.539	0.611	+0.072	0.329	0.354	réglée	learning_rate_init=0.003, hidden_layer_sizes=(64,), alpha=0.0001
naive_bayes	Probabiliste	—	0.525			0.320		par défaut (pas d'espace de réglage)	—

6.2 Règle de sélection, fixée avant de regarder les résultats. 1. Critère : kappa quadratique en validation croisée sur les répondants, **pondéré IPW** (estimation de la performance sur la population), départage par macro-F1 CV. 2. **Parcimonie** (« one standard error rule », Hastie, Tibshirani & Friedman, ESL § 7.10) : parmi les modèles à moins d'un écart-type (entre plis) du meilleur, le plus simple l'emporte, selon un ordre de simplicité fixé a priori (nombre de paramètres, lisibilité de l'explication). 3. Les 85 % silencieux sont le **test final** : rapportés pour tous, utilisés pour aucun choix.



Rang CV	Modèle	Famille	Formulation	Version	Simplicité	Kappa CV IPW	± (plis)	Macro-F1 CV	Dans la marge	Kappa silencieux	Macro-F1 sil.	Rappel Dét. sil.	Rappel Passif sil.	Rang silencieux
1	ridge_seuils	Régression + seuils	régression 1-5 puis seuillage	par défaut (pas d'espace de réglage)	2	0.621	0.035	0.534	✓	0.387	0.478	0.572	0.344	1
2	catboost	Boosting	classification nominale	réglée	5	0.616	0.053	0.603	✓	0.366	0.440	0.833	0.135	7
3	mlp	Réseau de neurones	classification nominale	réglée	6	0.611	0.063	0.529	✓	0.354	0.370	0.743	0.000	10
4	lightgbm	Boosting	classification nominale	réglée	5	0.605	0.057	0.585	✓	0.375	0.464	0.820	0.188	3
5	logistique_ordinale	Linéaire	classification ordinale	réglée	1	0.597	0.037	0.514	✓	0.384	0.490	0.629	0.481	2
6	xgboost	Boosting	classification nominale	par défaut	5	0.594	0.054	0.563	✓	0.373	0.427	0.805	0.099	4
7	hist_gradient_boosting	Boosting	classification nominale	réglée	5	0.592	0.050	0.576	✓	0.369	0.447	0.816	0.156	6
8	foret_aleatoire	Arbres et bagging	classification nominale	réglée	4	0.589	0.054	0.574	✓	0.362	0.420	0.835	0.091	9
9	hgb_seuils	Régression + seuils	régression 1-5 puis seuillage	par défaut (pas d'espace de réglage)	4	0.581	0.049	0.534		0.365	0.446	0.651	0.183	8
10	logistique	Linéaire	classification nominale	réglée	1	0.573	0.038	0.562		0.371	0.498	0.805	0.326	5
11	svm_rbf	Voisinage et noyaux	classification nominale	réglée	5	0.560	0.036	0.570		0.347	0.447	0.806	0.177	11
12	adaboost	Boosting	classification nominale	réglée	4	0.537	0.037	0.576		0.341	0.466	0.823	0.246	12
13	naive_bayes	Probabiliste	classification nominale	par défaut (pas d'espace de réglage)	1	0.525	0.034	0.508		0.320	0.477	0.818	0.399	14
14	arbre_decision	Arbres et bagging	classification nominale	réglée	2	0.516	0.054	0.574		0.341	0.466	0.823	0.246	13
15	knn	Voisinage et noyaux	classification nominale	réglée	3	0.487	0.016	0.490		0.295	0.345	0.778	0.000	15

6.3 Ce que le tableau dit. - Meilleur kappa CV brut : **ridge seuils** (0.621). Dans la marge de parcimonie (≥ 0.586) : ridge seuils, catboost, mlp, lightgbm, logistique ordinale, xgboost, hist gradient boosting, foret aleatoire. **Retenu : logistique ordinale** (réglée), le plus simple de la marge. - Corrélation de rang entre ce que la CV promet et ce que les silencieux donnent : $\rho = \mathbf{0.79}$ (0.79 sans pondération IPW). La CV sur les répondants classe correctement les modèles malgré le biais. - Meilleur sur les silencieux : **ridge seuils** (0.387) ; le modèle retenu fait 0.384 (rang 2 sur 15). L'écart (-0.003) est le prix d'une sélection honnête ; choisir a posteriori serait choisir sur le test. - Pour le modèle retenu, la CV promet 0.610 et les silencieux donnent 0.384 : **+0.238**. En production, personne ne verrait cet écart. C'est la quantité à retenir de toute la phase. - **Ce que les quinze modèles apprennent sur les données** : tous les kappas sur les silencieux tiennent dans une bande étroite (0.30–0.39). Le plafond n'est pas algorithmique, il est dans le signal : ~1 000 répondants biaisés et une cible bruitée. Changer de modèle rapporte moins que corriger le biais de réponse (groupe de contrôle, vraies réponses de la population cible, phase 6).

7. Calibration des probabilités

Les probabilités servent à prioriser des appels : un modèle mal calibré fait mal allouer le budget. Deux méthodes testées (isotonique, Platt). Résultat sur le modèle retenu, classe Détracteur :

	Brier	ECE	Rappel Passif
Non calibré	0.143	0.131	0.48
Calibré (Platt, 3 plis)	0.148	0.147	0.00

La calibration écrase la classe Passif (rappel < 0,05) : sous MNAR, les Passifs sont rares parmi les répondants et le calibrateur, ajusté sur peu de lignes, ne prédit plus jamais la classe intermédiaire. **Décision — stratégie hybride** : la **classe** vient du modèle non calibré ; la **probabilité de détraction**, seule utilisée pour classer les appels, vient du modèle calibré. Vérifié par test automatisé (aucune classe sous 0,05 de rappel). La courbe de fiabilité et sa lecture sont en phase 5 § 2.

8. Modèles de fondation tabulaires (bonus § 4.5)

Consigne de l'énoncé : « *do not frame it as the winner if it is not* ». Même découpage S3/M3, mêmes features préparées que la logistique, CPU.

Modèle	Version	Kappa	Macro-F1	Rappel Dét.	Rappel Passif	Ajustement (s)	Inférence (s)	ms / client	Statut
TabICL	?	0.379	0.377	0.789	0.000	5.6	206.48	34.63	évalué
TabPFN	9.0.0								indisponible — dépôt Hugging Face à accès contrôlé (gated) : l'acceptation des conditions d'utilisation e...
logistique ordinaire (retenu)		0.384	0.490	0.629			0.18		référence
lightgbm (meilleur boosting)		0.375	0.464						référence

- **TabICL** ne bat pas le modèle retenu (kappa 0.379 contre 0.384), pour une inférence 1173× plus lente (34.6 ms par client, CPU) et sans explication native.
- **TabPFN** n'a pas pu être évalué : dépôt Hugging Face à accès contrôlé (gated) : l'acceptation des conditions d'utilisation et huggingface-cli login sont requis pour télécharger les poids — OSE

Avantages : aucun réglage, aucun entraînement au sens classique (apprentissage en contexte), performance d'emblée au niveau des meilleurs modèles réglés sur un petit jeu comme celui-ci. **Limites** : latence d'inférence de deux à trois ordres de grandeur supérieure (le jeu d'entraînement est rejoué à chaque prédiction), empreinte mémoire, pas de coefficients ni de SHAP natif (explication par permutation, coûteuse), dépendance à des poids externes (TabPFN-2.5 : dépôt à accès contrôlé), domaine de validité borné (~50 000 lignes, ~2 000 features pour TabPFN-2.5). **Compromis** : pour un scoring mensuel de 7 000 clients, la latence est acceptable ; pour l'application interactive et pour l'explication client par client, le modèle retenu reste préférable.

9. Verbatims synthétiques et fusion texte (bonus § 4.4)

Génération. 7043 notes de dernier contact, une par client, source `gabarit_stochastique_seed`. Sans clé API dans l'environnement, le générateur local à gabarits stochastiques a été utilisé : fragments rédigés par un LLM (Claude), assemblage seedé (seed 42) — donc strictement reproductible. Le chemin API est prêt (`src/verbatim.py` : détection de `ANTHROPIC_API_KEY`, appels par lots à `claude-opus-5` avec reprise, prompt versionné `prompts/verbatim_v1.txt`, même schéma de sortie ; la colonne `source` dit lequel des deux a produit chaque ligne). Conditionnement : tonalité tirée de la classe M3 avec **25 % de bruit** et cas contre-intuitifs, ancrage sur contrat, ancienneté, internet, offre, parrainages, facture. Concordance tonalité / classe observée : **83.2%** (plafond théorique 83.3%).

Représentation et fusion. TF-IDF (1-2 grammes) + logistique pour le texte seul ; fusion tardive (moyenne pondérée des probabilités, poids choisi par validation croisée sur les répondants) et fusion précoce (SVD à 20 composantes du TF-IDF concaténée aux features tabulaires). Des plongements de phrases (sentence-transformers) ou une classification zero-shot par LLM sont possibles mais n'ont pas été retenus : sur du texte synthétique fabriqué à partir de la classe, ils ne mesureraient rien de plus.

Configuration	Kappa	Macro-F1	Rappel Détracteur
Tabulaire seul (référence)	0.384	0.490	0.629
Texte seul (TF-IDF 1-2 grammes + logistique)	0.381	0.481	0.622
Fusion tardive (poids texte 0.2, choisi par CV)	0.387	0.379	0.787
Fusion précoce (tabulaire + SVD 20 du TF-IDF)	0.417	0.513	0.800

Ce que le texte apporte — et pourquoi le chiffre ne prouve rien. Le texte encode la classe par construction (tonalité tirée de la classe, bruit 25 %). Tout gain est un artefact du protocole de génération : il valide la chaîne, pas la valeur de vrais verbatims. Le dispositif démontre que la chaîne texte → fusion fonctionne ; il ne dit rien de la valeur de vrais verbatims, qui pourraient être bien plus riches (incidents non enregistrés) ou bien plus pauvres (notes laconiques). C'est le « *spot when the added complexity is not worth it* » de l'énoncé : **pas de composante texte en production sur la base de cette seule expérience** ; l'application la montre en démonstration, avec l'avertissement.

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Trois formulations instanciées, arbitrées par la mesure	l'énoncé demande une justification, pas un a priori	§ 1
Découpage 15/85 par propension simulée, MNAR retenu	les répondants ne sont pas aléatoires ; le coût du biais est mesuré	§ 2, tests du protocole
IPW estimée sous MAR, effet mesuré	ce qu'un praticien peut faire ; limite face au MNAR explicitée	§ 2
Quinze modèles, sept familles, une hypothèse chacun	au-delà du minimum de l'énoncé ; alignés sur les quatre études de référence	§ 3
Sélection par CV sur les répondants, pondérée IPW, avec parcimonie	les silencieux sont le test : les utiliser pour choisir serait une fuite de sélection	§ 6
Retenu : logistique ordinaire (réglée)	le plus simple des modèles à moins d'un écart-type du meilleur kappa CV	§ 6.3
Stratégie de décision hybride si la calibration écrase une classe	vérifié, pas supposé ; test automatisé	§ 7
Modèles de fondation et texte : évalués, non retenus en production	consigne d'honnêteté de l'énoncé ; gain texte artificiel par construction	§ 8, § 9

Phase 5 — Évaluation

En bref. Le modèle retenu (logistique ordinaire, réglée) atteint un kappa quadratique de **0.384** sur les 5963 clients silencieux, rappelle **63%** des détracteurs et garde les trois classes vivantes. Sur 500 appels, **51%** touchent un vrai détracteur contre 18% au hasard (lift $\times 2.8$) — 18 585 € de gain net par campagne à hypothèses constantes. Le NPS des silencieux est estimé à **+4** (IC 95 % +2 à +5) pour une vérité de +20. Les drivers sont contractuels (engagement, ancienneté, parrainage, prix) et stables quel que soit le mapping. Le modèle rappelle moins bien les jeunes détracteurs (48% vs 73% pour les 60+) alors qu'il n'a aucune variable d'âge : les features retenues **reconstruisent** l'âge (AUC 0.92). Une mitigation par seuils est chiffrée ; l'arbitrage est remonté au métier.

1. Évaluation technique — jamais une métrique globale sans son détail par classe



Pourquoi ces métriques.

Métrique	Rôle	Pourquoi elle est là
Kappa quadratique pondéré	métrique principale de sélection	cible ordonnée : une erreur de deux crans (Promoteur prédit Détracteur) doit coûter plus qu'une erreur d'un cran ; le kappa quadratique le fait, l'exactitude et le F1 ne le font pas ; corrigé du hasard
Macro-F1	départage	moyenne non pondérée des F1 des trois classes : une classe minoritaire abandonnée fait chuter le score, ce que l'exactitude masque
Exactitude équilibrée	lecture	moyenne des rappels par classe ; même logique que le macro-F1 côté rappel
Rappel / précision / F1 par classe	obligatoire à chaque publication	la règle du projet : le Détracteur est la classe qui compte pour le métier, le Passif celle qu'un modèle abandonne en premier
AUC un-contre-tous et AP (Détracteur)	qualité du classement	l'application classe les clients par P(Détracteur) : l'AUC et l'aire précision-rappel mesurent ce classement indépendamment du seuil ; l'AP est préférée sous déséquilibre
Brier et ECE (Détracteur)	qualité des probabilités	les probabilités servent à allouer un budget d'appels : Brier mesure leur erreur quadratique, l'ECE l'écart entre probabilité annoncée et fréquence observée
Précision@K, rappel@K, lift	métrique métier	la question de l'équipe rétention : « sur les K clients qu'on peut appeler ce mois-ci, combien sont réellement des détracteurs ? »
Exactitude brute	rapportée pour montrer qu'elle trompe	prédire toujours Passif donne ~ 0.43 ; l'énoncé la disqualifie comme critère

Résultat sur les 5963 silencieux (modèle entraîné sur 1080 répondants, S3, cible M3) :


Métrique globale	Valeur
Kappa quadratique pondéré	0.384
Macro-F1	0.490
Exactitude équilibrée	0.511
AUC un-contre-tous (macro) · AUC Détracteur · AP Détracteur	$0.677 \cdot 0.820 \cdot 0.462$
Exactitude brute	0.486 — rapportée pour montrer qu'elle trompe : 0.43 en prédisant toujours « Passif »

Classe	Précision	Rappel	F1	Effectif
Détracteur	0.438	0.629	0.516	1083
Passif	0.473	0.481	0.477	2590
Promoteur	0.547	0.423	0.477	2290



- Le **Détracteur est rappelé à 63%** — c'est la classe qui compte pour le métier. Sa précision est de 44% : le modèle appelle large. C'est le bon arbitrage pour une campagne de rétention où manquer un détracteur coûte plus qu'un appel inutile ; la précision@K en tient compte.
- Le **Passif est la classe la plus difficile** (rappel 48%) : milieu ambigu par définition, rare à l'entraînement (phase 3 § 4). Cohérent avec Elero et al. (2026), où la classe neutre est aussi la moins bien prédite.
- La courbe précision-rappel est plus informative que la ROC sous déséquilibre : le Détracteur a une AP de 0.46 pour un taux de base de 0.18.
- Référence : la baseline logistique fait 0.370 de kappa sur les mêmes silencieux (le modèle retenu est au-dessus).

2. Calibration : ce que la courbe de fiabilité révèle



Les deux courbes sont **sous la diagonale** : le modèle surestime P(Détracteur), calibré ou non (ECE 0.15 après Platt). Cause : le calibrateur est ajusté sur les répondants, où les détracteurs sont sur-représentés par le biais MNAR ; il apprend le taux de base des répondants, pas celui de la population silencieuse. **La calibration sur un échantillon biaisé calibre vers la mauvaise population** — le problème MNAR réapparaît à un autre étage. Conséquence : le **classement** des clients par P(Détracteur) reste valide (l'ordre est préservé, AUC 0.82), mais la **valeur absolue** ne doit pas être lue comme une fréquence — l'application l'affiche. Correction possible en production : recalibrer sur les premières vraies réponses de la population cible (phase 6 § 4).

3. Évaluation métier

La vraie question n'est pas « quel taux de bonnes réponses » mais « **sur les K clients que l'équipe peut appeler ce mois-ci, combien sont réellement des détracteurs ?** »

K appels	Précision@K	Rappel@K	Lift	Détracteurs captés
100	59.0%	5.5%	×3.25	59
250	54.8%	12.7%	×3.02	137
500	51.2%	23.6%	×2.82	256
750	50.0%	34.6%	×2.75	375
1000	48.0%	44.3%	×2.64	480
1500	43.9%	60.9%	×2.42	659
2000	40.6%	74.9%	×2.23	811

Taux de base (part de détracteurs parmi les silencieux) : **18.2%**. À K = 500, **51.2% des clients appelés sont de vrais détracteurs — 2.8× mieux qu'au hasard**.

Traduction en euros. Hypothèses (paramètres dans `config.yaml`, à valider avec l'équipe rétention) : coût d'un appel 12 €, valeur d'un client retenu 450 €, taux de succès 25%.


	Campagne ciblée par le modèle	Campagne aléatoire de même taille
Coût	6 000 €	6 000 €
Clients retenus (estimés)	64.0	—
Gain net	22 800 €	4 215 €
ROI	3.80	—

Apporté par le modèle : 18 585 € par campagne de 500 appels, à hypothèses constantes.

CLTV en couche de décision. Interdite comme feature (sortie de modèle IBM : elle fuit), CLTV est légitime pour pondérer *qui appeler* parmi les détracteurs prédits : c'est un choix métier, pas une information sur la cible. Gómez-Vargas et al. (EJOR 2025) montrent qu'une CLV individuelle bat une CLV moyenne pour cibler une campagne. L'application propose cette pondération en option.

4. Simuler le NPS des 85 % silencieux

Simuler le NPS des 85 % silencieux (§ 2 de l'énoncé)



	NPS
Répondants — ce que l'opérateur observe	+26.9
Silencieux — prédit par le modèle (IC 95 % bootstrap)	+3.6 [+1.6 ; +5.3]
Silencieux — vrai (connu ici seulement)	+20.2
Base complète — prédit	+4.2

Classe	Prédit (silencieux)	Vrai (silencieux)
Détracteur	26.1%	18.2%
Passif	44.2%	43.4%
Promoteur	29.7%	38.4%


Lecture : le modèle sous-estime le NPS des silencieux de 16.6 pts (écart marqué, la vérité est hors de l'intervalle bootstrap : celui-ci ne couvre que l'aléa d'échantillonnage, pas le biais du modèle). Composition par classe : trop de Détracteurs ; trop peu de Promoteurs ; la part de Passifs est juste. Ce sont les conséquences du biais de réponse — le modèle apprend sur des répondants polarisés et une pondération de classes qui rééquilibre le Passif — et le NPS, différence de deux parts, cumule les erreurs sur les Détracteurs et les Promoteurs. À rapporter avec l'intervalle et cette réserve ; la correction passe par les premières vraies réponses de la population cible (phase 6 § 4). **Par segment (silencieux) :**

Segment	Clients	NPS prédit	NPS vrai	Part Dét. prédite	Part Dét. vraie
Contrat mensuel	3087	-40.9	-1.3	49.0%	32.1%
Contrat 1–2 ans	2876	51.5	43.4	1.5%	3.2%
Ancienneté < 12 mois	1815	-36.1	-2.6	49.5%	33.8%
Ancienneté ≥ 24 mois	3266	28.1	32.7	11.3%	9.1%
Fibre	2510	-31.4	2.0	42.7%	27.8%
DSL	1454	4.7	26.1	18.4%	13.3%
Sans internet	1278	80.8	50.9	0.0%	4.5%

Le classement des segments par NPS est respecté (contrats mensuels et clients récents sont bien les plus critiques) ; les niveaux sont exagérés dans les deux sens — effet du biais de réponse sur un modèle qui n'a jamais vu de Passifs en nombre.

5. Robustesse et sensibilité

5.1 Sensibilité au mapping de la cible (énoncé § 4.1). Kappa du modèle retenu sous les trois mappings (S3) : M1 0.247 · M2 0.351 · M3 0.376 — ⚠ non comparables entre eux (déplacer le milieu ambigu change la difficulté). Ce qui se compare, ce sont les **conclusions** : sur les 12 variables les plus influentes (logistique, dont les coefficients sont directement comparables), **10 conservent le même sens d'effet sous les trois mappings**. Les conclusions métier sont robustes au choix du mapping ; c'est l'amplitude qui varie, pas la direction.




5.2 Bruit d'étiquettes (énoncé § 4.1 : « adding realistic noise »). On corrompt une part des étiquettes d'entraînement (classe redistribuée au hasard) et on mesure sur les silencieux, dont les étiquettes restent vraies.

Bruit	Kappa	Macro-F1	Rappel Dét.	Rappel Passif	Rappel Prom.
0%	0.384	0.490	0.629	0.481	0.423
5%	0.377	0.483	0.611	0.525	0.371
10%	0.367	0.477	0.548	0.540	0.375
20%	0.353	0.466	0.497	0.637	0.292
30%	0.277	0.418	0.334	0.747	0.212

Le kappa perd 0.108 entre 0 et 30% de bruit : dégradation graduelle, pas d'effondrement. Un label NPS réel est bruité (humeur du jour, incompréhension de l'échelle) ; ce test borne ce que ça coûte.

5.3 Ablation de features — ce que chaque bloc coûte ou rapporte, modèle retenu, S3/M3, silencieux :




Configuration	Variabes	Kappa	Macro-F1	Rappel Dét.	Rappel Passif	AUC Dét.	Δ kappa
base (retenue)	35	0.384	0.490	0.629	0.481	0.818	+0.000
+ démographie	42	0.393	0.491	0.642	0.471	0.825	+0.009
+ géographie (lat, lon, population)	38	0.382	0.490	0.621	0.479	0.818	-0.002
+ démographie + géographie	45	0.386	0.490	0.639	0.471	0.825	+0.001
- variables dérivées	26	0.367	0.481	0.608	0.481	0.806	-0.017
- parrainage (Number of Referrals, a_parraine)	33	0.357	0.481	0.597	0.501	0.796	-0.027
- Offer et a_recu_offre	33	0.383	0.488	0.629	0.478	0.819	-0.001
- Contract	34	0.357	0.481	0.560	0.501	0.796	-0.027

Trois lectures. **Démographie et géographie** : ajouter la démographie change le kappa de +0.009, la géographie de -0.002, les deux de +0.001 — c'est le **coût mesuré du choix d'équité** (énoncé § 4.7 : « Removing a feature often costs accuracy. Make the trade-off explicit »). Il est assumé : un gain de cet ordre ne justifie pas de décider sur l'âge, le genre ou le code postal, et § 7 montre que le modèle retrouve de toute façon ces attributs par proxies. **Parrainage** : retirer Number of Referrals et a_parraine change le kappa de -0.027 — c'est le driver le plus proche de la cible sans être une fuite (comportement passé observable). **Variables dérivées** : -0.017 — elles portent une part réelle du signal. Retirer Contract : -0.027 ; retirer Offer : -0.001.

6. Drivers de détraction


Méthode : **coefficients × valeur (exact, additif)** — la même dans l'application, pour chaque client. Les contributions sont lues pour la classe Détracteur ; les variables liées par identité comptable (phase 3 § 3.5) se lisent en bloc.



Variable	Importance	Sens (corrélation valeur ↔ contribution)
Number of Referrals	0.5627	-1.00
Monthly Charge	0.5022	+1.00
Contract_Month-to-Month	0.4820	+1.00
a_parraine	0.4668	+1.00
Total Charges	0.4013	-1.00
Online Security_No	0.3932	-1.00
Total Long Distance Charges	0.2833	+1.00
Phone Service_Yes	0.2617	-1.00
Total Revenue	0.2284	-1.00
revenu_par_mois	0.2115	+1.00
Avg Monthly Long Distance Charges	0.2061	-1.00
Internet Service_Yes	0.1904	+1.00
Online Security_Yes	0.1671	+1.00
Contract_Two Year	0.1501	-1.00
Avg Monthly GB Download	0.1485	-1.00
tranche_anciennete_0-6m	0.1436	+1.00
Paperless Billing_Yes	0.1299	+1.00
Streaming Music_No	0.1122	+1.00
Device Protection Plan_No	0.0945	+1.00
Paperless Billing_No	0.0931	-1.00

Ce que le modèle dit. Les associations sont fortes et cohérentes avec la littérature sur ce dataset (Chong et al. 2023) et sur le NPS télécom (Elero et al. 2026) : **contrat sans engagement, faible ancienneté, absence de parrainage, charge mensuelle élevée** vont avec la détraction ; l'offre E ressort comme marqueur de clients déjà fragiles (phase 2 § 5.5), pas comme cause. **Le modèle établit des associations, pas des causes** : un coefficient positif est un signal, pas un levier prouvé.

Drivers par segment (énoncé § 4.6) — les mêmes variables ne pèsent pas partout pareil :



Segment	Clients	Driver 1	Driver 2	Driver 3	Driver 4	Driver 5
Contrat mensuel	3087	Contract_Month-to-Month (▲ risque)	Number of Referrals (▲ risque)	a_parraine (▼ risque)	Online Security_No (▼ risque)	Monthly Charge (▼ risque)
Contrat 1–2 ans	2876	Number of Referrals (▼ risque)	Monthly Charge (▼ risque)	a_parraine (▲ risque)	Total Charges (▼ risque)	Online Security_No (▼ risque)
Ancienneté < 12 mois	1815	Contract_Month-to-Month (▲ risque)	Online Security_No (▼ risque)	Number of Referrals (▲ risque)	tranche_anciennete_0-6m (▲ risque)	Total Charges (▲ risque)
Ancienneté ≥ 24 mois	3266	Number of Referrals (▼ risque)	Monthly Charge (▲ risque)	a_parraine (▲ risque)	Total Charges (▼ risque)	Online Security_No (▼ risque)
Fibre	2510	Contract_Month-to-Month (▲ risque)	Number of Referrals (▲ risque)	Monthly Charge (▲ risque)	a_parraine (▼ risque)	Total Charges (▼ risque)
DSL	1454	Number of Referrals (▼ risque)	a_parraine (▼ risque)	Contract_Month-to-Month (▲ risque)	Total Charges (▲ risque)	Monthly Charge (▼ risque)

Actionnable ou non, et levier :

Driver	Actionnable ?	Levier
Contrat mensuel	oui	proposer un engagement 12 mois avec avantage
Faible ancienneté	partiellement	parcours d'accueil renforcé les 6 premiers mois
Charge mensuelle / par service élevée	oui	revue tarifaire, bundle
Absence de parrainage	indirectement	programme de parrainage
Offre E reçue	signal, pas levier	ne pas « supprimer l'offre E » — comprendre à qui elle a été proposée
Type d'accès (fibre)	non à court terme	investissement réseau, support premium

Règle de recommandation individuelle (implémentée, affichée pour chaque client) : - 1. contrat mensuel → proposer un engagement 12 mois avec avantage - 2. sinon charge par service > médiane → revue tarifaire / bundle - 3. sinon ancienneté < 12 mois → parcours d'accueil renforcé - 4. sinon internet sans support premium → proposer le support technique premium - 5. sinon → appel de courtoisie et diagnostic


Répartition parmi les détracteurs prédits :

Levier recommandé	Détracteurs prédits concernés
Proposer un engagement 12 mois avec avantage	1513
Revue tarifaire / bundle (charge par service élevée)	17
Proposer le support technique premium	13
Appel de courtoisie et diagnostic	12
Parcours d'accueil renforcé (client récent)	1

heuristicque dérivée des drivers (associations), pas d'un effet causal mesuré.

7. Équité et biais (énoncé § 4.7)

Les variables démographiques et géographiques sont **exclues du modèle** et servent **uniquement ici**. On mesure, par sous-groupe, le rappel Détracteur (le modèle rate-t-il davantage certains détracteurs ?), la précision, et le **taux de sélection** (quelle part du groupe est prédite détracteur — c'est ce qui alloue le budget d'appels). zone = tertiles de population du code postal (proxy de densité).




Dimension	Groupe	Clients	Détracteurs réels	Taux de sélection	Rappel Dét.	Précision Dét.
Gender	Female	2939	18.4%	27.1%	64.1%	43.5%
Gender	Male	3024	18.0%	25.2%	61.7%	44.0%
Senior Citizen	No	5019	16.3%	23.9%	58.5%	39.7%
Senior Citizen	Yes	944	28.3%	37.6%	76.4%	57.5%
Married	No	3110	22.4%	31.9%	60.7%	42.7%
Married	Yes	2853	13.5%	19.8%	66.8%	45.7%
Dependents	No	4568	22.3%	30.0%	62.9%	46.7%
Dependents	Yes	1395	4.6%	13.2%	62.5%	21.7%
tranche_age	30-45	1655	16.4%	26.4%	60.5%	37.5%
tranche_age	45-60	1617	17.1%	26.5%	62.0%	40.0%
tranche_age	60+	1397	25.1%	34.1%	73.4%	54.0%
tranche_age	<30	1294	14.4%	16.6%	47.9%	41.4%
zone	densité moyenne	1998	16.1%	25.0%	62.6%	40.3%
zone	faible densité	1982	17.4%	25.0%	63.8%	44.4%
zone	forte densité	1983	21.0%	28.3%	62.4%	46.3%

Dimension	Écart max de rappel (pts)	Écart max de sélection (pts)
Gender	2.4	1.9
Senior Citizen	17.9	13.7
Married	6.2	12.1
Dependents	0.4	16.9
tranche_age	25.6	17.4
zone	1.4	3.4

7.1 Ce qu'on trouve. L'écart le plus important porte sur **tranche_age : 26 points** de rappel entre le groupe le mieux servi et le moins bien servi — le modèle rappelle 48% des détracteurs de moins de 30 ans contre 73% des 60 ans et plus. C'est le cas de figure que l'énoncé décrit comme inacceptable, **en sens inverse** : ce sont les jeunes détracteurs qu'on rate. Les écarts par genre et par densité de zone sont faibles.

7.2 Les features « proxient »-elles les attributs protégés ? Pour chaque attribut exclu, on mesure à quel point les features du modèle permettent de le reconstruire (AUC en validation croisée) :



Attribut (exclu du modèle)	Prévalence	AUC de reconstruction	Lecture
Moins de 30 ans	19.9%	0.920	fortement restructurable
Senior (65+)	15.8%	0.874	fortement restructurable
Femme	49.3%	0.486	non restructurable
Marié(e)	47.9%	0.982	fortement restructurable
A des dépendants	23.4%	0.793	fortement restructurable
Zone de forte densité	33.3%	0.505	non restructurable

Exclure une variable ne suffit pas à ce que le modèle l'ignore. L'âge et la situation familiale sont largement restructurables à partir du contrat, de l'ancienneté, des services et du parrainage ; le genre et la densité de zone ne le sont pas. C'est la raison structurelle de l'écart d'âge : le modèle « voit » l'âge sans en avoir la colonne. L'exclusion reste justifiée (elle empêche une décision *explicite* sur l'attribut et retire le levier le plus direct), mais elle ne dispense pas de l'audit.

7.3 Mitigation testée : un seuil de décision par tranche d'âge, calé pour que chaque groupe atteigne le rappel global (63%). Ce que ça coûte :

Tranche d'âge	Rappel avant	Rappel après	Précision avant	Précision après	Sélection avant	Sélection après	Seuil
30-45	60.5%	63.1%	37.5%	38.3%	26.4%	27.0%	0.5692
45-60	62.0%	63.0%	40.0%	40.6%	26.5%	26.5%	0.5726
60+	73.4%	63.1%	54.0%	54.8%	34.1%	28.8%	0.6132
<30	47.9%	63.4%	41.4%	33.6%	16.6%	27.1%	0.4304

	Kappa	Macro-F1	Rappel Dét.	Précision Dét.	Appels (prédits Détracteur)
Avant	0.384	0.490	0.629	0.438	1556
Après seuils par âge	0.373	0.483	0.629	0.419	1626

Égaliser le rappel se paie en précision chez les jeunes (plus d'appels inutiles) et en volume global. C'est un arbitrage **métier et juridique**, pas technique : traiter différemment selon l'âge pour corriger un écart est légal dans certaines juridictions et pas dans d'autres.

7.4 À remonter avant production. 1. L'écart d'âge (26 pts) et sa cause (proxies) — à l'équipe Expérience Client et au juridique. 2. Le fait que la mitigation par seuils est possible et chiffrée, mais qu'elle constitue un traitement différencié selon l'âge : décision à prendre au-dessus de la data science. 3. L'audit doit être répété à chaque réentraînement — il est dans le monitoring (phase 6 § 4).

8. Limites de la règle de ciblage

Cette étude classe les clients par **risque** d'être détracteur, comme demandé. Or Ascarza (2018, *Journal of Marketing Research*) établit, par deux expériences de terrain, que cibler les clients au risque le plus élevé est inefficace : il faut cibler ceux dont la **sensibilité à l'intervention** est la plus forte — même campagne, même budget, jusqu'à 7 points de churn en moins.

	On l'appelle	On ne l'appelle pas	
	reste	reste	acquis — appel gaspillé
	part	part	perdu d'avance — appel gaspillé
	reste	part	persuadable — seul cas qui crée de la valeur
	part	reste	à ne pas déranger — l'appel nuit

Les détracteurs les plus certains sont massivement des *perdus d'avance*. **On ne peut pas estimer cette sensibilité ici** : aucune campagne enregistrée, aucune assignation aléatoire (la table *offer* prouve que les offres ont été ciblées). Prétendre faire de l'uplift serait la faute reprochée à Mustafa et al. La seule chose à faire, gratuite, est en phase 6 § 5.

9. Revue du processus

Critère de succès (phase 1)	Résultat	Verdict
Précision@500 nettement au-dessus du taux de base	51.2% vs 18.2% (×2.8)	✅
Gain net vs aléatoire, en euros	18 585 € par campagne	✅ (hypothèses à valider)
Kappa et rappel Détracteur au niveau de la baseline ou au-dessus	retenu logistique ordinale : kappa 0.384 ; logistique 0.370	✅
Aucune classe abandonnée	rappel Passif 0.48	✅
Écart d'équité mesuré, signalé si > 10 pts	26 pts sur l'âge, cause identifiée, mitigation chiffrée	⚠️ signalé, arbitrage remonté

Solide : registre de fuites quantifié ; arbitrage empirique des « 3 » sans circularité ; protocole 15/85 avec coût du MNAR mesuré ; quinze modèles, sélection sans regarder le test ; calibration vérifiée ; audit d'équité avec proxies et mitigation. **Approximatif** : hypothèses économiques (placeholders) ; propension à répondre simulée ; verbatims synthétiques sans clé API ; TabPFN non évalué faute d'accès. **Impossible avec ces données** : estimer l'effet d'un appel.

Reproductibilité — test à blanc depuis une copie vierge. Protocole : copie de *src/*, *prompts/*, *config.yaml* et *data/raw/* seuls dans un répertoire vierge, exécution de `python -m src.run`, comparaison des indicateurs clés. Durée : 1336.3 s.

Indicateur	Original	Copie vierge	Identique
NPS M1	-42.0	-42.0	✓
NPS M3	21.3	21.3	✓
part des 3 -> détracteur	0.2788	0.2788	✓
modèle retenu	logistique_ordinale	logistique_ordinale	✓
version retenue	réglée	réglée	✓
kappa final (silencieux)	0.384446	0.384446	✓
macro-F1 final	0.490177	0.490177	✓
précision@K	0.512	0.512	✓
NPS silencieux prédit	3.6	3.6	✓
écart d'équité (âge)	0.2558	0.2558	✓

Reproductible à l'identique.

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Toute métrique globale accompagnée de son détail par classe	règle du projet ; contre-exemple Kannan et al.	§ 1
Probabilités utilisées pour classer, pas pour lire une fréquence	calibrateur ajusté sur une population biaisée	§ 2
K = 500 et hypothèses économiques dans config.yaml	paramètres métier, à valider avec l'équipe	§ 3
NPS des silencieux rapporté avec intervalle et réserve de composition	excès compensés de Détracteurs et Promoteurs	§ 4
Coût de l'exclusion des démographiques et de la géographie chiffré et assumé	énoncé § 4.7 ; proxies mesurés	§ 5-3, § 7.2
Mitigation par seuils d'âge chiffrée, non appliquée par défaut	traitement différencié : décision métier/juridique	§ 7.3
Pas d'uplift modeling	aucune assignation aléatoire ; le prétendre serait une faute	§ 8

Phase 6 — Déploiement

En bref. Le modèle est persisté d'un bloc (préprocessing + modèle + calibrateur) et consommé par une application Streamlit de sept pages pour l'équipe rétention : liste d'appels priorisée, analyse d'un client avec ses drivers et son levier, saisie manuelle tolérante aux inconnus, verbatim en démonstration. Un monitoring implémenté surveille la dérive des entrées et des prédictions, la performance sur les nouvelles réponses d'enquête, et déclenche le réentraînement sur seuil, volume ou échéance. La décision demandée à la direction : **un groupe de contrôle non contacté** à la prochaine campagne.

1. Carte du modèle

Nom	Prédiction de catégorie NPS — clients silencieux
Version	1.1 · seed 42 · régénéré par <code>python -m src.run</code>
Modèle	logistique ordinaire (Linéaire, classification ordinaire), version réglée, dans un <code>Pipeline</code> scikit-learn (imputation + encodage + modèle)
Cible	M3 — Détracteur (satisfaction 1–2) · Passif (3) · Promoteur (4–5)
Données d'entraînement	1080 répondants simulés (S3 — MNAR), IBM Telco 11.1.3+
Évaluation	5963 clients silencieux, vérité connue
Kappa quadratique · macro-F1	0.384 · 0.490
Rappel / précision Détracteur	0.63 / 0.44
Décision	hybride — classe : modèle non calibré (la calibration écrasait la classe Passif) ; P(Détracteur) : modèle calibré (Platt), pour le classement des appels
Explication	coefficients × valeur (exact, additif)
Variables exclues	tout ce qui touche au churn, CLTV, démographie, géographie (phase 2 § 4)
Usage prévu	prioriser une liste d'appels de rétention mensuelle ; comprendre les drivers
Usage interdit	décider d'une offre ou d'un tarif individuel ; toute décision fondée sur un attribut protégé ; lire P(Détracteur) comme une fréquence
Limites connues	écart de rappel de 26 pts entre groupes d'âge (proxies) ; classe Passif mal rappelée ; probabilités surestimées ; propension à répondre simulée
Fichiers	<code>models/modele_final.joblib</code> (pipelines calibré, brut, de décision, métadonnées) · <code>data/processed/clients_scores.parquet</code>

2. L'application — choix de conception (énoncé § 4.8)

`streamlit run app/app.py` · sept pages, adressables par `?page=` · toutes les valeurs sont lues dans les artefacts du pipeline, rien n'est recopié.

Page	Pour qui	Ce qu'elle permet
Synthèse	direction	les cinq chiffres, le NPS des silencieux, les trois résultats, la décision demandée
Prioriser les appels	équipe rétention	liste des silencieux classés par P(Détracteur), filtres, capacité K, pondération CLTV optionnelle, levier recommandé, export CSV
Analyser un client	conseiller	client existant ou saisie manuelle → classe, probabilités, drivers de ce client, levier ; verbatim collé (bonus, démonstration)
Données et cible	data / métier	exploration, qualité, registre de fuites, construction de la cible
Modèles et performance	data	catalogue justifié, grille, CV vs test, réglage, par classe, calibration, robustesse, fondation, texte
Drivers et équité	métier / CX	drivers globaux et par segment, leviers, audit par sous-groupe, proxies, mitigation
Suivi et méthode	data / direction	monitoring, carte du modèle, conformité à l'énoncé, reproductibilité

Pourquoi Streamlit : l'énoncé demande une interface utilisable par un responsable rétention, pas une API ; Streamlit livre une application complète en Python pur, sans front séparé, versionnable avec le pipeline. Une API (FastAPI) serait la brique suivante pour intégrer le score au CRM — hors périmètre.

Robustesse aux entrées (exigence « behave gracefully ») : chaque champ de saisie accepte « (inconnu) » ; le pipeline impute (médiane / mode) et `OneHotEncoder(handle_unknown='ignore')` absorbe toute modalité jamais vue. Testé automatiquement (`test_modele_tolere_entrees_vides_et_modalites_inconnues`).


Ce que l'application dit toujours : les probabilités servent à classer, pas à lire une fréquence ; les drivers sont des associations ; le modèle texte est une démonstration sur du texte synthétique.

Performance : modèle et données chargés une fois (`st.cache_resource`) ; explication d'un client en moins d'une seconde pour les modèles linéaires et à arbres.

3. Reproductibilité et livraison

`python -m src.run` (données → cible → 15 modèles → sélection → évaluation) · `python -m src.fondation_eval` · `python -m src.verbatims` et `python -m src.texte` · `python -m src.monitoring` · `python -m src.rapports` · `python -m src.writeup` · `python -m pytest tests -q`. Seed unique ; aucune clé dans le dépôt (`.env` ignoré, `.env.example` fourni) ; test à blanc depuis une copie vierge (phase 5 § 9).

4. Monitoring et réentraînement (énoncé § 4.9) — implémenté



Référence = population d'entraînement (répondants S3). **Courant** = population scorée. **Mois simulé** = tarif +12 %, 15 % des contrats basculés en mensuel, 10 % migrés vers la fibre.

	PSI des prédictions	Part de détracteurs prédits
Courant vs référence	0.025	31.4% (réf. 32.9%)
Mois simulé vs référence	0.054	36.4%

Variables les plus dérivantes — courant :


Variable	PSI	Statut
Total Charges	0.0482	stable
Total Revenue	0.0443	stable
Monthly Charge	0.0414	stable
Tenure in Months	0.0396	stable
Total Long Distance Charges	0.0385	stable
nb_services	0.0357	stable
Internet Type	0.0313	stable
tranche_anciennete	0.0301	stable

Variables les plus dérivantes — mois simulé :

Variable	PSI	Statut
Monthly Charge	1.3813	ALERTE
charge_par_service	0.6490	ALERTE
Total Charges	0.0482	stable
Contract	0.0475	stable
Total Revenue	0.0443	stable
Tenure in Months	0.0396	stable
Total Long Distance Charges	0.0385	stable
nb_services	0.0357	stable

Déclencheur de dérive sur le mois simulé : DÉCLENCHÉ (variables en alerte : Monthly Charge, charge_par_service). Le mécanisme détecte une hausse tarifaire et une migration de contrats que personne n'aurait signalées au modèle. Note : le PSI « courant » n'est pas nul alors que les deux populations viennent de la même base — c'est le **biais de sélection S3** qui s'affiche, et c'est exactement ce que le monitoring doit voir.

Performance sur les nouvelles réponses d'enquête (simulation : ~150 réponses par mois, tirées parmi les silencieux selon la propension biaisée S3) :



Mois	Nouvelles réponses	Cumul	Kappa (lot)	Rappel Dét. (lot)	Kappa (cumul)	Rappel Dét. (cumul)	Chute	Volume atteint
1	150	150	0.510	0.583	0.510	0.583		
2	150	300	0.556	0.622	0.534	0.602		
3	150	450	0.523	0.595	0.531	0.600		
4	150	600	0.600	0.641	0.549	0.612		✓
5	150	750	0.451	0.476	0.530	0.587		✓
6	150	900	0.420	0.609	0.513	0.591		✓

Référence : kappa 0.384, rappel 0.629. Seuils : chute de kappa > 0.05, chute de rappel

0.1, volume minimal 500 nouveaux labels (atteint au mois 4), échéance 6 mois. Chute détectée sur la simulation : non. réponses tirées parmi les silencieux selon la propension S3 (les extrêmes répondent plus) : la performance sur les nouveaux répondants est donc optimiste par rapport à la base — exactement le biais que le monitoring réel subira.

Ce qu'on surveille, et quand on réentraîne :

Signal	Mesure	Déclencheur
Dérive des entrées	PSI par variable, mensuel, vs population d'entraînement	PSI > 0,20 sur une variable majeure (Contract, Tenure, Monthly Charge)
Dérive des prédictions	PSI de P(Détracteur) ; part de Détracteurs prédits	PSI > 0,20 ou variation > 5 points sans cause métier connue
Performance réelle	kappa et rappel Détracteur sur les nouvelles réponses d'enquête	chute > 0,05 de kappa ou > 10 points de rappel
Équité	rappel Détracteur par tranche d'âge sur les nouvelles réponses	écart > 15 points
Volume de labels	nouvelles réponses reçues	réentraînement dès 500 nouveaux labels, au plus tard tous les 6 mois
Calibration	ECE sur les nouvelles réponses	recalibrer (Platt) sur les vraies réponses de la population cible dès 300 labels

Outil recommandé en production : Evidently (rapports HTML autonomes), cité par l'énoncé ; ici le PSI est implémenté directement pour rester sans dépendance.

5. La boucle de rétroaction — et la décision demandée

Un détracteur appelé puis retenu **change de classe**. Si on réentraîne sur ces données, le modèle apprend l'effet de sa propre intervention comme s'il s'agissait d'une propriété du client. Il se dégrade, et personne ne voit pourquoi. Trois parades, par ordre de coût :

1. **Journaliser chaque contact** (qui, quand, quel levier, quelle issue) et exclure du réentraînement les réponses postérieures à un contact, ou les traiter comme une strate séparée.
2. **Ne pas contacter 10 à 20 % des clients ciblés, tirés au hasard**, à chaque campagne. Ce groupe de contrôle coûte quelques clients non retenus et achète deux choses irremplaçables : la mesure de l'effet réel de la campagne, et les données d'un modèle d'**uplift** au cycle suivant — passer du ciblage par *risque* (cette étude) au ciblage par *sensibilité* (Ascarza 2018).
3. À terme, réentraîner sur les non-contactés et les contrôles seulement.

La décision demandée à la direction : autoriser le groupe de contrôle dès la prochaine campagne. C'est le seul passage de l'étude qui demande une décision plutôt que de présenter un résultat.

Décisions prises dans cette phase

Décision	Justification	Où c'est vérifié
Persistance d'un bloc : pipelines calibré, brut, de décision + métadonnées	rejouable sans réentraînement ; l'application n'a aucune logique de préparation	§ 1, models/modele_final.joblib
Streamlit, sept pages, contenu lu dans les artefacts	interface pour un responsable rétention ; aucune valeur recopiée	§ 2
Tolérance aux inconnus par le pipeline, pas par l'interface	un seul endroit à tester	§ 2, test dédié
Monitoring : PSI + performance sur nouvelles réponses + volume + échéance	les quatre déclencheurs de l'énoncé	§ 4
Groupe de contrôle recommandé	seule façon de mesurer l'effet et d'éviter la boucle de rétroaction	§ 5

Conformité à l'énoncé — chaque exigence, où elle est traitée

Relecture complète de l'énoncé (« Take-Home Challenge — Customer NPS Prediction for a Telecom Operator ») ; une ligne par exigence ou bonus.  traité ·  traité partiellement, raison indiquée.

Énoncé	Exigence	Réponse	Où	Statut
§ 2	Prioriser les appels vers les Détracteurs prédits	liste classée par P(Détracteur) calibrée, K réglable, export	phase 5 § 3 ; app <i>Prioriser les appels</i>	✓
§ 2	Drivers de détraction, individuels et par segment	contributions par client ; drivers par segment ; leviers	phase 5 § 6 ; app <i>Drivers et équité, Analyser un client</i>	✓
§ 2	Simuler le NPS des 85 % silencieux	NPS prédit avec IC bootstrap, vs répondants et vs vérité ; par segment	phase 5 § 4 ; app <i>Synthèse</i>	✓
§ 2	Formulation : classification / ordinale / régression + seuils, justifiée	les trois instanciées et comparées par la mesure	phase 4 § 1	✓
§ 3	IBM Telco 11.1.3+ comme source	cinq tables, jointure contrôlée	phase 2 § 1	✓
§ 3	Enrichissement externe justifié si utilisé	décision motivée de ne pas enrichir	phase 2 § 6	✓
§ 4.1	Mapping satisfaction → NPS justifié, raffiné, sensibilité discutée	M1/M2/M3, arbitrage empirique, sensibilité des drivers	phase 3 § 1 ; phase 5 § 5.1	✓
§ 4.1	Bruit réaliste	test de robustesse au bruit d'étiquettes 0–30 %	phase 5 § 5.2	✓
§ 4.1	Fuites dans la cible : Churn Score, Churn Value	registre de fuites en trois natures, information mutuelle, exclusion, test	phase 2 § 4	✓
§ 4.2	Schéma documenté (gardé / supprimé / transformé)	dictionnaire avec statut par colonne	phase 2 § 2 ; phase 3 § 3	✓
§ 4.2	Manquants et incohérences traités de façon transparente	cinq contrôles qualité	phase 2 § 3	✓
§ 4.2	Découpage reflétant 15 % répondants / 85 % silencieux, stratégie de validation	trois scénarios de non-réponse, MNAR retenu, CV sur les répondants	phase 4 § 2, § 6	✓
§ 4.2	Déséquilibre des classes discuté explicitement	double déséquilibre ; cinq stratégies comparées	phase 3 § 4	✓
§ 4.3	Features construites et justifiées ; fuites évitées	justification variable par variable ; neuf dérivées ; auto-pay	phase 3 § 3	✓
§ 4.3	Features géographiques / démographiques	testées en ablation, exclues par équité, coût chiffré	phase 5 § 5.3	✓
§ 4.4	Verbatims synthétiques par LLM, conditionnés, bruités, reproductibles, commités	7 043 verbatims, source <code>gabarit_stochastique_seed</code> ; chemin API prêt ; prompt versionné	phase 4 § 9 ; <code>data/processed/verbatim.parquet</code>	✓ (générateur local seedé ; API sans clé)
§ 4.4	Combiner texte et tabulaire, expliquer ce que le texte apporte	texte seul, fusion tardive, fusion précoce ; gain qualifié d'artificiel	phase 4 § 9 ; app <i>Analyser un client</i>	✓
§ 4.5	Baseline	logistique multinomiale pondérée	phase 4 § 3	✓
§ 4.5	Au moins deux familles justifiées (boosting, ordinal, ensembles calibrés, fondation)	quinze modèles, sept familles ; XGBoost, LightGBM, CatBoost, mord, forêt, TabICL	phase 4 § 3, § 8	✓
§ 4.5	Métriques adaptées : macro-F1, balanced accuracy, kappa, rappel par classe, calibration, lift	toutes, avec la raison de chacune	phase 5 § 1–3	✓
§ 4.5	Validation simulant l'écart répondants / silencieux	S3 MNAR ; sélection sans regarder les silencieux	phase 4 § 2, § 6	✓
§ 4.5	Interprétabilité : importance / SHAP, drivers	coefficients ou SHAP selon le modèle ; méthode unique app + étude	phase 5 § 6	✓
§ 4.5	Discussion fuites, biais, bruit, qualité, limites du label	réparties et récapitulées	phases 2, 3, 5 § 9	✓
§ 4.5 bonus	Modèle de fondation tabulaire (TabPFN-2.5, TabICL), avantages / limites / coût	TabICL évalué ; TabPFN indisponible (dépôt HF à accès contrôlé)	phase 4 § 8	✓
§ 4.6	Drivers par segment ; actionnable vs non ; levier unique par Détracteur prédit ; corrélation ≠ causalité	segments contrat / ancienneté / accès ; règle de levier implémentée	phase 5 § 6	✓
§ 4.7	Audit par sous-groupe démographique, rappel Détracteur	genre, senior, marié, dépendants, âge, densité de zone ; rappel, précision, sélection	phase 5 § 7	✓
§ 4.7	Proxies d'attributs protégés ; gardé / supprimé / pourquoi	audit de reconstruction (AUC) des attributs exclus	phase 5 § 7.2	✓
§ 4.7	Conséquence métier des choix d'équité, arbitrage explicite	coût de l'exclusion chiffré ; mitigation par seuils chiffrée	phase 5 § 5.3, § 7.3	✓
§ 4.7	Points à escalader à CX / juridique	liste explicite	phase 5 § 7.4	✓
§ 4.8	Persistance du modèle	<code>models/modele_final.joblib</code>	phase 6 § 1	✓
§ 4.8	Interface : saisie ou ID → classe + probabilités ; drivers ; verbatim (bonus) ; robuste aux inconnus ; choix expliqués	Streamlit sept pages ; test de robustesse	phase 6 § 2 ; app <code>app.py</code>	✓
§ 4.9	Monitoring : dérive des entrées, des prédictions, performance sur nouvelles réponses	PSI, mois simulé, lots mensuels de nouvelles réponses	phase 6 § 4	✓
§ 4.9	Déclencheur de réentraînement (planning, seuil, volume de labels)	les trois, implémentés	phase 6 § 4	✓
§ 4.9	Boucle de rétroaction actions ↔ données	journalisation, groupe de contrôle, réentraînement sur non-contactés	phase 6 § 5	✓
§ 6	Code source ; notebook ; README + <code>.env.example</code> ; dataset dérivé ; verbatims + script ; artefact modèle ; captures ; write-up 3–6 pages	tous présents	dépôt ; notebooks/ ; livrable/	✓
§ 7	Reproductible ; implémenté / approximatif / futur explicites ; usage d'IA déclaré ; pas de clés	test à blanc réussi ; revue ; README	phase 5 § 9 ; README	✓

Ce qui est implémenté, approximatif, ou laissé en travail futur (énoncé § 7)

Implémenté : tout le périmètre obligatoire (§ 4.1 à § 4.8), le monitoring (§ 4.9), les trois bonus (verbatimims + fusion texte, drivers par segment, modèle de fondation via TabICL).

Approximatif, et dit comme tel : les paramètres économiques (coût d'appel, valeur client, taux de succès) sont des placeholders ; la propension à répondre est simulée ; les verbatims viennent d'un générateur local seedé, pas d'un appel API (aucune clé disponible ; le chemin est prêt) ; le NPS des silencieux est estimé avec une composition par classe déformée.

Travail futur : TabPFN-2.5 dès accès aux poids ; recalibration sur les vraies premières réponses ; groupe de contrôle puis modèle d'uplift ; API de scoring pour le CRM ; enrichissement texte sur de vrais verbatims.