

Prédire la catégorie NPS des clients silencieux

Prioriser la rétention quand 85 % des clients ne répondent pas à l'enquête — take-home challenge, dataset IBM Telco 11.1.3+

Démarche CRISP-DM · 7 043 clients · 15 modèles comparés · application Streamlit · étude reproductible
Soutenance devant jury

Le problème : décider pour 85 % de clients dont on ignore la satisfaction

Trois usages demandés, trois critères de succès chiffrés avant toute ligne de code

RÉPONDENT À L'ENQUÊTE NPS

15 %

et ils ne sont pas un échantillon au hasard

SILENCIEUX À SCORER

5963

sur 7 043 clients

CAPACITÉ D'APPEL

500 / mois

qui appeler en premier ?

CIBLE

3 classes

ordonnées et déséquilibrées

Usage demandé (énoncé § 2)	Critère de succès fixé a priori	Où c'est mesuré
Prioriser les appels vers les détracteurs prédits	précision@500 nettement au-dessus du taux de base ; gain net en euros vs hasard	diapo 14
Identifier les drivers de détraction, individuels et par segment	drivers stables au mapping ; leviers actionnables	diapo 15
Simuler le NPS des 85 % silencieux	estimation avec intervalle, comparée à la vérité connue ici	diapo 14
Équité (§ 4.7)	écart de rappel Détracteur entre groupes mesuré, signalé si > 10 pts	diapo 16

Hypothèse déclarée : la satisfaction 1–5 est un proxy acceptable d'une note NPS 0–10 — Elero et al. (2026) font la même approximation. Cadre : dataset fictif, une photographie, aucune campagne enregistrée → aucun effet causal estimable.

Une démarche CRISP-DM complète, chaque phase fermée par des décisions justifiées

Ce qui a été fait dans chaque phase — et où le jury peut le vérifier

1 · Métier

- 3 usages, critères chiffrés
- cible ordonnée et déséquilibrée
- 3 formulations à arbitrer par la mesure
- registre de risques

2 · Données

- 5 tables, jointure contrôlée
- dictionnaire à statut
- 5 contrôles qualité
- **registre de fuites** en 3 natures, quantifié
- EDA, quasi-expérience Offer

3 · Préparation

- cible : 3 mappings, **arbitrage empirique des « 3 »**
- features justifiées une à une
- colinéarité, déséquilibre (5 stratégies)
- tout dans un Pipeline

4 · Modélisation

- protocole 15/85 **MNAR**
- **15 modèles, 7 familles**
- réglage, **sélection sans regarder le test**
- calibration vérifiée
- TabICL, texte

5 · Évaluation

- par classe, métier, NPS simulé
- robustesse : bruit, ablation, mapping
- drivers globaux et par segment
- **équité, proxies, mitigation**

6 · Déploiement


- modèle persisté, app 8 pages filtrables, image Docker
- monitoring 5 déclencheurs, dont l'équité
- boucle de rétroaction
- reproductibilité, tests
- décision demandée

Gestion du périmètre (énoncé : « scope management more than over-engineering ») : chaque pièce répond à une exigence nommée — matrice de conformité en diapo 21. Quinze modèles ne sont pas une course au score : une comparaison qui établit que le plafond vient du signal, donc que la marche suivante est métier (vraies réponses, groupe de contrôle). Laissé de côté volontairement, et dit : enrichissement externe, deep ordinal, API de scoring, MLflow.

Livrables : étude en 8 documents (dont la **matrice de conformité à l'énoncé**), write-up 6 pages, application, notebook, 30 fonctions de test, test à blanc depuis copie vierge identique sur 10 indicateurs.

Le dataset contient sa propre réponse : toute colonne liée au churn est une fuite


Fait fondateur, trois natures de fuite, exclusion mesurée plutôt qu'affirmée



- Satisfaction 1–2 → **100 % de départs** ; 4–5 → **0 %**.
Connaître le churn, c'est connaître la cible — et au moment de détecter un détracteur, il n'est pas encore parti.
- Trois natures nommées : **conséquence** (Churn Label/Value, Customer Status), **disponibilité** (Churn Category/Reason : vides = restés), **modèle amont** (Churn Score, CLTV — sorties SPSS).
- Après modélisation, deux diagnostics : exactitude max 0.65 (alerte à 0,85) ; écart arbres/linéaire -0.01 (signature d'une fuite : +0,30, Mustafa et al. 2021 : 98 % annoncés avec la note NPS en feature).
- **CLTV** : bannie des features, admise en **couche de décision** pour pondérer qui appeler.

La grille de l'énoncé donne un NPS de -42 ; les données disent +21

Trois mappings, un arbitrage empirique des 2 665 clients « 3 », et un piège de circularité évité



- **M1** (énoncé) envoie 58% de la base chez les détracteurs, dont 2665 clients « 3 ». NPS -42 : à 60–75 pts des benchmarks télécom — signal d'alerte, pas résultat.
- **Arbitrage empirique** (méthode Elero et al.) : modèle entraîné sur les seuls extrêmes 1–2 vs 4–5 (exactitude 80%), appliqué aux « 3 » jamais vus : **72% penchent promoteur** → le bloc va aux Passifs. NPS +21, dans la fourchette sectorielle.
- **Piège évité** : étiqueter chaque « 3 » individuellement rendrait la cible fonction des features — le modèle réapprendrait sa propre sortie. On tranche le bloc ; la probabilité individuelle reste un indicateur métier.
- Refusé : enrichir la cible par Churn Value (churn déguisé) ou l'ancienneté (même circularité).

Chaque variable a une hypothèse ; le déséquilibre est double et traité par pondération

18 numériques + 17 catégorielles ; démographie et géographie hors modèle

Variable dérivée	Hypothèse métier
nb_services	intensité de la relation commerciale : plus de services, plus de raisons de rester — ou de se plaindre
charge_par_service	perception du rapport qualité-prix : ce que coûte chaque service souscrit
tranche_anciennete	l'insatisfaction d'un nouveau client (attentes déçues) n'a pas la même nature que celle d'un ancien (usure)
a_recu_offre	un geste commercial a-t-il été fait ? (indicateur binaire, complémentaire du type d'offre)
a_eu_remboursement	trace d'un incident de facturation reconnu par l'opérateur
a_frais_supplementaires	trace d'un dépassement de forfait — friction tarifaire
revenu_par_mois	intensité économique moyenne de la relation, indépendante de l'ancienneté
a_parraine	proxy comportemental direct de la recommandation, donc du NPS lui-même ; comportement passé observable, pas une conséquence de la note
paiement_automatique	auto-pay (énoncé § 4.3) : un paiement automatisé signale une relation installée et sans friction

Brutes justifiées une à une (contrat, ancienneté, offre, parrainage, prix, usage, bouquet, paiement). Colinéarité : identité comptable des totaux — conservée,


Deux déséquilibres superposés. Base : Passif 38%, Détracteur 20%. Répondants (entraînement, MNAR) : Détracteur 33%, **Passif 7%**. La classe la plus fréquente à l'évaluation est la plus rare à l'entraînement — c'est elle qu'un modèle abandonne.

Stratégie (baseline logistique)	Kappa	Macro-F1	Rappel Dét.	Rappel Passif
aucune (logistique non pondérée)	0.365	0.380	0.76	0.01
pondération de classes 'balanced' (retenue)	0.370	0.497	0.78	0.32
sur-échantillonnage aléatoire	0.372	0.498	0.78	0.33
SMOTE (k=5)	0.357	0.489	0.74	0.32
sous-échantillonnage aléatoire	0.323	0.479	0.69	0.42

Décision : pondération « balanced » partout où l'estimateur l'accepte. SMOTE fabrique des clients dans un espace one-hot sans sens métier, pour aucun gain systématique.

Les répondants ne sont pas un échantillon au hasard : le biais est simulé, et son coût mesuré

Trois mécanismes de non-réponse ; entraînement sur les 15 %, évaluation sur les 85 % dont on connaît la vérité



- Un `train_test_split` stratifié rate l'intention de l'énoncé. On simule la propension à répondre : **MCAR** (hasard), **MAR** (covariables), **MNAR** (dépend de la satisfaction — les mécontents et les enthousiastes répondent plus).
- Sous S3, la part de notes extrêmes passe de **37% à 71%** : le modèle apprend sur une population qui ne ressemble pas à celle qu'il scorera.
- Avantage rare du dataset : la satisfaction des 100 % est connue → on **mesure** ce que le biais coûte, ce qu'aucun praticien ne peut faire en production.
- IPW estimée sous MAR (poids 0.51–3.26) : utilisée pour pondérer la validation croisée ; effet à l'entraînement 0.384 → 0.371. Limite structurelle face au MNAR (Heckman exigerait une restriction d'exclusion).
- Kannan et al. (2022) : taux de réponse réel 2,6 % — notre 15 % est optimiste.

Quinze modèles, sept familles, trois formulations — chacun pour tester une hypothèse

Pas un tableau de leaderboard : chaque modèle est là parce qu'il répond à une question sur les données

logistique

Linéaire · classification nominale
les frontières entre classes sont proches du linéaire dans l'espace des variables standardisées

logistique ordinale

Linéaire · classification ordinale
l'ordre Détracteur < Passif < Promoteur est porté par une seule direction latente

ridge seuils

Régression + seuils · régression 1-5 puis seuillage
la note fine 1-5 contient plus d'information que les trois classes et mérite d'être exploitée à l'entraînement

hgb seuils

Régression + seuils · régression 1-5 puis seuillage
la relation variables → note comporte des interactions qu'un modèle linéaire ne capte pas

arbre decision

Arbres et bagging · classification nominale
quelques règles contractuelles (contrat, ancienneté, parrainage) suffisent à séparer les classes

foret aleatoire

Arbres et bagging · classification nominale
le bagging stabilise les arbres sur un petit échantillon bruité mieux que le boosting ne le fait

hist gradient boosting

Boosting · classification nominale
des interactions et non-linéarités sont apprenables avec ~1 000 lignes

lightgbm

Boosting · classification nominale
même famille que HGB : l'écart entre les deux mesure la variance d'implémentation, pas une différence de métho...

xgboost

Boosting · classification nominale
idem LightGBM ; régularisation L2 des feuilles utile sur petit échantillon

catboost

Boosting · classification nominale
le one-hot fait perdre de l'information sur `Offer`, `Contract`, `Payment Method` ; un encodage cible ordonné ...

adaboost

Boosting · classification nominale
repondérer les erreurs suffit, sans gradient ni régularisation

knn

Voisinage et noyaux · classification nominale
la structure locale (voisinage) porte l'information ; si KNN égale les arbres, des « jumeaux » existent dans l...

svm rbf

Voisinage et noyaux · classification nominale
la marge maximale est plus robuste au bruit d'étiquettes que les modèles qui ajustent chaque point

mlp


Réseau de neurones · classification nominale
une représentation apprise bat les variables construites à la main — attendu faux sur ~1 000 lignes, inclus po...

naive bayes

Probabiliste · classification nominale
l'indépendance conditionnelle des variables — fausse ici (colinéarité mesurée en phase 3), ce qui rend sa cont...

3 scénarios × 3 mappings × 15 modèles : la cible arbitrée est la plus apprenable, le biais coûte à tous


Kappa quadratique pondéré sur les 85 % silencieux — la métrique qui respecte l'ordre des classes



- **M3 domine M1 et M2 pour toutes les familles** : la cible arbitrée par les données est aussi celle que les modèles apprennent le mieux.
- **La performance chute de S1 à S3** pour presque tous les modèles : c'est le coût mesuré du biais de non-réponse — le résultat scientifique du protocole.
- Tous les kappas tiennent dans une bande étroite (0.30–0.39) : **le plafond n'est pas algorithmique, il est dans le signal** (~1 000 répondants biaisés, cible bruitée). Changer de modèle rapporte moins que corriger le biais de réponse.
- Pourquoi le kappa quadratique : une erreur de deux crans (Promoteur prédit Détracteur) doit coûter plus qu'une erreur d'un cran ; l'exactitude et le F1 ne le voient pas.

Choisir sans regarder le test : logistique ordinale retenue, le plus simple des modèles dans la marge


Règle fixée a priori : kappa CV sur les répondants (pondéré IPW), puis parcimonie à un écart-type (ESL § 7.10)



- Meilleur kappa CV brut : **ridge seuils**. Dans la marge (≥ 0.586) : 8 modèles. Retenu : **logistique ordinale** (réglée), simplicité 1.
- Sur le test : le retenu fait **0.384** (rang 2/15) ; le meilleur, ridge seuils, 0.387. L'écart de -0.003 est le prix d'une sélection honnête ; choisir a posteriori serait choisir sur le test.
- $\rho = 0.79$: la CV sur les répondants classe correctement les modèles malgré le biais.
- **La CV promet 0.61, le test donne 0.38** : en production personne ne verrait cet écart. C'est la quantité à retenir.
- Réglage : recherche aléatoire, espaces modestes ; version réglée retenue seulement si elle gagne > 0,005 en CV pondérée.

Jamais une métrique globale sans son détail par classe : les trois classes restent vivantes

Kappa 0.384 · macro-F1 0.490 · exactitude équilibrée 0.511 · AUC Détracteur 0.82





Classe	Précision	Rappel	F1	n
Détracteur	0.44	0.63	0.52	1083
Passif	0.47	0.48	0.48	2590
Promoteur	0.55	0.42	0.48	2290

- Le **Détracteur** est rappelé à 63% avec une précision de 44% : le modèle appelle large — le bon arbitrage quand manquer un détracteur coûte plus qu'un appel inutile.
- Le **Passif**, milieu ambigu et rare à l'entraînement, est le plus difficile (48%) — comme chez Elero et al. La pondération de classes le maintient vivant ; sans elle il tombait à 0,08.
- Exactitude brute 0.49 : rapportée pour montrer qu'elle trompe — prédire toujours Passif donne 0,43.
- Baseline logistique : 0.370 de kappa. Contre-exemple Kannan et al. : F 0,876 en résumé, 0,126 sur la classe minoritaire.

Les probabilités servent à classer les clients, pas à lire une fréquence



Calibration testée, vérifiée, corrigée par une stratégie de décision hybride



- Platt (3 plis) : Brier 0.143 → 0.148, ECE 0.131 → 0.147. Mais le calibrateur **écrase la classe Passif** (rappel 0.00) : rare chez les répondants, il ne la prédit plus.
- **Décision hybride** : la **classe** vient du modèle non calibré ; **P(Détracteur)**, seule utilisée pour classer les appels, vient du modèle calibré. Vérifié par test automatisé.
- Les courbes sont **sous la diagonale** : le calibrateur apprend le taux de base des répondants, pas celui des silencieux — **calibrer sur un échantillon biaisé calibre vers la mauvaise population**. Le classement (AUC 0.82) reste valide ; la valeur absolue non.
- Correction en production : recalibrer sur les premières vraies réponses de la population cible (dès 300 labels).

Sur 500 appels, 51% de vrais détracteurs ($\times 2.8$) ; le NPS des silencieux estimé à +4

La question de l'équipe rétention, et la question de la direction



GAIN NET APPORTÉ

18 585 €

par campagne vs
hasard

ROI


3.8

6 000 € de coût

- Hypothèses (config.yaml, **à valider avec la rétention**) : appel 12 €, client retenu 450 €, succès 25%.
- **NPS des silencieux** : +4 [+2 ; +5] contre une vérité de +20 — sous-estimé de 17 pts. L'intervalle ne couvre que l'aléa d'échantillonnage, pas le biais : dit tel quel. Composition : Détracteurs 26% vs 18% réels, Promoteurs 30% vs 38%.
- Le classement des segments par NPS est respecté (mensuel et récents les plus critiques).
- **Correction testée** : quatre estimateurs de quantification (CC, PCC, ACC, PACC) ; le plus proche reste à 8 pts. La matrice de confusion des répondants ne se transfère pas aux silencieux sous MNAR — la correction doit venir de vraies réponses, pas d'un calcul.

Drivers contractuels, stables au mapping ; par segment, c'est le poids qui change, pas le coefficient

Explication : coefficients $\times$ valeur (exact, additif) — la même dans l'étude et pour chaque client de l'application




- **Contrat sans engagement, faible ancienneté, absence de parrainage, facture élevée** vont avec la détraction — cohérent avec Chong et al. (2023) sur ce dataset et Elero et al. (2026).
- **Offre E** : marqueur de clients déjà fragiles (52,9 % de départs vs 27 % sans offre) — biais d'indication, **pas une cause**. Association $\neq$ causalité, dit à chaque écran.
- **Par segment** : les mêmes variables changent de poids entre contrat mensuel et engagé, récent et ancien, fibre et DSL.
- **Un levier par détracteur prédit**, règle implémentée : engagement 12 mois si mensuel $\rightarrow$ revue tarifaire si charge par service élevée $\rightarrow$ parcours d'accueil si récent $\rightarrow$ support premium. 1476 des détracteurs prédits relèvent du premier levier.
- Sensibilité : sur les 12 drivers principaux, le sens d'effet tient sous les trois mappings.


Le modèle rate davantage les jeunes détracteurs (47% vs 73%) — sans variable d'âge

Audit par sous-groupe, audit des proxies, mitigation chiffrée, arbitrage remonté au métier et au juridique


Par tranche d'âge — écart 26 pts



Les features reconstruisent-elles l'attribut ?



Mitigation testée : ce que ça coûte




- Démographie et géographie **exclues du modèle**, utilisées uniquement pour l'audit. Écart de rappel Détracteur par âge : **26 pts** — le cas que l'énoncé juge inacceptable, en sens inverse. Genre et densité de zone : écarts faibles.
- Pourquoi** : les features retenues **reconstruisent** l'âge (AUC 0.92) et la situation familiale (AUC 0.98). Exclure une colonne n'empêche pas le modèle de la voir.
- Coût de l'exclusion, chiffré : démographie +0.009 de kappa, géographie -0.002. Assumé.
- Mitigation testée** : un seuil par tranche d'âge égalise le rappel (63%) au prix de la précision chez les jeunes et de +273 appels. Traitement différencié selon l'âge : **décision CX + juridique**, non appliquée par défaut. Audit répété à chaque réentraînement.


Robuste au bruit d'étiquettes ; chaque bloc de variables a un coût mesuré

Ce qu'un label NPS réel — bruité — coûterait, et ce que vaut chaque choix de features

Robustesse au bruit d'étiquettes



Ablation : ce que chaque bloc coûte ou rapporte



- **Bruit d'étiquettes** : 30% d'étiquettes corrompues coûtent 0.073 de kappa — dégradation graduelle, pas d'effondrement. Un label NPS réel est bruité (humeur, échelle mal comprise).
- **Contract** est le bloc le plus précieux (-0.027 si retiré) ; le **parrainage** (-0.027) est le driver le plus proche de la cible sans être une fuite — comportement passé observable.
- Variables dérivées : -0.017 ; Offer : -0.001.
- Déséquilibre : 5 stratégies comparées (diapo 6). Mapping : 3 cibles comparées (diapo 9). Aucune conclusion métier ne dépend d'un seul de ces choix.

Deux bonus explorés honnêtement : le modèle de fondation ne gagne pas, le texte synthétique ne prouve rien

TabICL et TabPFN v2 évalués sur poids publics ; TabPFN 2.5 bloqué par une licence, pas par un dépôt fermé

Modèles de fondation tabulaires

Modèle	Kappa	Macro-F1	Rappel Passif	Inférence	Verdict
TabICL	0.379	0.377	0.00	206 s (35 ms/client)	ne bat pas le retenu
TabPFN 2.5	indisponible — licence PriorLabs non acceptée sur cette machine : le téléchargement des poids exige un compte et une clé API (TABPFN_TO				
TabPFN v2	indisponible — écarté pour raison de coût, pas d'accès : l'inférence sur processeur rejoue le jeu d'entraînement à chaque prédiction et				
logistique ordinale (retenu)	0.384	0.490	0.48	0.18 s	référence

Avantages : aucun réglage, performance d'emblée — un excellent étalon de première heure. **Limites**, et la première n'est pas la latence : **la classe Passif est abandonnée** (rappel ~0), ce que le kappa quadratique pénalise peu ; la comparaison n'est pas à protocole égal (aucun des deux n'accepte la pondération de classes utilisée par les 15 autres modèles) ; inférence 2–3 ordres de grandeur plus lente ; aucune explication native. **Compromis chiffré face au meilleur gradient boosting** dans l'étude, phase 4 § 8. Acceptable pour un scoring mensuel, pas pour l'application interactive.

Verbatims synthétiques et fusion texte

Configuration	Kappa	Macro-F1	Rappel Dét.
Tabulaire seul	0.384	0.490	0.63
Texte seul (TF-IDF + logistique)	0.390	0.430	0.53
Fusion tardive (poids 0.3)	0.391	0.380	0.78
Fusion précoce (SVD 20)	0.412	0.510	0.80

7043 notes générées (générateur local seedé, fragments LLM ; chemin API Anthropic prêt, prompt versionné), tonalité tirée de la classe avec 25 % de bruit. Le texte **encode la classe par construction** : tout gain est un artefact. La chaîne fonctionne ; **pas de composante texte en production** sur cette base — le « spot when the added complexity is not worth it » de l'énoncé.

Un outil pour l'équipe rétention : liste priorisée, explication et levier pour chaque client

Application Streamlit, 8 pages filtrables, livrée en image Docker, chaque valeur lue dans les artefacts du pipeline

NPS · Rétention

Prédire la catégorie NPS des clients silencieux, prioriser les appels, comprendre les drivers.

- ☐ Synthèse
- ☐ Prioriser les appels
- ☒ Analyser un client
- ☐ Données et cible
- ☐ Modèles et performance
- ☐ Drivers et équité
- ☐ Suivi et méthode

Modèle retenu logistique ordinaire - réglée
Cible M3 - Scénario S3 (MNAR)
Entraîné sur 1080 répondants - évalué sur 5963 silencieux
Kappa 0.384 - seed 42

Analyser un client

☒ Client existant ☐ Saisie manuelle

Identifiant client: 8779-QRDMV

CONTRAT: Month-to-Month (ancienneté 1 mois)

FACTURE MENSUELLE: 40 \$ (3 services)

INTERNET: DSL (8 Go/mois)

OFFRE PARRAINAGES: Aucune offre (0 parrainage(s))

Satisfaction déclarée = 3 (zone ambiguë). L'arbitrage empirique attribue à ce client un **profil de détracteur à 69%**. Indicateur métier, non utilisé à l'entraînement.

Détracteur

classe prédite (pipeline de décision)

Classe réelle (connue ici) : **Passif**

Levier recommandé
Proposer un engagement 12 mois avec avantage

Probabilités calibrées

Détracteur — 69.9%

Passif — 5.4%

Promoteur — 24.7%

Servent à classer les clients entre eux ; surestimés en valeur absolue.

Ce qui pèse pour ce client

Facteur	Effet	Poids
Contract = Month-to-Month	▲ risque	0.931
tranche_anciennete = 0-6m	▲ risque	0.66
Online Security = No	▼ risque	0.56
Monthly Charge	▼ risque	0.531
Total Charges	▲ risque	0.509
Number of Referrals	▲ risque	0.456
a_parraine	▼ risque	0.455

Méthode : coefficients * valeur (exact, additif). Associations, pas causes.

Contexte : dans le segment « Contrat mensuel », 32% des clients sont réellement détracteurs (NPS du segment -1).

> Toutes les données du client

Dernière note de contact (verbatim synthétique)

Question sur l'activation de l'option streaming. Le service est dans la moyenne de ce que j'ai connu. Je réfléchis avant de changer quoi que ce soit.

Coller un verbatim client (bonus § 4.8)


Note de contact, extrait de chat ou avis

Ex. : Troisième appel ce mois-ci pour la même coupure, j'attends un retour écrit.

- **Prioriser** : silencieux classés par P(Détracteur), filtres, capacité K, pondération CLTV (couche de décision), levier, export CSV.
- **Analyser** : client existant ou saisie manuelle — « (inconnu) » accepté partout, le pipeline impute et `handle_unknown='ignore'` absorbe toute modalité nouvelle (testé). Classe, probabilités, contributions de ce client, levier, contexte du segment, verbatim collé (démonstration).
- **Comprendre et surveiller** : données et cible, 15 modèles et sélection, drivers et équité, monitoring, carte du modèle, conformité à l'énoncé.
- Pourquoi Streamlit : l'énoncé demande un outil pour un responsable rétention, pas une API ; Python pur, versionné avec le pipeline. FastAPI serait la brique CRM suivante.
- Modèle persisté d'un bloc (préparation + modèle + calibrateur + décision) : rejouable sans réentraînement.

Monitoring implémenté : dérive, performance sur les nouvelles réponses, cinq déclencheurs dont l'équité suivie mois par mois

Et la boucle de rétroaction, qui rendrait le modèle pire que rien si on l'ignorait



- **Dérive des entrées** (PSI par variable) et **des prédictions** : sur un mois simulé (tarif +12 %, 15 % vers le mensuel, 10 % vers la fibre), alerte sur Monthly Charge, charge_par_service → réentraînement déclenché.
- **Performance réelle** sur les nouvelles réponses d'enquête (~150/mois) : chute de kappa > 0.05 ou de rappel > 0.1 ; **volume** ≥ 500 labels (mois 4) ; **échéance** 6 mois ; recalibration dès 300 labels ; équité par âge : rappel Détracteur recalculé par tranche d'âge sur le cumul, alerte au-delà de 10 pts — le seuil de la phase 1, désormais le même partout.
- **Boucle de rétroaction** : un détracteur appelé puis retenu change de classe — réentraîner dessus apprend au modèle l'effet de sa propre intervention. Parades : journaliser chaque contact, groupe de contrôle, réentraîner sur non-contactés et contrôles.

Ce que l'étude ne peut pas faire, et la seule décision qu'elle demande à la direction

Cibler par risque n'est pas l'optimum : un groupe de contrôle gratuit permet de faire mieux au cycle suivant

	Ce qui est
Implémenté	tout le périmètre obligatoire (§ 4.1–4.8), le monitoring (§ 4.9), les trois bonus
Approximatif, dit tel quel	paramètres économiques placeholders ; propension à répondre simulée ; verbatims locaux (pas d'API) ; NPS des silencieux sous-estimé de 17 pts
Impossible avec ces données	estimer l'effet d'un appel : aucune campagne, aucune assignation aléatoire — la table Offer prouve que les offres ont été ciblées
Travail futur	TabPFN 2.5 dès acceptation de la licence PriorLabs ; recalibration sur vraies réponses ; uplift après groupe de contrôle ; API CRM ; vrais verbatims

La décision demandée. Ascarza (2018, *J. Marketing Research*) : cibler les clients au risque le plus élevé est inefficace ; il faut cibler ceux dont le comportement change quand on les appelle — même budget, jusqu'à 7 pts de churn en moins. Les détracteurs les plus certains sont souvent des *perdus d'avance*.

À la prochaine campagne, ne pas contacter 10 à 20 % des clients ciblés, tirés au hasard. Ce groupe de contrôle achète la mesure de l'effet réel de la campagne et les données d'un modèle d'uplift — passer du ciblage par risque au ciblage par sensibilité.

C'est le seul passage de l'étude qui demande une décision plutôt que de présenter un résultat.

Chaque exigence de l'énoncé a une réponse et un emplacement vérifiable

Reproductible à l'identique ; usage d'IA déclaré ; aucune clé dans le dépôt

✓	§ 4.1	Cible justifiée, raffinée, sensibilité, bruit, fuites
✓	§ 4.2	Schéma, manquants, split 15/85, déséquilibre
✓	§ 4.3	Features justifiées, géo/démo arbitrées
✓	§ 4.4	Verbatims LLM reproductibles + fusion (bonus)
✓	§ 4.5	Baseline, 15 modèles, métriques adaptées, validation, SHAP/coefficients, fondation (bonus)
✓	§ 4.6	Drivers par segment, actionnable, levier unique (bonus)
✓	§ 4.7	Audit sous-groupes, proxies, arbitrage, escalade
✓	§ 4.8	Modèle persisté, app robuste aux inconnus
✓	§ 4.9	Monitoring, déclencheurs, boucle de rétroaction
✓	§ 6–7	Code, notebook, README, .env.example, dataset, verbatims, modèle, captures, write-up 6 p. ; reproductible ; IA déclarée ; pas de clés

TEST À BLANC DEPUIS COPIE VIERGE

10/10

indicateurs identiques (NPS, modèle retenu, kappa, précision@K, équité...)

TESTS AUTOMATISÉS

30

jointure, fuites, cible, protocole, 15 modèles clonables, sélection, exécution réelle des 8 pages de l'app

Usage d'IA (§ 7) : code, structure de l'étude et rédaction produits avec l'assistance d'un assistant IA (Claude), sous direction et relecture humaines ; fragments des verbatims synthétiques rédigés par ce même assistant. Choix de modélisation, périmètre et conclusions assumés par l'auteur.

Cinq choses à retenir

Clear reasoning, practical execution, reproducibility — et honnêteté sur ce que les données permettent

1 · LA CIBLE

+21

et non -42 : les « 3 » arbitrés par les données, sans circularité

2 · LES FUTURES

0

colonne liée au churn dans le modèle ; exactitude max 0.65

3 · LE MODÈLE

×2.8

logistique ordinaire, choisie parmi 15 sans regarder le test

4 · L'ÉQUITÉ

26 pts

d'écart par âge, cause mesurée (proxies), mitigation chiffrée, remontée

5 · LA DÉCISION

10–20 %

de groupe de contrôle : mesurer l'effet, préparer l'uplift

Ce que les quinze modèles disent ensemble : le plafond de performance est dans le signal — ~1 000 répondants biaisés et une cible bruitée — pas dans l'algorithme. La prochaine marche n'est pas un modèle de plus : ce sont de vraies réponses de la population cible, un journal des contacts et un groupe de contrôle.

Limites assumées : hypothèses économiques à valider ; propension simulée ; taux de réponse 15 % optimiste (2,6 % chez Kannan et al.) ; NPS agrégé des silencieux sous-estimé ; verbatims synthétiques ; TabPFN 2.5 non évalué faute d'acceptation de licence (TabICL et TabPFN v2 l'ont été).

Merci. Application : `streamlit run app/app.py` · Étude : `reports/` (8 documents) · Write-up : `livrable/write_up.pdf` · Conformité : `reports/07_conformite_enonce.md`