

Prédire la catégorie NPS des clients silencieux

Priorisation des appels de rétention — write-up pour la direction Expérience Client

1. En une page

L'opérateur interroge ses clients sur leur propension à le recommander, et 15 % répondent. J'ai construit un modèle qui estime, pour chacun des 85 % silencieux, s'il est Détracteur, Passif ou Promoteur. Il alimente une application qui en tire une liste d'appels priorisée, avec pour chaque client les raisons et le levier à activer. J'y ajoute une estimation du NPS des silencieux et un dispositif de suivi.

Les cinq chiffres	
NPS réel de la base, avec la grille retenue	+21. On le connaît ici parce que la note des 7 043 clients est dans le jeu de données : ce n'est pas une prédiction. Avec la grille proposée dans l'énoncé, il vaudrait -42
NPS des 85 % silencieux, estimé par le modèle	+4 (intervalle +2 à +5). La vérité est +20, donc je sous-estime de 17 points. Ce chiffre se lit en tendance, pas en valeur absolue. Les répondants seuls donneraient +27
Sur 500 appels, part de vrais détracteurs	51% contre 18% au hasard — $\times 2.8$
Gain net supplémentaire par campagne	18 585 € à hypothèses de coût constantes (à valider)
Détracteurs retrouvés	63% — mais 47% seulement chez les moins de 30 ans

Trois résultats me paraissent devoir être retenus.

D'abord, la grille NPS proposée dans l'énoncé donne un résultat peu crédible. Elle classe en détracteurs 2665 clients moyennement satisfaits, dont 84% sont pourtant toujours là. En entraînant un modèle sur les seuls clients aux notes extrêmes, j'obtiens que 72% d'entre eux ressemblent plutôt à des promoteurs.

Ensuite, le modèle multiplie par 2.8 l'efficacité des appels. Je l'ai choisi sans regarder les clients qui servent à l'évaluer : 15 modèles de 7 familles comparés, sélection par validation croisée sur les seuls répondants, et à performance équivalente le plus simple l'emporte. C'est la logistique ordinale qui sort.

Enfin, il repère moins bien les jeunes détracteurs, alors qu'il n'utilise pas l'âge. Le contrat et l'ancienneté suffisent à le retrouver. J'ai chiffré une correction, mais la décision de l'appliquer ne m'appartient pas : elle est remontée au métier et au juridique.

Sur le périmètre. J'ai cherché à couvrir ce qui est demandé plutôt qu'à en faire trop, et une matrice en annexe relie chaque pièce du rendu à l'exigence correspondante. Les quinze modèles ne sont pas une course au score : quand des approches aussi différentes plafonnent au même endroit, c'est que la limite vient des données. La marche suivante est donc métier, pas algorithmique. J'ai laissé de côté l'enrichissement externe, les réseaux ordinaux, une API de scoring et un suivi d'expériences, en expliquant pourquoi dans l'étude.

Ce que je vous demande. Appeler les clients les plus à risque n'est pas forcément la stratégie la plus rentable. La littérature montre qu'il vaut mieux cibler ceux dont le comportement change le plus quand on les appelle (Ascarza, *J. Marketing Research*, 2018). Pour le mesurer, il suffit de ne pas contacter 10 à 20 % des clients ciblés à la prochaine campagne, tirés au hasard. Cela ne coûte rien.

2. Les données et leurs pièges

Le jeu de données couvre 7 043 clients d'un opérateur californien fictif. J'ai utilisé la version IBM Telco Customer Churn 11.1.3+, la seule qui porte la note de satisfaction ; le fichier Kaggle le plus diffusé ne l'a pas. Cinq tables jointes sans perte, 51 colonnes, et une colonne clé : une note de satisfaction de 1 à 5. Trois

constats ont orienté tout le reste.

Le jeu de données contient sa propre réponse. Tous les clients notés 1 ou 2 sont partis, aucun de ceux notés 4 ou 5. Du coup, n'importe quelle colonne liée au départ (Churn Value, Churn Score, Customer Status, CLTV) donnerait un score presque parfait et un modèle inutilisable : au moment où l'on veut repérer un détracteur, il n'est pas encore parti. Je les ai classées en trois types de fuite, mesurées par information mutuelle, puis exclues. Deux contrôles après modélisation vérifient qu'il n'en reste pas (exactitude maximale 0.65 pour un seuil d'alerte à 0,85 ; écart entre arbres et linéaire -0.01 pour un seuil à +0,30).

La note « 3 » décide de tout. Ils sont 2665, soit 38% de la base, et 84% sont encore clients. Plutôt que de trancher moi-même, j'ai entraîné un modèle sur les seules notes extrêmes (1–2 contre 4–5, 80% d'exactitude) et je lui ai fait classer ces clients : 72% ressemblent à des promoteurs. J'ai donc traité le bloc comme Passif. Attention, je n'ai pas étiqueté chaque client par ce modèle : la cible serait devenue une fonction des variables, et le modèle final aurait réappris sa propre sortie.

Voici la grille que je retiens, et l'écart avec celle de l'énoncé :

Grille	Détracteur	Passif	Promoteur	NPS	Statut
Énoncé	1, 2, 3	4	5	-42.0	écartée : 58% de la base en détracteurs
Recentrée	1, 2	3, 4	5	-4.1	variante prudente, publiée
Retenue	1, 2	3	4, 5	+21.3	le « 3 » arbitré par la mesure, le « 4 » par hypothèse d'échelle

Ce sont deux décisions, pas une, et elles n'ont pas le même statut. Le déplacement du « 3 » est mesuré. Le passage du « 4 » chez les promoteurs est une hypothèse que j'assume : une note de 4 sur 5 correspond à « satisfait », et aucun client noté 4 n'a quitté l'opérateur. Pour qui refuse cette hypothèse, la grille recentrée est calculée et publiée.

Les offres commerciales sont une quasi-expérience — piégée. Les clients ayant reçu l'offre E partent **deux fois plus** que ceux sans offre : elle a été proposée à des clients déjà fragiles. On ne lit pas un effet causal dans des données observationnelles.

Les variables retenues (18 numériques, 17 catégorielles) sont chacune adossées à une hypothèse écrite ; la démographie et la géographie sont exclues du modèle par décision d'équité, et le coût de cette exclusion est chiffré (+0.009 de kappa pour la démographie, -0.002 pour la géographie). Aucun enrichissement externe : il réintroduirait le proxy socio-économique qu'on a exclu.

3. Un modèle évalué dans les conditions réelles, choisi sans regarder la réponse

Le protocole. Séparer les clients au hasard entre apprentissage et test m'aurait induit en erreur. Ceux qui répondent à une enquête ne sont pas un échantillon au hasard : les mécontents et les enthousiastes répondent davantage. J'ai donc simulé trois façons de ne pas répondre, jusqu'à la plus réaliste, où le fait de répondre dépend de la satisfaction elle-même¹. Dans ce cas, la part de notes extrêmes passe de 37% dans la base à 71% chez les répondants. Le modèle apprend sur ces 15 % biaisés, et il est jugé sur les 85 % silencieux, dont on connaît ici la vraie réponse.

Quinze modèles, sept familles, trois façons de poser le problème. Chacun teste une hypothèse précise sur les données. Je les ai comparés sur toutes les combinaisons de cible et de scénario, réglés, puis choisis en n'utilisant que les répondants, seule information dont on disposerait en production. La règle est simple : entre des modèles que la mesure ne distingue pas, je garde le plus simple². Les 85 % silencieux servent à vérifier, jamais à choisir.

Rang	Modèle	Famille	Score sur les répondants ³	Score sur les silencieux (vérité)	Détracteurs retrouvés	Dans la marge
1	ridge seuils	Régression + seuils	0.621	0.387	0.57	✓
2	catboost	Boosting	0.616	0.366	0.83	✓
3	mlp	Réseau de neurones	0.611	0.354	0.74	✓
4	lightgbm	Boosting	0.605	0.375	0.82	✓

Retenu : **logistique ordinale** (réglée). Le meilleur sur la vérité est ridge seuils, à 0.003 près : un écart assumé, prix d'un choix fait sans regarder la réponse. J'en retiens deux choses. La validation promet 0.61 et la vérité donne 0.38 : cet écart est le coût du biais de réponse, et il serait invisible en production. C'est la raison pour laquelle il faut de vraies réponses de la population cible (section 6). Ensuite, tous les modèles tiennent dans une bande étroite, de 0.30 à 0.39 : ce qui limite la performance, c'est le signal disponible, pas l'algorithme. **TabICL**, modèle de fondation tabulaire (bonus), a été évalué sur le même découpage : kappa 0.379 contre 0.384 pour le modèle retenu, inférence 1173× plus lente, sans explication native. Il ne bat pas le modèle retenu. Un modèle n'a pas pu être évalué — TabPFN 2.5 : licence PriorLabs non acceptée sur cette machine : le téléchargement des poids exige un compte et une clé API (TABPFN_TOKEN), TabPFN v2 : écarté pour raison de coût, pas d'accès : l'inférence sur processeur rejoue le jeu d'entraînement à chaque prédiction et demande plusieurs minutes pour 5 963 clients, sans changer la conclusion que TabICL établit déjà ; la cause exacte et ce qu'il faudrait faire sont dans l'étude.




Figure 2 — Ce que la validation sur les répondants promet (horizontal) contre ce que les 85 % silencieux donnent (vertical).
Rouge : retenu ; bleu : modèles que la mesure ne distingue pas du meilleur.

Performance classe par classe. Je ne publie jamais un score global sans son détail.

Classe	Quand le modèle dit « X », il a raison à	Part des vrais « X » retrouvés	Effectif
Détracteur	44%	63%	1083
Passif	47%	48%	2590
Promoteur	55%	42%	2290

Le score d'accord ordonné³ vaut 0.384, contre 0.370 pour le point de départ logistique, et la qualité du classement des détracteurs⁴ atteint 0.82. Le Passif, c'est-à-dire le client moyennement satisfait, est le plus difficile à retrouver : il est rare chez les répondants, et la littérature fait le même constat. J'ai testé puis corrigé les probabilités affichées. Ajustées sur des répondants biaisés, elles surestiment le risque : elles servent à classer les clients entre eux, pas à lire une fréquence. J'ai également vérifié la robustesse. Corrompre 30% des étiquettes d'apprentissage ne coûte que 0.073 de score, et les conclusions sur les facteurs de détraction tiennent quelle que soit la définition retenue pour la cible. **Texte.** 7043 notes de contact synthétiques (source `gabarit_stochastique_seed (6010) + claude_code_agent (1033)`, 25 % de bruit de tonalité) ont été combinées au modèle tabulaire : la fusion gagne +0.007 de kappa — et ce chiffre ne prouve rien, le texte ayant été fabriqué à partir de la classe. L'expérience valide la chaîne technique ; conclusion opérationnelle : **pas de composante texte** sur cette base.

4. Ce que ça vaut pour l'équipe rétention

Sur 500 appels par mois, la liste contient 51% de vrais détracteurs, ce qui couvre 24% d'entre eux, soit 2.8 fois mieux qu'un ciblage au hasard. En prenant un coût d'appel de 12 €, une valeur de client retenu de 450 € et un taux de succès de 25%, la campagne ciblée rapporte 22 800 € nets contre 4 215 € au hasard. Ces trois paramètres sont des hypothèses, à valider avec votre équipe. J'ai aussi laissé CLTV en option pour pondérer qui appeler : elle est interdite comme variable du modèle, mais rien n'empêche de s'en servir pour arbitrer entre deux détracteurs prédits.

Le NPS des silencieux. Le modèle l'estime à +4, avec un intervalle de +2 à +5. La vérité, qu'on connaît ici, est +20, soit -17 points d'écart. Composition par classe : trop de Détracteurs ; trop peu de Promoteurs ; la part de Passifs est juste. Ce sont les conséquences du biais de réponse — le modèle apprend sur des répondants polarisés et une pondération de classes qui rééquilibre le Passif — et le NPS, différence de deux parts, cumule les erreurs sur les Détracteurs et les Promoteurs. À rapporter avec l'intervalle et cette réserve ; la correction passe par les premières vraies réponses de la population cible (phase 6 § 4). Quatre estimateurs de quantification (Forman 2005) ont été testés pour corriger cet écart ; le meilleur reste à 8 pts : la matrice de confusion mesurée sur les répondants ne se transfère pas aux silencieux — la correction doit venir de vraies réponses de la population cible.




Figure 4 — Le NPS que l'opérateur observe (répondants), celui que le modèle estime pour les silencieux, la vérité.

Ce qui fait un détracteur, selon le modèle. Un contrat sans engagement, une faible ancienneté, l'absence de parrainage et une facture élevée. Ces associations restent les mêmes quelle que soit la grille retenue pour la cible, et elles rejoignent ce que décrit la littérature. Leur poids varie d'un segment à l'autre, et l'étude les donne segment par segment : contrat mensuel ou engagé, client récent ou ancien, fibre ou DSL.

Pour chaque détracteur prédit, l'application propose deux leviers, classés selon ce qui pèse chez ce client précis. Le premier est souvent l'engagement, simplement parce que la quasi-totalité des détracteurs prédits sont en contrat mensuel : c'est vrai, mais cela ne trie pas. C'est le second levier qui distingue deux clients par

ailleurs semblables, et c'est celui qu'il faut lire en priorité.

Un point important : ce sont des associations, pas des causes. L'offre E « prédit » le départ parce qu'elle a été proposée à des clients déjà fragiles, pas parce qu'elle les fait partir.

5. Équité




Figure 5 — Rappel Détracteur (bleu) et taux de sélection (gris) par sous-groupe. Variables exclues du modèle, utilisées uniquement pour cet audit.

Le problème. Sur 100 clients mécontents de moins de 30 ans, ma liste d'appels en repère 47. Sur 100 seniors mécontents, elle en repère 73. À budget d'appels égal, les jeunes clients mécontents ont donc nettement moins de chances d'être rappelés.

Pourquoi, alors que le modèle ne connaît pas l'âge ? Il ne le connaît pas, mais il le devine. Les jeunes clients sont pour la plupart en contrat mensuel et récents, si bien que le contrat et l'ancienneté suffisent à retrouver la tranche d'âge presque à coup sûr. Retirer la colonne empêche de décider explicitement sur l'âge, cela n'empêche pas le modèle de le voir.

Ce que coûterait la correction, en appels et en euros. Deux options ont été chiffrées, et elles n'ont pas le même prix.

Politique	Jeunes mécontents repérés (sur 100)	Seniors mécontents repérés (sur 100)	Appels par campagne	Coût d'appel supplémentaire	Gain net
Aujourd'hui, sans correction	47	73	1 556	0	57 940
Corriger pour tous (nivellement)	61	71	1 829	3 276	62 877
Corriger seulement les moins bien servis	61	73	1 659	1 236	59 292

Niveler pour tous coûte plus qu'il n'y paraît. Ramener tous les groupes au même niveau ajoute 273 appels par campagne (3 276 €), et surtout : cela **abaisse** la couverture des seniors mécontents, aujourd'hui les mieux repérés. On égalise en partie par le bas.

Rattraper seulement les moins bien servis ne prend rien à personne. Abaisser le seuil de décision pour les seuls moins de 30 ans, sans toucher aux autres, coûte 103 appels de plus (1 236 €) et ne dégrade la détection d'aucun groupe. **C'est l'option que nous recommandons de soumettre au juridique.**

Ce que je vous demande. Je n'applique aucune de ces corrections par défaut, parce qu'appliquer un seuil différent selon l'âge est une décision juridique avant d'être technique. Selon le pays, c'est une discrimination prohibée ou une mesure correctrice admise, et ce n'est pas à moi de trancher. La question est à poser au juridique, avec les chiffres ci-dessus. L'écart est par ailleurs recalculé chaque mois sur les nouvelles réponses et déclenche une alerte au-delà de dix points, donc l'audit ne s'arrête pas à cette étude. (Détail technique en phase 5 § 7 de l'étude : AUC de reconstruction de l'âge 0.92, de la situation familiale 0.98 ; genre et densité de zone non reconstituables et sans écart.)

6. Limites, décision, suites

Ce que ces données ne permettent pas. Estimer l'effet d'un appel, tout simplement : il n'y a aucune campagne enregistrée ni assignation aléatoire. Mon modèle classe par risque. L'optimum économique, lui, classerait par sensibilité à l'intervention, c'est-à-dire les clients qui restent parce qu'on les a appelés, et non ceux qui étaient déjà décidés.

Ma recommandation. À la prochaine campagne, ne contactez pas 10 à 20 % des clients ciblés, tirés au hasard. Ce groupe de contrôle vous donne la mesure de l'effet réel de la campagne, et les données qu'il faudrait pour cibler par sensibilité au cycle suivant. Sans lui, un détracteur appelé puis retenu change de classe, le modèle réapprend l'effet de sa propre intervention, et il se dégrade sans que personne ne comprenne pourquoi.

Monitoring. Implémenté : dérive des entrées et des prédictions, performance **et équité par tranche d'âge** sur les nouvelles réponses, 5 déclencheurs de réentraînement. Sur un mois simulé (tarif +12 %, 15 % des contrats basculés en mensuel, 10 % migrés vers la fibre), la dérive et l'équité se déclenchent — le dispositif est vérifié, pas seulement décrit.

Ce que j'assume comme limites. Les hypothèses économiques restent à valider avec vous. La propension à répondre est simulée : elle est plausible, elle n'est pas observée. Le taux de réponse de 15 % est optimiste, Kannan et ses coauteurs rapportent 2,6 %. Le cadrage panafricain de l'énoncé est plaqué sur un jeu de données californien. Les verbatims sont synthétiques. Enfin, TabPFN 2.5 n'a pas été évalué, sa licence PriorLabs demandant un compte et une clé API.

Reproductibilité et livraison. `docker compose up` lance l'application sans rien installer, modèle et données embarqués ; `python -m src.run` régénère tout depuis les fichiers bruts. Seed unique, aucune clé dans le dépôt, tests automatisés. Test à blanc depuis une copie vierge : identique sur les 10 indicateurs contrôlés.

Usage d'outils d'IA (énoncé § 7) : code, structure de l'étude et rédaction produits avec l'assistance d'un assistant IA (Claude), sous direction et relecture humaines ; fragments des verbatims synthétiques rédigés par ce même assistant. Les choix de modélisation, les décisions de périmètre et les conclusions sont assumés par l'auteur.

Glossaire. ¹ **Non-réponse dépendante de la réponse** (MNAR, *missing not at random*) : la probabilité de répondre dépend de ce qu'on aurait répondu. ² **Règle de parcimonie** (« one standard error rule », Hastie et al., ESL § 7.10) : parmi les modèles à moins d'un écart-type du meilleur, le plus simple. ³ **Kappa quadratique pondéré** : score d'accord entre prédiction et vérité, corrigé du hasard, qui pénalise davantage une erreur de deux crans (Promoteur ↔ Détracteur) qu'une erreur d'un cran ; sur les répondants il est pondéré pour représenter la population entière (IPW). ⁴ **AUC** : probabilité qu'un vrai détracteur soit classé avant un non-détracteur (0,5 = hasard, 1 = parfait).

Références. Ascarza (2018) *Retention Futility*, J. Marketing Research · Elero et al. (2026) *Computers* 15(2) · Chong et al. (2023) J. Soft Computing & Data Mining · Mustafa et al. (2021) *F1000Research* · Kannan et al. (2022) *ICTIM* · Hastie, Tibshirani & Friedman, *Elements of Statistical Learning* § 7.10 · Gómez-Vargas et al. (2025) *Eur. J. Operational Research* · Qu et al. (2025) *TabICL*, *ICML* · Hollmann et al. (2025) *TabPFN*, *Nature*.