

Prédire la catégorie NPS des clients silencieux

Priorisation des appels de rétention — write-up pour la direction Expérience Client

1. En une page

Un opérateur télécom interroge ses clients sur leur propension à le recommander ; **15 % répondent**. Ce travail construit un modèle qui estime, pour chacun des 85 % silencieux, s'il est Détracteur, Passif ou Promoteur ; une application qui en tire une liste d'appels priorisée avec, pour chaque client, les raisons et le levier ; une estimation du NPS des silencieux ; et un dispositif de suivi.

Les cinq chiffres	
NPS estimé de la base complète	+21 (secteur +19 à +34) — contre -42 avec la grille de l'énoncé prise au pied de la lettre
NPS des 85 % silencieux, estimé par le modèle	+4 (intervalle +2 à +5) ; les répondants seuls donnent +27
Sur 500 appels, part de vrais détracteurs	51% contre 18% au hasard — $\times 2.8$
Gain net supplémentaire par campagne	18 585 € à hypothèses de coût constantes (à valider)
Détracteurs retrouvés	63% — mais 48% seulement chez les moins de 30 ans

Trois résultats. (1) **La grille NPS de l'énoncé fabrique un résultat faux** : elle classe en détracteurs 2665 clients « moyennement satisfaits » dont 84 % sont restés ; un modèle entraîné sur les seuls extrêmes montre qu'ils penchent à 72% côté promoteur. (2) **Le modèle multiplie par 2.8 l'efficacité des appels**, et il a été choisi honnêtement : 15 modèles de 7 familles comparés, sélection par validation croisée sur les répondants *sans regarder* les clients d'évaluation, règle de parcimonie ; retenu : logistique ordinaire. (3) **Il rate davantage les jeunes détracteurs**, sans variable d'âge : les variables contractuelles reconstruisent l'âge ; une correction est chiffrée, la décision de l'appliquer est remontée au métier et au juridique.

Une décision demandée. Appeler les clients les plus à risque n'est pas la stratégie la plus rentable : il faut cibler ceux dont le comportement change le plus quand on les appelle (Ascarza, *J. Marketing Research*, 2018). Le mesurer ne demande qu'une chose, gratuite : **ne pas contacter 10 à 20 % des clients ciblés à la prochaine campagne, tirés au hasard.**

2. Les données et leurs pièges

7 043 clients d'un opérateur californien fictif (IBM Telco), cinq tables jointes sans perte, 51 colonnes. La colonne clé est une **satisfaction de 1 à 5** déclarée par le client. Trois faits ont structuré le travail.

Le dataset contient sa propre réponse. Les clients à satisfaction 1–2 sont **tous partis** ; ceux à 4–5, **aucun**. Toute colonne liée au départ (Churn Value, Churn Score, Customer Status, CLTV...) donnerait un score presque parfait et un modèle inutilisable — au moment de détecter un détracteur, il n'est pas encore parti. Ces colonnes sont classées en trois natures de fuite (conséquence, disponibilité, modèle amont), **mesurées** par information mutuelle, et exclues ; deux diagnostics vérifient après modélisation qu'aucune fuite ne subsiste (exactitude maximale 0.65 pour un seuil d'alerte à 0,85 ; écart arbres/linéaire -0.01 pour un seuil à +0,30).

La note « 3 » décide de tout. 2665 clients, 38 % de la base, 84 % encore présents. Plutôt que de décider où ils vont, un modèle entraîné sur les seuls extrêmes (1–2 contre 4–5, exactitude 80%) les a classés : 72% ressemblent à des promoteurs. Le bloc est traité comme **Passif**. On a évité d'étiqueter chaque client

individuellement par ce modèle — la cible serait devenue une fonction des variables, et le modèle final aurait réappris sa propre sortie.




Figure 1 — Trois façons de construire la cible, et le NPS qui en résulte. Bande verte : benchmark télécom publié.

Les offres commerciales sont une quasi-expérience — piégée. Les clients ayant reçu l'offre E partent **deux fois plus** que ceux sans offre : elle a été proposée à des clients déjà fragiles. On ne lit pas un effet causal dans des données observationnelles.

Les variables retenues (18 numériques, 17 catégorielles) sont chacune adossées à une hypothèse écrite ; la démographie et la géographie sont exclues du modèle par décision d'équité, et le coût de cette exclusion est chiffré (+0.009 de kappa pour la démographie, -0.002 pour la géographie). Aucun enrichissement externe : il réintroduirait le proxy socio-économique qu'on a exclu.

3. Un modèle évalué dans les conditions réelles, choisi sans regarder le test

Le protocole. Un découpage aléatoire aurait été trompeur : les répondants ne sont pas un échantillon au hasard — les mécontents et les enthousiastes répondent plus. Trois mécanismes de non-réponse ont été simulés ; dans le scénario réaliste (la propension à répondre dépend de la satisfaction), la part de notes extrêmes passe de **37% dans la base à 71% chez les répondants**. Le modèle est entraîné sur ces 15 % biaisés et évalué sur les 85 % silencieux, dont on connaît la vérité.

Quinze modèles, sept familles, trois formulations. Régression logistique (baseline), logistique ordinaire, régression à seuils (linéaire et boosting), arbre, forêt aléatoire, cinq boostings (HGB, LightGBM, XGBoost, CatBoost, AdaBoost), KNN, SVM, réseau de neurones, Naive Bayes — chacun présent pour tester une hypothèse nommée. Comparés sur 3 scénarios × 3 mappings, réglés par recherche aléatoire, puis **sélectionnés par validation croisée sur les répondants, pondérée par l'inverse de la propension estimée** — la seule information disponible en production — avec une règle de parcimonie : parmi les modèles à moins d'un écart-type du meilleur, le plus simple l'emporte. Les silencieux ne servent qu'au test.

Rang CV	Modèle	Famille	Kappa CV (IPW)	Kappa test	Rappel Dét. test	Dans la marge
1	ridge seuils	Régression + seuils	0.621	0.387	0.57	✓
2	catboost	Boosting	0.616	0.366	0.83	✓
3	mlp	Réseau de neurones	0.611	0.354	0.74	✓
4	lightgbm	Boosting	0.605	0.375	0.82	✓
5	logistique ordinaire	Linéaire	0.597	0.384	0.63	✓
6	xgboost	Boosting	0.594	0.373	0.81	✓

Retenu : **logistique ordinale** (réglée). Meilleur kappa CV brut : ridge seuils ; meilleur sur le test : ridge seuils (0.387 contre 0.384 pour le retenu — écart assumé, prix d’une sélection honnête). La corrélation entre ce que la validation croisée promet et ce que le test donne est de $\rho = 0.79$; pour le modèle retenu, la CV promet 0.61 et le test donne 0.38 : **c’est le coût du biais de réponse, invisible en production**. Tous les kappas de test tiennent dans une bande étroite (0.30–0.39) : le plafond n’est pas algorithmique, il est dans le signal. **TabICL**, modèle de fondation tabulaire (bonus), a été évalué sur le même découpage : kappa 0.379 contre 0.384 pour le modèle retenu, inférence 1173× plus lente, sans explication native. Il ne bat pas le modèle retenu. TabPFN n’a pas pu être évalué (poids à accès contrôlé sur Hugging Face) ; sa place est documentée dans l’étude.




Figure 2 — Ce que la validation croisée sur les répondants promet (x) contre ce que les 85 % silencieux donnent (y). Rouge : retenu ; bleu : dans la marge de parcimonie.

Performance, par classe — jamais globale seule.

Classe	Précision	Rappel	F1	Effectif
Détracteur	0.44	0.63	0.52	1083
Passif	0.47	0.48	0.48	2590
Promoteur	0.55	0.42	0.48	2290

Kappa quadratique **0.384**, macro-F1 0.490, AUC Détracteur 0.82 (baseline logistique : kappa 0.370). Le Passif, milieu ambigu et rare chez les répondants, est le plus difficile — comme dans la littérature. La calibration des probabilités a été testée puis **corrigée** : ajustée sur des répondants biaisés, elle écrasait la classe Passif et surestime P(Détracteur). Décision : les probabilités servent à **classer** les clients, pas à lire une fréquence. Robustesse vérifiée : 30% d’étiquettes corrompues coûtent 0.108 de kappa ; les conclusions sur les drivers tiennent sous les trois mappings de la cible. **Texte**. 7043 notes de contact synthétiques (source gabarit_stochastique_seed, 25 % de bruit de tonalité) ont été combinées au modèle tabulaire : la fusion gagne +0.002 de kappa — et ce chiffre ne prouve rien, le texte ayant été fabriqué à partir de la classe. L’expérience valide la chaîne technique ; conclusion opérationnelle : **pas de composante texte** sur cette base.

4. Ce que ça vaut pour l’équipe rétention




Figure 3 — Gauche : fiabilité des probabilités (sous la diagonale : surestimées). Droite : part des détracteurs captés selon le nombre d'appels.

À K = 500 appels par mois : **précision 51%**, rappel 24%, lift $\times 2.8$. Avec un coût d'appel de 12 €, une valeur de client retenu de 450 € et un taux de succès de 25% — **paramètres à valider avec l'équipe** — la campagne ciblée rapporte 22 800 € nets contre 4 215 € au hasard. CLTV, interdite comme variable du modèle, est proposée en option pour pondérer *qui appeler*.

Le NPS des silencieux. Le modèle l'estime à +4 (IC 95 % +2 à +5) ; la vérité, connue ici, est +20 (-17 pts). Composition par classe : trop de Détracteurs ; trop peu de Promoteurs ; la part de Passifs est juste. Ce sont les conséquences du biais de réponse — le modèle apprend sur des répondants polarisés et une pondération de classes qui rééquilibre le Passif — et le NPS, différence de deux parts, cumule les erreurs sur les Détracteurs et les Promoteurs. À rapporter avec l'intervalle et cette réserve ; la correction passe par les premières vraies réponses de la population cible (phase 6 § 4).




Figure 4 — Le NPS que l'opérateur observe (répondants), celui que le modèle estime pour les silencieux, la vérité.

Ce qui fait un détracteur, selon le modèle : contrat sans engagement, faible ancienneté, absence de parrainage, facture élevée — associations robustes au mapping de la cible et cohérentes avec la littérature. Elles ne pèsent pas partout pareil : les drivers sont donnés **par segment** (contrat mensuel / engagé, client récent / ancien, fibre / DSL). Pour chaque détracteur prédit, l'application recommande **un levier** : engagement si contrat mensuel, revue tarifaire si charge par service élevée, parcours d'accueil si client récent, support premium sinon. Ce sont des **associations**, pas des causes — l'offre E « prédit » le départ parce qu'elle a été proposée à des clients fragiles.

5. Équité




Figure 5 — Rappel Détracteur (bleu) et taux de sélection (gris) par sous-groupe. Variables exclues du modèle, utilisées uniquement pour cet audit.

L'écart de **26 points** de rappel entre tranches d'âge (48% chez les moins de 30 ans, 73% chez les 60 ans et plus) est le point à escalader : c'est le cas que l'énoncé décrit comme inacceptable, en sens inverse. Sa cause a été mesurée : les variables retenues **reconstruisent** l'âge (AUC 0.92) et la situation familiale (AUC 0.98) — exclure une colonne n'empêche pas le modèle de la voir. Genre et densité de zone ne sont pas restructurables et ne montrent pas d'écart. Une **mitigation par seuils de décision par tranche d'âge** a été chiffrée : elle égalise le rappel (63% partout) au prix de la précision chez les jeunes et de +70 appels. Traiter différemment selon l'âge est un arbitrage juridique et métier : non appliqué par défaut, remonté à l'Expérience Client et au juridique. L'audit est dans le monitoring et se répète à chaque réentraînement.

6. Limites, décision, suites

Ce qu'on ne peut pas faire avec ces données : estimer l'effet d'un appel. Aucune campagne enregistrée, aucune assignation aléatoire. Ce modèle classe par **risque** ; l'optimum économique classe par **sensibilité à l'intervention** — les clients qui restent *parce qu'on les a appelés*, pas ceux qui étaient déjà décidés.

La décision. À la prochaine campagne, ne pas contacter 10 à 20 % des clients ciblés, tirés au hasard. Ce groupe de contrôle achète la mesure de l'effet réel de la campagne et les données qui permettraient, au cycle suivant, de cibler par sensibilité. Sans lui, un détracteur appelé puis retenu change de classe et le modèle réapprend l'effet de sa propre intervention — il se dégrade sans que personne ne voie pourquoi.

Monitoring. Un monitoring est implémenté : dérive des entrées et des prédictions (indice PSI), performance sur les nouvelles réponses d'enquête, déclencheurs par seuil de dérive, chute de performance, volume de labels (500 nouvelles réponses) et échéance. Sur un mois simulé (tarif +12 %, 15 % des contrats basculés en mensuel, 10 % migrés vers la fibre), le déclencheur de dérive se déclenche (variables en alerte : Monthly Charge, charge_par_service).

Limites assumées : hypothèses économiques à valider ; propension à répondre simulée (plausible, non observée) ; taux de réponse de 15 % optimiste (2,6 % chez Kannan et al.) ; cadrage panafricain plaqué sur un dataset californien ; verbatims synthétiques sans clé API ; TabPFN non évalué faute d'accès aux poids.

Reproductibilité et livraison. `python -m src.run` régénère données, cible, quinze modèles, sélection et évaluation ; `python -m src.rapports` l'étude complète (huit documents, une vingtaine de figures) ; l'application Streamlit (sept pages) consomme les mêmes artefacts ; tests automatisés ; seed unique ; aucune clé dans le dépôt. Test à blanc depuis une copie vierge : identique sur les 10 indicateurs contrôlés.

Usage d'outils d'IA (énoncé § 7) : code, structure de l'étude et rédaction produits avec l'assistance d'un assistant IA (Claude), sous direction et relecture humaines ; fragments des verbatims synthétiques rédigés par ce même assistant. Les choix de modélisation, les décisions de périmètre et les conclusions sont assumés par l'auteur.

Références. Ascarza (2018) *Retention Futility*, J. Marketing Research · Elero et al. (2026) *Computers* 15(2) · Chong et al. (2023) J. Soft Computing & Data Mining · Mustafa et al. (2021) *F1000Research* · Kannan et al. (2022) *ICTIM* · Hastie, Tibshirani & Friedman, *Elements of Statistical Learning* § 7.10 · Gómez-Vargas et al.

(2025) Eur. J. Operational Research · Qu et al. (2025) TabICL, ICML · Hollmann et al. (2025) TabPFN, Nature.