

Prédire la catégorie NPS des clients silencieux

Priorisation des appels de rétention — synthèse pour la direction Expérience Client

1. En une page

Un opérateur télécom interroge ses clients sur leur propension à le recommander ; **15 % répondent**. Ce travail construit un modèle qui estime, pour chacun des 85 % silencieux, s'il est Détracteur, Passif ou Promoteur, et une application qui en tire une liste d'appels priorisée pour l'équipe rétention.

Trois résultats.

1. **La grille NPS proposée dans l'énoncé fabrique un résultat faux.** Appliquée telle quelle, elle donne un NPS de **-42**, à 60–75 points des benchmarks télécom. Elle classe en détracteurs 2665 clients « moyennement satisfaits » (38 % de la base) dont 84 % sont restés fidèles. En demandant aux données à qui ces clients ressemblent, on trouve qu'ils penchent à **72% du côté des promoteurs**. Le NPS corrigé est de **+21**, dans la fourchette du secteur.
2. **Le modèle multiplie par 2.7 l'efficacité des appels.** Sur 500 appels, 49% touchent un vrai détracteur contre 18% au hasard — **17 235 € de gain net supplémentaire par campagne** à hypothèses de coût constantes. Il retrouve 78% des détracteurs.
3. **Il rate davantage les jeunes détracteurs** : 61% de rappel chez les moins de 30 ans contre 86% chez les 60 ans et plus — sans qu'aucune variable d'âge n'entre dans le modèle. Mesuré, signalé, à traiter avant production.

Une décision demandée. Appeler les clients les plus à risque n'est pas la stratégie la plus rentable : la recherche établit qu'il faut cibler ceux dont le comportement change le plus quand on les appelle (Ascarza, *Journal of Marketing Research*, 2018). Mesurer cela ne demande qu'une chose, gratuite : **ne pas contacter 10 à 20 % des clients ciblés à la prochaine campagne, tirés au hasard.**

2. Les données et leurs pièges

7 043 clients d'un opérateur californien fictif (IBM Telco), cinq tables jointes sans perte. La colonne clé est une **satisfaction de 1 à 5** déclarée par le client. Trois faits ont structuré le travail.

Le dataset contient sa propre réponse. Les clients à satisfaction 1–2 sont **tous partis** ; ceux à 4–5, **aucun**. Toute colonne liée au départ (Churn Value, Churn Score, Customer Status, CLTV...) donnerait un score presque parfait et un modèle inutilisable — au moment de détecter un détracteur, il n'est pas encore parti. Ces colonnes sont identifiées, classées en trois natures de fuite (conséquence, disponibilité, modèle amont), **mesurées** par information mutuelle, et exclues. La littérature fournit le contre-exemple : une étude publiée annonce 98 % d'exactitude avec la note NPS parmi ses variables.

La note « 3 » décide de tout. 2665 clients, 38 % de la base, 84 % encore présents. Plutôt que de décider où ils vont, un modèle entraîné sur les seuls extrêmes (1–2 contre 4–5, exactitude 80%) les a classés : 72% ressemblent à des promoteurs. Le bloc est donc traité comme **Passif**. On a évité d'étiqueter chaque client individuellement par ce modèle — la cible serait devenue une fonction des variables, et le modèle final aurait réappris sa propre sortie.




Figure 1 — Trois façons de construire la cible, et le NPS qui en résulte. Bande verte : benchmark télécom publié.

Les offres commerciales sont une quasi-expérience — piégée. Les clients ayant reçu l'offre E partent **deux fois plus** que ceux sans offre. Lire « l'offre E fait fuir » serait une erreur : elle a été proposée à des clients déjà fragiles. On ne lit pas un effet causal dans des données observationnelles — ce constat fonde la décision demandée en section 5.

3. Un modèle évalué dans les conditions réelles

Le protocole. Un découpage aléatoire aurait été trompeur : les répondants à une enquête ne sont pas un échantillon au hasard — les mécontents et les enthousiastes répondent plus. Trois scénarios de non-réponse ont été simulés, du plus optimiste au plus réaliste (MNAR : la propension à répondre dépend de la satisfaction elle-même). Dans le scénario réaliste, la part de notes extrêmes passe de **37% dans la base à 71% chez les répondants**. Le modèle est entraîné sur ces 15 % biaisés et évalué sur les 85 % silencieux, dont on connaît la vérité. Ses scores sont donc réalistes.




Figure 2 — Satisfaction des répondants simulés vs base complète. Sous S3, les extrêmes dominent.

Trois familles, le plus simple gagne. Régression logistique, régression ordinaire à seuils, gradient boosting — comparés sur 27 combinaisons (3 scénarios × 3 cibles × 3 modèles), réglés puis sélectionnés sur le kappa quadratique pondéré, qui respecte l'ordre des classes.

Modèle	Kappa	Macro-F1	Rappel Détracteur
baseline_logistique	0.370	0.497	0.785
ordinal_seuils	0.368	0.450	0.629
boosting_hgb	0.343	0.387	0.741

Famille	Kappa par défaut	Kappa réglé	Décision
baseline_logistique	0.370	0.369	version par défaut
boosting_hgb	0.343	0.365	non retenu (famille non finale)

Avec ~1 050 clients pour apprendre, le boosting n'a pas de quoi justifier sa complexité. La baseline n'était pas une formalité. TabPFN n'a pas pu être évalué dans l'environnement de travail ; sa place est documentée dans le rapport détaillé.

Aucune fuite. Exactitude maximale observée 0.61 (seuil d'alerte 0,85, calé sur la littérature) ; écart arbres/linéaire -0.06 (une fuite se signale par un écart > +0,30).

Performance, par classe — jamais globale seule.

Classe	Précision	Rappel	F1	Effectif
Détracteur	0.39	0.78	0.53	1083
Passif	0.58	0.32	0.42	2590
Promoteur	0.54	0.56	0.55	2290

Kappa quadratique **0.370**, macro-F1 0.497. Le Détracteur — la classe qui compte — est la mieux retrouvée. Le Passif, milieu ambigu par définition, est le plus difficile, comme dans la littérature. La calibration des probabilités a été testée puis **corrigée** : ajustée sur les répondants biaisés, elle écrasait la classe Passif et surestimait les probabilités. Décision : les probabilités servent à **classer** les clients, pas à lire une fréquence.

Le signal textuel

7043 notes de contact synthétiques ont été générées (source : gabarit_stochastique_seed, 25 % de bruit de tonalité), puis combinées au modèle tabulaire. La fusion gagne +0.022 de kappa — **et ce chiffre ne prouve rien** : le texte a été fabriqué à partir de la classe, il contient donc le label. L'expérience valide la chaîne technique, pas la valeur de vrais verbatims. La conclusion opérationnelle est de **ne pas déployer** de composante texte sur cette seule base.

4. Ce que ça vaut pour l'équipe rétention




Figure 3 — Gauche : fiabilité des probabilités (sous la diagonale : surestimées). Droite : part des détracteurs captés selon le nombre d'appels.

À K = 500 appels par mois : **précision 49%**, rappel 23%, lift $\times 2.7$. Avec un coût d'appel de 12 €, une valeur de client retenu de 450 € et un taux de succès de 25% — **paramètres à valider avec l'équipe** — la campagne ciblée rapporte 21 450 € nets contre 4 215 € au hasard.

Ce qui fait un détracteur, selon le modèle : contrat sans engagement, faible ancienneté, absence de parrainage, facture mensuelle élevée. Ces associations tiennent quel que soit le mapping de la cible. Le levier le plus probable pour un détracteur prédit : s'il est en contrat mensuel, proposer un engagement ; sinon, revoir la charge mensuelle. Ce sont des **associations**, pas des causes.




Figure 4 — Rappel Détracteur par sous-groupe. Les variables démographiques sont exclues du modèle et servent uniquement à cet audit.

Équité. L'écart de 25 points entre groupes d'âge est le point à escalader. Exclure les démographiques du modèle coûte peu en performance mais **ne suffit pas** : le modèle les retrouve via les proxys contractuels. L'audit doit être répété à chaque réentraînement ; un seuil de décision par groupe d'âge est une piste, à trancher par le métier.

5. Limites, décision, suites

Ce qu'on ne peut pas faire avec ces données : estimer l'effet d'un appel. Aucune campagne enregistrée, aucune assignation aléatoire. Ce modèle classe par **risque**. La littérature établit que l'optimum économique classe par **sensibilité à l'intervention** — les clients qui restent *parce qu'on les a appelés*, pas ceux qui étaient déjà décidés à partir.

La décision. À la prochaine campagne, ne pas contacter 10 à 20 % des clients ciblés, tirés au hasard. Ce groupe de contrôle coûte quelques clients non retenus et achète deux choses : la mesure de l'effet réel de la campagne, et les données qui permettraient, au cycle suivant, de cibler par sensibilité. Sans lui, un détracteur appelé puis retenu change de classe, et le modèle réapprend l'effet de sa propre intervention comme une propriété du client — il se dégrade sans que personne ne voie pourquoi.

Monitoring. Un monitoring de dérive (indice PSI par variable et sur les prédictions) est implémenté. Sur un mois simulé (tarif +12 %, 15 % des contrats basculés en mensuel, 10 % migrés vers la fibre), le déclencheur de réentraînement se déclenche — variables en alerte : Monthly Charge, charge_par_service.

Limites assumées : hypothèses économiques à valider ; propension à répondre simulée, plausible mais non observée ; cadrage panafricain plaqué sur un dataset californien ; verbatims synthétiques sans clé API disponible.

Reproductibilité. `python -m src.run` régénère données, cible, modèles et évaluation ; `python -m src.rapports` l'étude complète (19+ rapports, 17+ figures) ; l'application Streamlit consomme les mêmes artefacts. Seed unique. Aucune clé dans le dépôt.

Usage d'outils d'IA (§ 7 de l'énoncé) : code, structure de l'étude et rédaction produits avec l'assistance d'un assistant IA (Claude), sous direction et relecture humaines ; fragments des verbatims synthétiques rédigés par ce même assistant. Les choix de modélisation, les décisions de périmètre et les conclusions sont assumés par l'auteur.

Références. Ascarza (2018) *Retention Futility*, J. Marketing Research · Elero et al. (2026) *Computers* 15(2) · Chong et al. (2023) *J. Soft Computing & Data Mining* · Mustafa et al. (2021) *F1000Research* · Kannan et al. (2022) *ICTIM* · Zihayat et al. (2021) *J. Business Research* · Gómez-Vargas et al. (2025) *Eur. J. Operational Research* · Devriendt, Berrevoets, Verbeke, Information Sciences.